



Doc: Ingeniería de Datos y Generación del Entorno

👤 Creada por	 Roberto Rodríguez Núñez
🕒 Hora de creación	@7 de diciembre de 2025 18:23
☰ Categoría	Documentación técnica
👤 Última edición por	 Roberto Rodríguez Núñez
🕒 Fecha de última actualización	@28 de enero de 2026 20:15

Documentación Técnica: Ingeniería de Datos y Generación del Entorno

Módulo: src/utils/generar_dataset_final.py

Objetivo: Generación del dataset maestro (dataset_final.csv) para el entrenamiento del Agente RL.

1. Justificación del Pipeline ETL (Extract, Transform, Load)

El entrenamiento de un agente de Aprendizaje por Refuerzo requiere un entorno estocástico pero realista. Dado que no existen datasets públicos que contengan simultáneamente el consumo desagregado de 15 viviendas específicas en España y la generación solar en la misma ubicación para el año 2023, se ha diseñado un proceso de **Ingeniería de Datos** para sintetizar este escenario a partir de fuentes oficiales normalizadas.

El script `generar_dataset_final.py` actúa como un orquestador que ingesta tres series temporales heterogéneas y las fusiona en un tensor de estado coherente.

2. Metodología de Transformación de Datos

A. Modelado de la Demanda: Desnormalización y Agregación Estocástica

El archivo fuente consumo_esios_2023.csv proveniente de Red Eléctrica de España (REE) no contiene valores de energía (kWh), sino Coeficientes de Perfilado (C_h). Estos son valores adimensionales normalizados tal que:

$$\sum_{h=1}^{8760} C_h = 1.0$$

(La suma de todos los coeficientes del año es igual a la unidad).

Justificación de la Multiplicación por 3.500:

Para transformar este perfil estadístico en una curva de carga física (potencia/energía), es necesario realizar una operación de desnormalización aplicando un escalar que represente la demanda anual total de la vivienda objetivo.

Según informes del IDAE y estadísticas del mercado eléctrico español, el consumo medio anual de un hogar residencial estándar se sitúa en el entorno de los 3.500 kWh.

Por tanto, la demanda base horaria ($D_{\text{base}, h}$) se calcula como:

$$D_{\text{base}, h} \text{ (kWh)} = C_h \times 3500$$

Simulación de la Comunidad (15 Vecinos):

Para evitar que la simulación asuma que las 15 viviendas son clones idénticos (lo cual generaría picos de demanda irreales), se aplica un algoritmo de Perturbación Estocástica para generar la demanda agregada

$$D_{\text{total}, h} = \sum_{i=1}^{15} D_{\text{base}, h} \cdot \alpha_i \cdot \beta_{i,h}$$

Donde:

- $\alpha_i \sim U(0.8, 1.2)$: Factor de escala constante por vivienda (simula que unos vecinos son más eficientes y otros gastan más).
- $\beta_{i,h} \sim N(1.0, 0.1)$: Ruido gaussiano horario (simula la variabilidad aleatoria del comportamiento humano en cada hora).

B. Modelado de la Generación: Escalado Lineal

Los datos de solar_pvgis_2023.csv representan la producción unitaria de 1 kWp (P_{unit}).

Dado que la comunidad dispone de una instalación fotovoltaica compartida de 50 kWp, la generación total se obtiene mediante escalado lineal, asumiendo pérdidas de sistema constantes (14%):

$$G_{\text{total}, h} = P_{\text{unit}, h} \times 50$$

C. Modelado de Precios: Homogeneización de Unidades

Los datos de mercado (precios_esios_2023.csv) se publican en €/MWh.

El agente de RL opera tomando decisiones sobre cantidades de energía en kWh. Para evitar inconsistencias numéricas en la función de recompensa, se realiza la conversión de unidades:

$$\text{Precio}_{\text{kWh}} = \frac{\text{Precio}_{\text{MWh}}}{1000}$$

3. Estructura del Dataset Resultante

El proceso genera el archivo `data/processed/dataset_final.csv`, una matriz de dimensiones (8760×3) , que constituye la "Verdad Terreno" (Ground Truth) para la simulación:

Variable	Unidad	Descripción	Uso en el Agente
(RL) <code>consumo_total</code>	kWh	Demanda agregada de las 15 viviendas tras la perturbación.	Define el Déficit a cubrir.
<code>generacion_total</code>	kWh	Producción solar total	

de la planta de 50kWp. Define el **Excedente** disponible. `precio_kwh` €/kWh Precio final de la energía (término de facturación). Variable de estado crítica para la toma de decisiones de **Arbitraje**.