



Doc: Justificación de la Estructura y Datos

👤 Creada por	 Roberto Rodríguez Núñez
🕒 Hora de creación	@7 de diciembre de 2025 16:27
☰ Categoría	Documentación técnica
👤 Última edición por	 Roberto Rodríguez Núñez
🕒 Fecha de última actualización	@7 de diciembre de 2025 18:24

Fecha: 7 de Diciembre de 2025

Fase: 2 - Desarrollo del Backend y Entorno de Simulación

Tarea: Configuración del Proyecto y ETL de Datos

1 Estructura y Organización del Proyecto

Para el desarrollo de la plataforma, se ha adoptado una arquitectura de carpetas basada en los estándares de la industria para proyectos de Ciencia de Datos y Aprendizaje por Refuerzo (inspirada en la metodología *Cookiecutter Data Science*). Esta estructura garantiza la **reproducibilidad**, la **modularidad** y la correcta separación entre los datos, el código de simulación y los scripts de entrenamiento.

A continuación, se detalla el árbol de directorios del repositorio y la función de cada módulo:

Figura 5.X: Árbol de directorios del proyecto

Plaintext

```
TFG-Comunidad-Energetica/
├── data/
│   ├── raw/          # Fuente de verdad: Datos inmutables (ESIOS, PVGIS)
│   └── processed/    # Datos transformados y normalizados para el Agente
├── src/
│   ├── envs/         # Definición del Entorno de Simulación (Gymnasium)
│   ├── utils/        # Módulos ETL y herramientas auxiliares
│   └── main.py       # Punto de entrada para el entrenamiento del Agente
```

```
|— .gitignore      # Configuración de exclusión para control de versiones
|— requirements.txt # Gestión de dependencias y librerías
```

La justificación técnica de esta organización se basa en tres pilares fundamentales:

1. Integridad y Pipeline de Datos (`/data`)

Se ha establecido una separación estricta entre los datos crudos (`/raw`) y los datos procesados (`/processed`):

- **Carpeta `/raw` (Datos Crudos):** Contiene los archivos originales descargados de fuentes oficiales (perfiles de ESIOS y radiación de PVGIS). Estos archivos se tratan como **inmutables** (solo lectura) para garantizar que la fuente de verdad nunca se corrompa.
- **Carpeta `/processed` (Datos Procesados):** Contiene el *dataset* final (`dataset_final.csv`) generado por los scripts de ingeniería de datos. Este archivo es el resultado de la limpieza, interpolación y agregación de las 15 viviendas, y es el único que consume el Agente de IA.
- *Beneficio:* Esta separación permite regenerar el dataset de entrenamiento en cualquier momento ejecutando el pipeline de datos, asegurando la **reproducibilidad** del experimento.

2. Modularidad del Código Fuente (`/src`)

El código se ha desacoplado siguiendo el principio de responsabilidad única:

- **Módulo `/envs`:** Encapsula toda la lógica de la simulación física y económica. Aquí reside la clase `EnergyEnv` (que hereda de `gymnasium.Env`), definiendo el espacio de estados, las acciones y la función de recompensa.
- **Módulo `/utils`:** Contiene scripts auxiliares para el preprocesado de datos (ETL). Esto evita contaminar la lógica principal del agente con tareas de limpieza de datos.
- **Script `main.py`:** Actúa como orquestador. Su única función es instanciar el entorno, configurar el agente (DQN) e iniciar el bucle de entrenamiento.

3. Gestión de Versiones y Dependencias

- **Archivo `.gitignore`:** Configurado para excluir del repositorio remoto los archivos binarios pesados (datasets en `/raw`) y los archivos temporales de compilación. Esto optimiza el rendimiento de Git y protege la propiedad de datos que pudieran ser sensibles.

- **Archivo** `requirements.txt` : Declara explícitamente las versiones de las librerías utilizadas (`pandas` , `numpy` , `stable-baselines3` , `gymnasium`), permitiendo replicar el entorno de desarrollo exacto en cualquier otra máquina mediante un gestor de paquetes.

2. Justificación de las Fuentes de Datos (ETL)

Para entrenar al Agente de Aprendizaje por Refuerzo (RL) en un escenario realista que simule una **Comunidad Energética en España**, se han seleccionado tres fuentes de datos oficiales correspondientes al año cerrado **2023**.

La elección del año 2023 se justifica por ser el último año natural completo con datos consolidados, permitiendo entrenar al agente con estacionalidad completa (invierno/verano).

A. Demanda: Perfil de Consumo Doméstico (ESIOS)

- **Fuente:** Red Eléctrica de España (ESIOS), Archivo "Perfiles de consumo iniciales (2.0TD)".
- **Justificación:** Ante la imposibilidad legal (RGPD) de obtener datos reales minuto a minuto de 15 familias específicas en España, se opta por utilizar el **perfil de carga estándar** definido por el operador del sistema.
- **Metodología de Simulación:** Este perfil unitario se utiliza como "semilla" para generar 15 perfiles sintéticos mediante **perturbación gaussiana**. Esto permite simular la diversidad estocástica de una comunidad real manteniendo la coherencia con los horarios y costumbres españolas.

B. Generación: Producción Fotovoltaica (PVGIS)

- **Fuente:** Photovoltaic Geographical Information System (PVGIS) de la Comisión Europea.
- **Ubicación:** [Tu Ciudad/Coordenadas].
- **Justificación:** PVGIS es el estándar científico para la estimación solar en Europa. Se utilizan datos de **SARAH-3** para obtener la irradiancia histórica real de 2023, asegurando que la correlación entre "Día Soleado" y "Precio de la luz" (que suele bajar cuando hay sol) se mantenga en la simulación. Se asume una instalación óptima (Azimut/Inclinación optimizados) para evaluar el potencial máximo de la comunidad.

C. Mercado: Precios de la Electricidad (ESIOS 1001)

- **Fuente:** ESIOS, Indicador "Término de facturación de energía activa del PVPC 2.0TD".
- **Justificación:** Para que la optimización económica sea realista, el agente debe entrenar con el precio final que paga el consumidor (incluyendo peajes y cargos), no con el precio mayorista (OMIE). Este dataset introduce la volatilidad real del mercado español, obligando al agente a aprender estrategias de arbitraje (comprar barato/vender caro).