

Análisis Comparativo Técnico y Económico entre DQN y PPO para Sistemas de Gestión de Energía Comunitaria (2020-2025)

1. Introducción: El Paradigma de la Gestión Energética Comunitaria

La transición energética global, acelerada drásticamente entre 2020 y 2025, ha precipitado un cambio estructural desde la generación centralizada hacia la descentralización a través de recursos energéticos distribuidos (DER). En este contexto, las Comunidades Energéticas Locales (LEC) han emergido como actores fundamentales, donde la gestión eficiente de los activos compartidos, específicamente los Sistemas de Almacenamiento de Energía en Baterías (BESS), determina la viabilidad económica y técnica del modelo. Este informe presenta un análisis exhaustivo y profundo sobre la implementación de algoritmos de Aprendizaje por Refuerzo Profundo (DRL) para el control de un Sistema de Gestión de Energía (EMS) en una comunidad residencial compuesta por 15 viviendas con almacenamiento compartido.

El problema de optimización al que se enfrenta un EMS comunitario es estocástico y de alta dimensión. Debe orquestar los flujos de energía para satisfacer la demanda agregada de 15 perfiles de carga heterogéneos, maximizar los ingresos mediante el arbitraje de energía en mercados eléctricos volátiles y, simultáneamente, mitigar la degradación electroquímica de la batería compartida, un activo de alto coste de capital.¹ Durante el periodo de revisión (2020-2025), la literatura científica ha evidenciado un desplazamiento de los métodos de control tradicionales, como la Programación Lineal Entera Mixta (MILP) y el Control Predictivo de Modelos (MPC), hacia enfoques basados en datos como el DRL. Esta transición responde a la incapacidad de los modelos tradicionales para gestionar eficazmente la incertidumbre inherente a los precios de mercado y la generación renovable sin depender de predicciones perfectas, las cuales son raramente alcanzables en la práctica.³

Dentro del espectro del DRL, dos algoritmos han dominado la investigación aplicada a microrredes y gestión de BESS: las Redes Q Profundas (DQN), que operan en espacios de acción discretos, y la Optimización de Política Próxima (PPO), que opera en espacios de acción continuos. La elección entre una arquitectura discreta o continua no es meramente una decisión de implementación de software; define la filosofía de control subyacente, afectando directamente la granularidad de la gestión de la potencia, la capacidad de respuesta ante picos de precios y la longevidad de la batería.⁵ Este documento desglosa las

implicaciones técnicas y económicas de esta elección, sintetizando hallazgos empíricos y teóricos para ofrecer una recomendación definitiva para operadores de microrredes comunitarias.

2. Marco Teórico y Mecánica Algorítmica en el Contexto del EMS

Para comprender las divergencias en el rendimiento económico y técnico entre DQN y PPO, es imperativo diseccionar sus mecánicas matemáticas y cómo estas interactúan con la física de los sistemas de almacenamiento y la microeconomía de los mercados eléctricos.

2.1 Deep Q-Networks (DQN): La Discretización del Control

El algoritmo DQN, una evolución del Q-learning clásico potenciada por redes neuronales profundas, se fundamenta en la aproximación de la función de valor $Q(s, a)$, que estima el retorno esperado de tomar una acción a en un estado s . En el contexto de un BESS comunitario, la naturaleza "basada en valor" de DQN implica que el agente aprende a predecir la utilidad económica futura de cada acción posible y selecciona la que maximiza esta utilidad.⁷

La característica definitoria de DQN es su requisito de un espacio de acciones discreto. Dado que la potencia de carga y descarga de un inversor de batería es físicamente continua (dentro de sus límites nominales), la aplicación de DQN requiere un proceso de **discretización**. Para una batería comunitaria con una capacidad de potencia $P_{\max}$, el espacio de acción continuo $A \in [-P_{\max}, P_{\max}]$ se fragmenta en un conjunto finito de niveles de potencia. Una configuración típica observada en la literatura incluye acciones como $\{-100\%, -50\%, 0\%, +50\%, +100\%\}$ de la capacidad nominal.⁵ Esta discretización transforma el problema de control óptimo en un problema de clasificación, donde la red neuronal debe seleccionar el índice de la acción óptima.

Aunque la discretización introduce un error de cuantificación inherente—el agente no puede solicitar, por ejemplo, un 73% de la potencia, sino que debe elegir entre 50% o 100%—estudios recientes sugieren que esta limitación se alinea sorprendentemente bien con la naturaleza de las decisiones de arbitraje, donde las estrategias óptimas a menudo residen en los límites operativos del sistema.⁵ Además, DQN utiliza un mecanismo de "Experience Replay" (repetición de experiencia), almacenando transiciones pasadas en un búfer de memoria y muestreándolas aleatoriamente para el entrenamiento. Esto rompe las correlaciones temporales en los datos secuenciales y permite una alta eficiencia de muestreo, ya que cada dato puede ser reutilizado múltiples veces para ajustar los pesos de la red, un factor crítico cuando los datos históricos de la comunidad son limitados.⁸

2.2 Proximal Policy Optimization (PPO): Control Continuo y Estabilidad

PPO, perteneciente a la familia de métodos Actor-Crítico, aborda el problema de control desde una perspectiva fundamentalmente diferente. En lugar de estimar el valor de cada acción individualmente, PPO aprende directamente una política parametrizada $\pi_\theta(a|s)$ que mapea estados a una distribución de probabilidad sobre el espacio de acciones continuo. El agente muestrea una acción de esta distribución, típicamente una Gaussiana definida por una media μ y una desviación estándar σ que la red neuronal emite.⁹

La ventaja teórica principal de PPO en un EMS reside en su capacidad para operar en el espacio de acción continuo nativo del inversor de la batería. Esto permite una granularidad de control infinita; el agente puede ajustar la potencia de carga/descarga con precisión arbitraria (por ejemplo, cargar a 12.5 kW para coincidir exactamente con el excedente solar de las 15 viviendas). Esta precisión es teóricamente superior para minimizar el estrés térmico en la batería y realizar un seguimiento de carga exacto.⁵

Sin embargo, PPO es un algoritmo "on-policy" (en política), lo que significa que solo puede aprender de los datos generados por la versión actual de su política. Una vez que se actualiza la política, los datos anteriores se descartan, lo que resulta en una eficiencia de muestreo significativamente menor en comparación con DQN. Para compensar la inestabilidad inherente al entrenamiento de gradiente de política, PPO introduce una función objetivo con "recorte" (clipping), que penaliza los cambios demasiado drásticos en la política entre actualizaciones. Esto garantiza una convergencia monótona y robusta, haciendo que PPO sea menos sensible a la selección de hiperparámetros que DQN, el cual puede sufrir de divergencia catastrófica si no se ajusta cuidadosamente.⁵

3. Análisis Económico: Eficiencia en Arbitraje y Mercados Energéticos

El arbitraje de energía—la práctica de cargar el BESS cuando los precios de la electricidad son bajos y descargar cuando son altos—constituye la principal fuente de ingresos para amortizar la inversión del sistema comunitario. El análisis de la literatura del periodo 2020-2025 revela una dicotomía fascinante: a pesar de la sofisticación y precisión teórica de PPO, los métodos discretos como DQN demuestran frecuentemente un rendimiento económico superior en escenarios de arbitraje puro.

3.1 La Superioridad del Control "Bang-Bang" en Espacios Discretos

Múltiples estudios empíricos han corroborado que, en entornos caracterizados por alta volatilidad de precios y estructuras tarifarias lineales (comunes en los mercados mayoristas y tarifas dinámicas residenciales), la estrategia de control óptima tiende a ser de naturaleza "bang-bang". Esto implica que, para maximizar el beneficio, el sistema debe operar en sus extremos operativos: cargar a máxima potencia, descargar a máxima potencia o permanecer

inactivo.⁵

El algoritmo DQN, al estar limitado a un conjunto discreto de acciones que típicamente incluye los extremos operativos ($P_{\max}$, $-P_{\max}$), posee un sesgo inductivo que favorece este comportamiento óptimo. En un estudio de caso realizado en el mercado eléctrico de Alberta, Canadá, caracterizado por fluctuaciones de precios extremas, se demostró que un agente DQN superó consistentemente a un agente PPO en la acumulación de recompensas financieras. La naturaleza binaria de las decisiones de arbitraje (comprar o vender) se alinea naturalmente con la arquitectura de clasificación de DQN, permitiendo al agente identificar y explotar rápidamente los diferenciales de precios.³

Por el contrario, los agentes de espacio continuo como PPO a menudo convergen hacia políticas conservadoras que operan en rangos intermedios de potencia. Este fenómeno se debe en parte a la dificultad de los gradientes de política para saturar las acciones hacia los límites físicos sin desestabilizar el entrenamiento. En la práctica, esto significa que durante una ventana de precios altos de 15 minutos, un agente DQN descargará agresivamente al 100% de la capacidad, mientras que un agente PPO podría descargar solo al 60% o 70%, dejando ingresos potenciales "sobre la mesa".⁵

3.2 El Problema del "Clipping" en los Límites Físicos

Un hallazgo técnico crítico que explica el subrendimiento de PPO en tareas de arbitraje es el problema del recorte de acciones en los límites (boundary clipping). Los inversores y baterías tienen límites físicos estrictos de potencia y Estado de Carga (SoC). Cuando un agente PPO genera una acción que excede estos límites (por ejemplo, solicitar una carga del 120% de la potencia nominal o intentar cargar una batería ya llena), la acción debe ser recortada por el entorno simulado al máximo físico (100%).

Este recorte introduce un problema de "gradiente desvanecido" o información oculta: el agente no recibe retroalimentación sobre *cuánto* excedió el límite, solo que la acción resultó en el límite. Como resultado, las políticas continuas a menudo se "atascan" en los límites del SoC o aprenden a ser excesivamente cautelosas para evitar generar acciones inválidas, lo que lleva a una subutilización de la capacidad de almacenamiento.⁵ Los algoritmos discretos como DQN evitan este problema estructuralmente, ya que el espacio de acciones se define a priori dentro de los límites factibles, o las acciones inválidas se pueden enmascarar explícitamente antes de la selección, garantizando que el agente siempre opere dentro de la región válida.⁵

3.3 Integración de Pronósticos y Maximización de Ingresos

La capacidad de integrar pronósticos de series temporales (precios y demanda futura) es un determinante clave del rendimiento económico. El análisis comparativo indica que DQN se beneficia de manera más significativa de la inclusión de datos predictivos que PPO.

En experimentos donde se proporcionaron pronósticos de precios perfectos o predicciones

basadas en modelos LSTM, el rendimiento de DQN mejoró hasta un 60%, logrando capturar oportunidades de arbitraje a largo plazo que requieren planificación (por ejemplo, cargar ahora para descargar dentro de 6 horas). La estructura basada en valor de DQN ($V(s,a)$) permite propagar eficazmente el alto valor esperado de los estados futuros (precios altos) hacia las decisiones presentes. En contraste, PPO mostró mejoras marginales o incluso inestabilidad al incorporar vectores de pronóstico de alta dimensión, debido a la varianza que estos introducen en la estimación de la ventaja y las actualizaciones de la política.³

La evidencia sugiere que para una comunidad de 15 viviendas donde el objetivo principal es reducir la factura eléctrica agregada mediante arbitraje, la "tosquedad" de DQN no es un defecto, sino una característica que facilita la convergencia hacia estrategias de maximización de beneficios agresivas y efectivas.

4. Análisis Técnico: Gestión de la Degradación de la Batería

Si bien DQN domina las métricas puramente económicas, la gestión de la salud de la batería introduce un objetivo contrapuesto. Las baterías de iones de litio, activos costosos y centrales para la comunidad, sufren degradación no lineal acelerada por el ciclaje profundo y las altas corrientes (C-rates).

4.1 Mecanismos de Degradación y Modelado en RL

La degradación de las baterías se manifiesta como pérdida de capacidad y aumento de la resistencia interna, impulsada por fenómenos como el crecimiento de la capa de Interfase de Electrolito Sólido (SEI) y el recubrimiento de litio. Estos procesos se aceleran exponencialmente con la temperatura y la magnitud de la corriente. En los sistemas de gestión energética basados en RL, la degradación se modela típicamente incorporando un término de penalización en la función de recompensa o utilizando modelos semi-empíricos de "throughput" (energía procesada) ponderados por la severidad del ciclo.⁹

4.2 La Promesa del Control Continuo (PPO) para la Salud de la Batería

Teóricamente, PPO posee una ventaja intrínseca para la preservación de la batería. Su espacio de acción continuo permite al agente seleccionar corrientes de carga y descarga precisas y moderadas (por ejemplo, 0.3C en lugar de 1C) que son suficientes para satisfacer la demanda neta de las 15 viviendas sin incurrir en el calentamiento resistivo asociado a las altas corrientes.

Estudios comparativos en el dominio de vehículos eléctricos híbridos (HEV)—que comparten la física de baterías de iones de litio—han demostrado que los agentes PPO pueden reducir las tasas de degradación entre un 2.5% y un 5.22% en comparación con DQN, manteniendo un rendimiento energético similar. La capacidad de PPO para generar perfiles de potencia

suaves evita los cambios abruptos y los picos de corriente característicos de las políticas discretas, lo que reduce el estrés mecánico y térmico en las celdas.¹¹

4.3 La Realidad del "Bang-Bang" en el Almacenamiento Estacionario

Sin embargo, la transferencia de esta ventaja de los vehículos eléctricos al almacenamiento estacionario comunitario no es directa. En el arbitraje de red, la estructura de incentivos a menudo favorece el comportamiento "bang-bang". Si el diferencial de precios entre horas valle y punta es suficiente para justificar el uso de la batería (superando el costo amortizado de degradación), la acción económicamente racional suele ser utilizar la máxima potencia disponible para mover la mayor cantidad de energía posible durante la ventana de oportunidad.

Por lo tanto, incluso con un espacio de acción continuo, un agente PPO bien entrenado para maximizar el beneficio neto (ingresos menos costo de degradación) a menudo convergerá hacia una política que imita el comportamiento "bang-bang" de DQN, oscilando entre potencia máxima y cero. La ventaja de la "suavidad" de PPO solo se materializa si la función de recompensa penaliza la degradación de manera muy agresiva, lo cual, paradójicamente, puede llevar al agente a una política de inacción excesiva para preservar la batería, sacrificando desproporcionadamente los ingresos.⁵

4.4 Estrategias de Mitigación en Espacios Discretos

Para abordar la agresividad inherente de DQN sin sacrificar su eficiencia en el arbitraje, la investigación reciente propone el uso de espacios de acción discretos "multi-nivel". En lugar de un conjunto binario simple (Carga Máx/Descarga Máx), se implementa un espacio de acción con mayor granularidad, por ejemplo:

$$A = \{-100\%, -66\%, -33\%, 0, +33\%, +66\%, +100\%\}$$

Este enfoque permite al agente DQN seleccionar tasas de C más bajas cuando el diferencial de precios es moderado o cuando se necesita gestión térmica, capturando aproximadamente el 95% de los beneficios de salud teóricos del control continuo sin incurrir en la complejidad y la inestabilidad de entrenamiento de PPO.¹⁴

5. Escalabilidad y Dinámica Comunitaria: El Reto de las 15 Viviendas

La dimensión específica de "15 viviendas" introduce desafíos de escalabilidad que afectan la elección del algoritmo, dependiendo de si el EMS controla solo la batería central o también las cargas flexibles dentro de las viviendas.

5.1 La Maldición de la Dimensionalidad

Si el alcance del EMS se limita a controlar el BESS compartido para gestionar la carga agregada de la comunidad, el espacio de estado es manejable y DQN sigue siendo altamente efectivo. Sin embargo, si el objetivo incluye la Gestión de Demanda (Demand Response) activa, controlando termostatos, cargadores de vehículos eléctricos o electrodomésticos dentro de cada una de las 15 viviendas, la complejidad del espacio de acción cambia drásticamente.

Para un control conjunto de 1 batería y 15 termostatos inteligentes (asumiendo acciones binarias ON/OFF para cada termostato), el tamaño del espacio de acción discreto para un DQN centralizado sería:

$$|A| = |A_{\text{BESS}}| \times |A_{\text{Termostato}}|^{15} \approx 5 \times 2^{15} \approx 163,840 \text{ acciones posibles}$$

Explorar y aprender una función Q sobre un espacio de 160,000 acciones es computacionalmente inviable y extremadamente ineficiente en términos de muestreo. Aquí es donde DQN falla categóricamente debido a la "maldición de la dimensionalidad".¹⁶

5.2 La Ventaja de Escalabilidad de PPO

PPO, al operar con salidas vectoriales continuas, escala linealmente con el número de activos controlados. Para el mismo escenario de 1 batería + 15 termostatos, la red neuronal de PPO simplemente necesitaría una capa de salida con 16 neuronas (un valor continuo para la batería y 15 valores continuos para los puntos de ajuste de temperatura). Esta capacidad de manejar espacios de acción de alta dimensión hace que PPO sea la única opción viable para arquitecturas de control centralizado que buscan orquestar múltiples activos flexibles dentro de la comunidad simultáneamente.¹

5.3 Implementación y Viabilidad Operativa

Desde una perspectiva de implementación para un proyecto piloto o una tesis universitaria (como sugieren algunos fragmentos de investigación), DQN presenta una barrera de entrada más baja. La lógica de decisión de DQN es transparente: se pueden inspeccionar los valores Q para ver exactamente qué valor espera el agente de cada acción ("Cargar", "Descargar", "Esperar"). Esto facilita la depuración y genera confianza en los operadores de la red. PPO, con su salida estocástica y arquitectura Actor-Crítico, es más complejo de implementar, ajustar y auditar.¹⁹

Además, en términos de velocidad de convergencia, aunque PPO es más estable, DQN suele ser más rápido en términos de "tiempo de reloj" para alcanzar una política competente en simulaciones de EMS, debido a su capacidad de reutilizar datos pasados (off-policy). PPO requiere generar nuevos datos frescos constantemente, lo que puede ralentizar el entrenamiento si el simulador de la comunidad (que modela 15 perfiles de carga térmica y

eléctrica) es computacionalmente pesado.¹⁰

6. Síntesis Comparativa y Matriz de Decisión

La siguiente tabla sintetiza los hallazgos técnicos y económicos revisados, proporcionando una comparación directa para el escenario de la comunidad de 15 viviendas.

Característica	DQN (Espacio Discreto)	PPO (Espacio Continuo)	Ventaja para EMS Comunitario
Espacio de Acción	Finito (ej. $\{-1, 0, 1\}$)	Infinito (Rango $[-1, 1]$)	DQN (Para arbitraje BESS puro)
Beneficio de Arbitraje	Alto (Explota diferenciales de precios)	Moderado (Tendencia conservadora)	DQN
Salud de Batería	Estrés alto (Tendencia "Bang-bang")	Potencial de optimización fina	PPO (Teórico) / DQN (Práctico multi-nivel)
Eficiencia de Muestreo	Alta (Off-policy, Replay Buffer)	Baja (On-policy)	DQN
Estabilidad	Baja (Sensible a hiperparámetros)	Alta (Región de confianza)	PPO
Escalabilidad	Pobre (Exponencial con activos)	Excelente (Lineal con dimensiones)	PPO (Si controla cargas domésticas)
Uso de Pronósticos	Excelente integración de valor futuro	Integración moderada/compleja	DQN
Complejidad Código	Baja/Media	Media/Alta	DQN

Tabla 1: Matriz comparativa de idoneidad técnica y económica.⁵

6.1 La Emergencia de Soluciones Híbridas

Es crucial destacar que la literatura de 2023-2025 apunta hacia la obsolescencia de la dicotomía estricta. Investigadores están adoptando enfoques híbridos como **P-DQN** (Parameterized Deep Q-Networks), que combinan la toma de decisiones discretas de alto nivel (ej. "Modo: Cargar") con parámetros continuos de bajo nivel (ej. "Intensidad: 12.5A"). Asimismo, se están integrando técnicas de "Safe RL" (RL Seguro) en PPO para imponer restricciones duras sobre la temperatura y el SoC de la batería, mitigando sus problemas de inestabilidad en los límites.⁵

7. Recomendaciones Estratégicas para la Comunidad de 15 Viviendas

Basándose en la evidencia recopilada, se formulan las siguientes recomendaciones específicas para el diseño del EMS comunitario:

7.1 Escenario A: El EMS controla únicamente la Batería Compartida

Recomendación: DQN (Double Dueling DQN) con Acciones Multi-Nivel.

Si el objetivo principal es gestionar el flujo de energía del BESS compartido para realizar arbitraje y autoconsumo colectivo, DQN es técnicamente y económicamente superior.

- **Justificación:** El problema se reduce a optimizar un solo activo donde las decisiones óptimas son predominantemente extremas ("comprar barato, vender caro"). PPO introduce una complejidad innecesaria y tiende a subutilizar la capacidad de la batería en ventanas de oportunidad cortas.
- **Implementación:** Se debe utilizar un espacio de acción discreto con granularidad media (ej. 5 o 7 niveles) para permitir cierta gestión de la degradación sin perder la capacidad de respuesta rápida. Es imperativo integrar una red LSTM para procesar pronósticos de precios y alimentar esta información al estado del agente DQN.

7.2 Escenario B: El EMS controla Batería + Cargas Domésticas (HVAC/EV)

Recomendación: PPO (o Multi-Agent PPO).

Si el alcance del proyecto incluye la modulación activa de las cargas dentro de las 15 viviendas para ofrecer servicios de respuesta a la demanda, DQN es inviable debido a la explosión combinatoria de estados.

- **Justificación:** PPO puede manejar un vector de acción de dimensión 16+ (1 batería + 15 cargas) de manera eficiente. Su estabilidad es crucial cuando se controlan múltiples actuadores simultáneamente.
- **Mitigación:** Para contrarrestar la debilidad de PPO en el arbitraje, se deben emplear técnicas de "Action Masking" (enmascaramiento de acciones) para evitar que el agente explore zonas de SoC inválidas y guiarlo hacia una utilización más efectiva del

almacenamiento.

7.3 Estrategia de Mitigación de Degradación

Independientemente del algoritmo, la gestión de la degradación no debe confiarse únicamente a la "suavidad" implícita del control continuo. Debe ser explícita en la función de recompensa. Se recomienda utilizar un modelo de **conteo de ciclos (Rainflow)** simplificado o un modelo de **throughput ponderado** por temperatura y C-rate durante el entrenamiento. Esto permite que tanto DQN como PPO "aprendan" el coste oculto de cada ciclo y autolimiten su agresividad operativa solo cuando el beneficio económico marginal no justifique el daño al activo.⁹

8. Conclusión

El análisis comparativo entre DQN y PPO para la gestión energética en una comunidad de 15 viviendas demuestra que no existe una solución única perfecta, sino una dependencia crítica del alcance del control. Para el periodo 2020-2025, la evidencia favorece a **DQN** como la herramienta pragmática y económicamente dominante para la gestión dedicada de almacenamiento (BESS), gracias a su alineación con la naturaleza binaria del arbitraje y su eficiencia de datos. Su supuesta desventaja en la gestión de la degradación es mitigable mediante la discretización multi-nivel.

Por otro lado, **PPO** se consolida como la arquitectura necesaria para la escalabilidad hacia sistemas multi-activo complejos. A medida que las comunidades energéticas evolucionen para integrar no solo una batería central, sino decenas de dispositivos IoT flexibles en cada hogar, la flexibilidad dimensional de PPO superará las limitaciones estructurales de DQN. Para el despliegue actual enfocado en arbitraje y vida útil del BESS compartido, la recomendación técnica es una implementación robusta de DQN asistida por pronósticos, priorizando la captura de valor económico y la simplicidad operativa sobre la precisión teórica del control continuo.

Obras citadas

1. Comparative analysis of Q-learning, SARSA, and deep Q-network for microgrid energy management - PubMed Central, fecha de acceso: diciembre 8, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11698738/>
2. Integrated Energy Optimization in Manufacturing Through Multiagent Deep Reinforcement Learning: Holistic Control of Manufacturing, Microgrid Systems, and Battery Storage | J. Manuf. Sci. Eng. | ASME Digital Collection, fecha de acceso: diciembre 8, 2025, <https://asmedigitalcollection.asme.org/manufacturingscience/article/147/6/061003/1211186/Integrated-Energy-Optimization-in-Manufacturing>
3. Enhancing Battery Storage Energy Arbitrage With Deep Reinforcement Learning and Time-Series Forecasting - arXiv, fecha de acceso: diciembre 8, 2025,

- <https://arxiv.org/html/2410.20005v1>
4. (PDF) Enhancing Battery Storage Energy Arbitrage with Deep Reinforcement Learning and Time-Series Forecasting - ResearchGate, fecha de acceso: diciembre 8, 2025, https://www.researchgate.net/publication/385318367_Enhancing_Battery_Storage_Energy_Arbitrage_with_Deep_Reinforcement_Learning_and_Time-Series_Forecasting
 5. Exploring the Preference for Discrete over Continuous Reinforcement Learning in Energy Storage Arbitrage - MDPI, fecha de acceso: diciembre 8, 2025, <https://www.mdpi.com/1996-1073/17/23/5876>
 6. (PDF) A Comparative Study of 13 Deep Reinforcement Learning Based Energy Management Methods for a Hybrid Electric Vehicle - ResearchGate, fecha de acceso: diciembre 8, 2025, https://www.researchgate.net/publication/362600080_A_Comparative_Study_of_13_Deep_Reinforcement_Learning_Based_Energy_Management_Methods_for_a_Hybrid_Electric_Vehicle
 7. What separates discrete and continuous action spaces (practically) when choosing an RL algorithm? - Quora, fecha de acceso: diciembre 8, 2025, <https://www.quora.com/What-separates-discrete-and-continuous-action-spaces-practically-when-choosing-an-RL-algorithm>
 8. Progress and summary of reinforcement learning on energy management of MPS-EV - PMC, fecha de acceso: diciembre 8, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC10755288/>
 9. Reinforcement Learning Based Optimal Battery Control Under Cycle-based Degradation Cost - IEEE Xplore, fecha de acceso: diciembre 8, 2025, <https://ieeexplore.ieee.org/ielam/5165411/9927219/9789478-aam.pdf>
 10. (PDF) Comparative Study of Reinforcement Learning Performance Based on PPO and DQN Algorithms - ResearchGate, fecha de acceso: diciembre 8, 2025, https://www.researchgate.net/publication/393613412_Comparative_Study_of_Reinforcement_Learning_Performance_Based_on_PPO_and_DQN_Algorithms
 11. Proximal Policy Optimization Based Intelligent Energy Management for Plug-In Hybrid Electric Bus Considering Battery Thermal Characteristic - MDPI, fecha de acceso: diciembre 8, 2025, <https://www.mdpi.com/2032-6653/14/2/47>
 12. Reinforcement Learning for Hydrobotic AUVs - DiVA portal, fecha de acceso: diciembre 8, 2025, <https://www.diva-portal.org/smash/get/diva2:1706612/FULLTEXT01.pdf>
 13. A Comparison of Representative Value-based and Policy-based ..., fecha de acceso: diciembre 8, 2025, <https://snu.elsevierpure.com/en/publications/a-comparison-of-representative-value-based-and-policy-based-deep->
 14. A New Error Temporal Difference Algorithm for Deep Reinforcement Learning in Microgrid Optimization This work was supported in part by the Royal Society under grants IEC\NSFC\201107. - arXiv, fecha de acceso: diciembre 8, 2025, <https://arxiv.org/html/2511.18093v1>
 15. Multi-User Satisfaction-Driven Bi-Level Optimization of Electric Vehicle Charging

Strategies, fecha de acceso: diciembre 8, 2025,

<https://www.mdpi.com/1996-1073/18/15/4097>

16. (PDF) Active management of battery degradation in wireless sensor network using deep reinforcement learning for group battery replacement - ResearchGate, fecha de acceso: diciembre 8, 2025, https://www.researchgate.net/publication/390038805_Active_management_of_battery_degradation_in_wireless_sensor_network_using_deep_reinforcement_learning_for_group_battery_replacement
17. Hybrid Deep Reinforcement Learning Considering Discrete-Continuous Action Spaces for Real-Time Energy Management in More Electric Aircraft - ResearchGate, fecha de acceso: diciembre 8, 2025, https://www.researchgate.net/publication/363142399_Hybrid_Deep_Reinforcement_Learning_Considering_Discrete-Continuous_Action_Spaces_for_Real-Time_Energy_Management_in_More_Electric_Aircraft
18. Parallel Hybrid Deep Reinforcement Learning for Real-time Energy Management of Microgrid - IEEE Xplore, fecha de acceso: diciembre 8, 2025, <https://ieeexplore.ieee.org/iel8/8685265/8816648/10666963.pdf>
19. Comparative Analysis of Optimization Techniques for Microgrid Energy Management - POLITesi, fecha de acceso: diciembre 8, 2025, <https://www.politesi.polimi.it/bitstream/10589/231235/5/Thesis%20%2810%29.pdf>
20. DQN vs PPO. Discussion with my mentors - Jerrick Liu, fecha de acceso: diciembre 8, 2025, <https://jerrickliu.com/2020-07-13-FourthPost/>
21. Mixed-Integer Optimal Control via Reinforcement Learning: A Case Study on Hybrid Electric Vehicle Energy Management - arXiv, fecha de acceso: diciembre 8, 2025, <https://arxiv.org/html/2305.01461v3>
22. Optimizing EV Battery Management: Advanced Hybrid Reinforcement Learning Models for Efficient Charging and Discharging - MDPI, fecha de acceso: diciembre 8, 2025, <https://www.mdpi.com/1996-1073/17/12/2883>