

Universidade de Vigo

ESCOLA SUPERIOR DE ENXEÑARÍA INFORMÁTICA

Memoria do Traballo de Fin de Grao que presenta

D. Roberto Rodríguez Núñez

para a obtención do Título de Graduado en Enxeñaría Informática

**Diseño y Desarrollo de una Plataforma Software para la Optimización
de Comunidades Energéticas**



Ourense, Xullo, 2026

Traballo de Fin de Grao N°: EI 25/26-79

Titor/a: Eva Mª Lorenzo Iglesias

Cotitor: Pedro Celard Pérez

Área de coñecemento: Linguaxes e Sistemas Informáticos

Departamento: Informática

Resumen

El actual marco regulatorio del autoconsumo colectivo en España, consolidado mediante el Real Decreto 244/2019, ha abierto una oportunidad para que las comunidades de pequeña escala gestionen de forma autónoma su energía fotovoltaica. Sin embargo, las soluciones de gestión inteligente disponibles suelen ser cerradas y propietarias y están concebidas mayoritariamente para el almacenamiento individual o industrial; las pocas orientadas al caso comunitario rara vez resultan accesibles o adaptables a una comunidad rural de pequeña escala bajo el RD 244/2019, ni validan de forma transparente el beneficio que aporta su controlador frente a una referencia bien calibrada.

Este trabajo investiga, diseña e implementa un motor de decisión inteligente basado en aprendizaje por refuerzo para la optimización económica de la batería comunitaria en una comunidad energética de autoconsumo fotovoltaico colectivo. Tras un proceso documentado de exploración con las familias DQN, PPO, TD3, DDPG y SAC, se diseña e implementa el controlador Residual SAC sobre un MPC base, arquitectura híbrida que resuelve los problemas de arranque en frío y cuantización que impidieron a los candidatos anteriores superar el *baseline* competitivo (MPC con pronóstico realista, +43,39 €/semana). En la suite de validación final (tres semillas de entrenamiento, diez semillas de ruido y 50 semanas de evaluación no vistas), el controlador alcanza +44,05 €/semana, una mejora de +0,66 €/semana estadísticamente significativa (test de Wilcoxon pareado, $p < 0,001$) sobre el MPC realista.

El motor se integra en una plataforma software de tipo SaaS con gemelo digital de la instalación, módulo de ingeniería de datos con fuentes oficiales (ESIOS, PVGIS) y capa de visualización diferenciada por rol (Superadmin y Usuario de la comunidad). El sistema implementa la capa de planificación horaria (Nivel 3) del control jerárquico estándar para sistemas de almacenamiento, replicando la lógica de despacho horario utilizada por los agregadores energéticos en el mercado diario de OMIE.

Índice general

Índice de figuras	v
Índice de tablas	vi
Glosario de Acrónimos	1
1 Introducción	2
1.1 Contexto y Problemática	2
1.2 Posicionamiento en el Control Jerárquico Estándar	3
1.3 Estructura del Documento	3
2 Objetivos	4
2.1 Objetivos Generales	4
2.2 Objetivos Específicos	5
2.3 Alcance	5
3 Antecedentes y Contexto	6
3.1 Marco Regulatorio del Autoconsumo Colectivo en España	6
3.2 El Problema de la Gestión de Baterías en Comunidades Energéticas . .	8
3.3 El Espacio de Acciones: Discreto frente a Continuo	9
3.4 Estado del Arte: RL puro frente a MPC y la Arquitectura Híbrida . . .	9
3.5 Soluciones Actuales para la Gestión del Almacenamiento	11
4 Resumen de la Solución Propuesta y Metodología	12
4.1 Descripción General	12
4.2 Metodología	13
5 Marco Práctico y Herramientas Empleadas	15
5.1 Fundamentos Teóricos y Herramientas	15
5.1.1 Proceso de Decisión de Markov	15
5.1.2 Familias de Algoritmos Aplicables	16
5.1.3 Soft Actor-Critic	16
5.1.4 Control Predictivo Basado en Modelos (MPC)	17
5.1.5 Arquitectura Residual MPC+RL	17
5.1.6 Herramientas y Stack Tecnológico	18
5.2 Ingeniería de Datos y Entorno de Simulación	19
5.2.1 Fuentes de Datos Oficiales	19
5.2.2 Pipeline ETL	19
5.2.3 Justificación del Dimensionado de la Instalación	21
5.2.4 Partición Train/Evaluación por Muestreo Estratificado	21
5.2.5 Simulador Físico-Económico: Gemelo Digital	22
5.3 Motor de Decisión Energético	26
5.3.1 Cotas de Rendimiento: El Controlador MPC	26
5.3.2 Experimentación con Algoritmos Candidatos	27

5.3.3	Justificación del Motor de IA sobre MPC Puro	31
5.3.4	Diseño del Residual SAC: de Aditiva a Multiplicativa	33
5.3.5	Formulación Final del Residual SAC	34
5.3.6	Espacio de Observación (112 dimensiones)	35
5.3.7	Protocolo de Inicialización DAWN	36
5.3.8	Modelo de Ruido de Precios en Tres Capas	36
5.3.9	Hiperparámetros Finales	36
5.3.10	Criterio de Selección del Modelo y Protocolo de Evaluación . . .	37
5.3.11	Diseño de la Suite de Validación	37
5.3.12	Resultados Experimentales	38
5.4	Despliegue en Producción: Exportación a ONNX	44
5.5	Plataforma SaaS	45
5.5.1	Arquitectura	45
5.5.2	Integración con el Motor de Decisión: la API Edge	46
5.5.3	Cálculo de Cierres y Reparto por Vivienda	46
5.5.4	Naturaleza de los Valores del Panel de Control	48
6	Planificación y Seguimiento	50
6.1	Fases del Proyecto	50
6.2	Desviaciones Técnicas	51
7	Principales Aportaciones	52
8	Conclusiones	53
8.1	Conclusiones Técnicas	53
8.2	Limitaciones y Decisiones de Diseño	54
8.3	Conclusiones Personales	56
9	Líneas de Trabajo Futuro	57
	Bibliografía	58
A	Capacidad Fotovoltaica por Vivienda	62
B	Configuración Completa: system.yaml	63
C	Árbol de Directorios del Repositorio	66
D	Suite de Tests Automatizados	68
E	Análisis de Viabilidad Económica	69
E.1	Coste de la Inversión	69
E.2	Beneficio del Controlador y Periodo de Retorno	69
E.3	El Papel de las Subvenciones	70
E.4	Conclusión	70

F	Resultados Completos de la Suite de Validación	71
F.1	Baselines (sin aprendizaje)	71
F.2	Familia DQN (valor, discreta; 3 semillas)	71
F.3	Familia PPO discreto (on-policy, discreta; 3 semillas)	72
F.4	Familia PPO continuo (on-policy, continua; 3 semillas)	72
F.5	SAC puro (continua, sin MPC; 3 semillas)	72
F.6	Familia Residual SAC (controlador propuesto)	73
F.7	Familia TD3 residual (3 semillas)	73
F.8	Familia DDPG residual (3 semillas)	73
G	Reproducibilidad y Entornos de Entrenamiento	74
H	Historial Completo de Experimentos	76
H.1	Familia DQN	76
H.2	Familia PPO	77
H.3	Familia Residual SAC	77

Índice de figuras

4.1	Arquitectura de la plataforma, parte 1: capas de investigación y <i>benchmarking</i> (datos, simulación, entornos, entrenamiento multisevilla, controladores y evaluación comparativa). La parte de producción (<i>edge</i> y SaaS) se muestra en la Figura 5.5.	13
5.1	Pipeline de datos: fuentes crudas oficiales (ESIOS 1006/1001/1739 y PVGIS), proceso ETL y escalado comunitario, construcción de la observación en el entorno de simulación y normalización VecNormalize previa a la red del agente.	20
5.2	Topología física de la comunidad y de los cuatro flujos de la batería. En cada hora la batería o carga (cs, cm) o descarga (dc, dr); los flujos grises son consecuencia automática del balance horario y no pasan por la batería. 22	
5.3	Taxonomía de los controladores implementados. Todas las familias comparten el contrato <code>solve(state, forecast)</code> , lo que permite evaluarlas bajo el mismo protocolo; el MPC suministra la política base <code>u_mpc(t)</code> a la familia residual.	33

5.4	Diagrama de secuencia de la inferencia del Residual SAC sobre el entorno simulado: el MPC resuelve su LP y propone la acción base, el actor calcula la corrección Δ (determinista, con normalización congelada) y la fusión multiplicativa se aplica al simulador físico-económico.	35
5.5	Arquitectura de la plataforma, parte 2: producción <i>edge</i> (exportación ONNX, inferencia ligera y bucle horario) y capa SaaS (recepción de decisiones, histórico y cierres mensuales).	45
5.6	Modelo de datos de la plataforma SaaS: siete entidades con AccesoVivienda como relación asociativa N:M entre Usuario y Vivienda	46
5.7	Captura de pantalla del panel de control de la plataforma SaaS (LeaLink) para una vivienda: indicadores de ahorro, comparativa de gasto entre escenarios (sin paneles, sin comunidad y con comunidad), origen de la energía consumida y comparación con el resto de viviendas de la comunidad.	49
6.1	Diagrama de Gantt del proyecto, con resolución quincenal: para cada fase, la barra superior (gris) es la planificación inicial y la inferior (azul) la ejecución real. Las mayores desviaciones se concentran en las fases 5 y 6 (en torno a un mes entre ambas, por las causas de la Sección 6.2) y se absorben comprimiendo las fases 7 y 8, manteniendo la entrega en julio de 2026.	51
C.1	Componentes y dependencias del pipeline completo del Residual SAC (seis fases, de los datos crudos al SaaS). Los artefactos que cruzan fases (<code>dataset_final.csv</code> , <code>best_model.zip</code> , <code>residual_sac_actor.onnx</code>) aparecen resaltados.	67

Índice de cuadros

5.1	Stack tecnológico de la plataforma LeaLink.	18
5.2	Comparativa estructural de los controladores evaluados.	32
5.3	Composición del vector de observación del Residual SAC.	35
5.4	Hiperparámetros del Residual SAC (configuración final SAC-C).	36
5.5	Resultados de la suite de validación: <i>baselines</i> y mejor versión de cada familia (€/semana, beneficio marginal frente a IDLE; 50 semanas <i>held-out</i> $\times$ 10 semillas de ruido; IC95 por <i>bootstrap</i> ; <i>p</i> del test de Wilcoxon pareado por semana y semilla de ruido frente al MPC realista).	39

5.6	Consistencia inter-entrenamiento del Residual SAC (SAC-C): métrica interna de entrenamiento por semilla (€/semana).	40
5.7	Barrido del rango de corrección $\delta_{\text{máx}}$ (ablación F2).	41
5.8	Sensibilidad al error de pronóstico de consumo (ablación F6). La fila central corresponde a la configuración estándar (F6-s15 es exactamente SAC-C).	41
6.1	Fases del proyecto y distribución temporal.	50
A.1	Capacidad fotovoltaica y número de paneles por vivienda.	62
D.1	Tests críticos del sistema.	68
G.1	Entornos de entrenamiento por familia.	74
H.1	Historial de configuraciones DQN.	76
H.2	Historial de configuraciones PPO.	77
H.3	Historial de configuraciones Residual SAC.	77

Glosario de Acrónimos

API Interfaz de Programación de Aplicaciones (*Application Programming Interface*).

BESS Sistema de Almacenamiento de Energía en Baterías (*Battery Energy Storage System*).

DDPG Gradiente de Política Determinista Profundo (*Deep Deterministic Policy Gradient*).

DQN Red Q Profunda (*Deep Q-Network*).

EMS Sistema de Gestión Energética (*Energy Management System*).

ETL Extracción, Transformación y Carga (*Extract, Transform, Load*).

FV Fotovoltaico.

LFP Litio Hierro Fosfato (*Lithium Iron Phosphate*).

LP Programación Lineal (*Linear Programming*).

MDP Proceso de Decisión de Markov (*Markov Decision Process*).

MPC Control Predictivo Basado en Modelos (*Model Predictive Control*).

ONNX Open Neural Network Exchange.

PPO Optimización de Política Proximal (*Proximal Policy Optimization*).

PVPC Precio Voluntario para el Pequeño Consumidor.

RL Aprendizaje por Refuerzo (*Reinforcement Learning*).

SaaS Software como Servicio (*Software as a Service*).

SAC Actor-Crítico Suave (*Soft Actor-Critic*).

SB3 Stable-Baselines3.

SoC Estado de Carga (*State of Charge*).

TD3 Gradiente de Política Determinista Profundo con Doble Retardo (*Twin Delayed Deep Deterministic Policy Gradient*).

Capítulo 1

Introducción

1.1. Contexto y Problemática

La transición energética hacia un modelo descarbonizado sitúa al autoconsumo fotovoltaico colectivo como uno de los instrumentos más prometedores para democratizar la generación de energía renovable a nivel ciudadano. El Real Decreto 244/2019 consolidó en España el marco regulatorio que permite a varias unidades de consumo compartir una instalación de generación fotovoltaica y distribuir los excedentes entre sus participantes mediante coeficientes de reparto horarios. Este mecanismo abre la puerta a un modelo energético más justo y autónomo, especialmente en el entorno rural.

Sin embargo, la puesta en práctica de este potencial choca con una realidad técnica. Existen soluciones comerciales de gestión energética e incluso productos que abordan el almacenamiento compartido, pero la mayoría son cerradas y propietarias (difíciles de auditar y de adaptar) y están diseñadas para el almacenamiento individual o industrial, donde la batería responde a un único punto de consumo. Las que sí contemplan el caso comunitario rara vez se ajustan al caso español (el marco de autoconsumo del RD 244/2019 o, como en este trabajo, la cooperativa con un único punto de suministro cuya factura es el balance horario agregado) ni resultan asequibles para una comunidad rural de pequeña escala, y casi nunca documentan de forma transparente cuánto beneficio económico aporta realmente su controlador frente a una referencia bien calibrada. La batería de una comunidad de autoconsumo colectivo plantea, por tanto, un problema distinto: un único activo debe gestionarse de forma centralizada para el balance agregado de todos los participantes, y queda infrautilizada sin una política de carga y descarga que explote la variabilidad horaria del precio de la energía en el mercado español.

Modalidad adoptada. Este trabajo se acoge al marco de autoconsumo del RD 244/2019 y el RDL 7/2025, pero en la modalidad concreta de **cooperativa con un único punto de suministro (CUPS)**: las quince viviendas se presentan ante el sistema eléctrico a través de un solo contador frontera, por lo que la liquidación económica se realiza sobre el **balance horario agregado** de la comunidad (y no vivienda a vivienda mediante coeficientes de reparto). Ese balance neto hora a hora es, exactamente, la factura eléctrica que optimiza el controlador. La justificación de esta elección, sus condiciones

de aplicabilidad y su encaje jurídico se detallan en la Sección 3.1.

La variabilidad del precio PVPC, que en el periodo analizado (2021–2023) alcanzó un máximo horario de 0,95 €/kWh (marzo de 2022, crisis energética) frente a valores cercanos a cero en horas valle, ofrece un margen de arbitraje que solo un motor de decisión con capacidad predictiva puede explotar. El presente trabajo aborda este problema desde una perspectiva dual: investigadora, al desarrollar y comparar algoritmos de aprendizaje por refuerzo aplicados a este dominio; e ingenieril, al integrar el motor resultante en una plataforma software accesible para comunidades rurales de pequeña escala.

1.2. Posicionamiento en el Control Jerárquico Estándar

El sistema implementa la **capa de planificación horaria (Nivel 3)** del control jerárquico estándar para sistemas de almacenamiento de energía. Esta capa opera con horizonte de 24 horas y resolución horaria, determinando la estrategia económicamente óptima de carga y descarga en función del pronóstico de precios, generación y consumo. La integración con la capa de control supervisorio (Nivel 2, SCADA) y la capa de control en tiempo real (Nivel 1, BMS) queda como trabajo futuro para el despliegue en instalaciones reales.

Desde la perspectiva del mercado eléctrico, la arquitectura replica la capa de despacho horario utilizada por los agregadores energéticos en el mercado diario español (OMIE). La participación en mercados intradiarios de OMIE y en servicios de balance de REE (que operan en horizontes sub-horarios) queda como extensión natural hacia una arquitectura de gestión energética multi-capas completa.

1.3. Estructura del Documento

El documento sigue la estructura del Tipo II de la Guía de Elaboración del TFG de la ESEI. El Capítulo 2 define los objetivos. El Capítulo 3 revisa los antecedentes y el contexto del problema. El Capítulo 4 resume la solución propuesta y la metodología. El Capítulo 5, marco práctico y herramientas empleadas, constituye el núcleo técnico del trabajo: desarrolla los fundamentos teóricos y el *stack* tecnológico (Sección 5.1), la ingeniería de datos y el gemelo digital físico-económico de la comunidad (Sección 5.2), el motor de decisión (Sección 5.3), su exportación a producción (Sección 5.4) y la plataforma SaaS (Sección 5.5). Los Capítulos 6 a 9 completan la documentación con planificación, aportaciones, conclusiones y trabajo futuro.

Capítulo 2

Objetivos

Este trabajo se articula en torno a una **pregunta de investigación**:

¿Puede un controlador basado en aprendizaje por refuerzo superar a los controladores convencionales (desde las reglas heurísticas hasta el control predictivo basado en modelos) en la optimización económica de la batería de una comunidad energética de autoconsumo fotovoltaico colectivo bajo el RD 244/2019?

De ella se deriva la **hipótesis de trabajo** que la experimentación buscará contrastar: un agente de RL que opera de forma autónoma iguala, pero no supera de forma consistente, a un MPC bien calibrado; en cambio, una arquitectura híbrida que aprende correcciones residuales sobre ese MPC sí logra superarlo, conservando como garantía de suelo el rendimiento del propio MPC. Aceptar o rechazar esta hipótesis (y cuantificar el margen de mejora) es el hilo conductor de la fase experimental (Sección 5.3).

El objetivo central del presente trabajo es el diseño, implementación y validación experimental de un motor de decisión basado en aprendizaje por refuerzo para la optimización económica de la batería comunitaria en una comunidad energética de autoconsumo fotovoltaico colectivo, operando bajo el marco regulatorio del RD 244/2019, e integrado en una plataforma software accesible orientada a comunidades rurales de pequeña escala.

2.1. Objetivos Generales

- OG1.** Investigar y comparar algoritmos de aprendizaje por refuerzo aplicados a la gestión de sistemas de almacenamiento de energía, con especial atención a su capacidad para superar un *baseline* de control predictivo bien calibrado.
- OG2.** Diseñar e implementar un gemelo digital físico-económico de una comunidad energética, calibrado con datos reales de fuentes oficiales (ESIOS, PVGIS), que sirva como entorno de entrenamiento y evaluación reproducible.
- OG3.** Seleccionar, justificar e implementar el algoritmo de control más adecuado tras experimentación documentada con candidatos alternativos.

- OG4.** Integrar el motor de decisión en una plataforma software accesible que democratice la gestión energética inteligente para comunidades rurales.

2.2. Objetivos Específicos

- OE1.** Construir el pipeline ETL reproducible que integre datos de consumo normativo (ESIOS 2.0TD), generación FV (PVGIS) y precios de mercado (PVPC e indicador de compensación simplificada) en un dataset unificado de 22.646 horas.
- OE2.** Implementar el simulador físico-económico con modelo de degradación no lineal de batería LFP y modelo económico asimétrico coherente con el RD 244/2019.
- OE3.** Implementar el controlador MPC con horizonte deslizante de 24 horas como cota teórica (pronóstico oráculo) y como *baseline* competitivo (pronóstico realista con ruido AR(1)).
- OE4.** Experimentar con DQN y PPO como algoritmos candidatos, documentando su rendimiento y sus limitaciones estructurales.
- OE5.** Diseñar e implementar el controlador Residual SAC con protocolo de inicialización con demostraciones del MPC, y validar experimentalmente que supera al *baseline* competitivo mediante una suite estadística multisentida que lo contrasta con las familias alternativas (DQN, PPO discreto y continuo, SAC puro, y TD3 y DDPG residuales).
- OE6.** Desarrollar una suite de tests automatizados que garantice los invariantes físicos y económicos del simulador y la reproducibilidad de los experimentos.

2.3. Alcance

El trabajo cubre el diseño, implementación y validación experimental del motor de decisión sobre datos históricos simulados. La integración con APIs de datos en tiempo real está diseñada pero no activada en el prototipo actual. El despliegue en hardware físico y la integración con datos de viviendas reales constituyen extensiones naturales en el trabajo futuro.

Capítulo 3

Antecedentes y Contexto

3.1. Marco Regulatorio del Autoconsumo Colectivo en España

El autoconsumo colectivo en España, en transposición de la normativa europea sobre energías renovables y mercado interior de la electricidad (Parlamento Europeo y Consejo de la Unión Europea, 2018, 2019), se regula mediante el **Real Decreto 244/2019** (Gobierno de España, 2019), que establece las condiciones administrativas, técnicas y económicas del autoconsumo e introduce el mecanismo de **compensación simplificada de excedentes**, posteriormente reforzado por el Real Decreto-ley 7/2025 (Gobierno de España, 2025).

El mecanismo realiza una liquidación económica hora a hora del intercambio de energía entre la comunidad y la red. En cada hora se compara la generación fotovoltaica total con el consumo total de la comunidad, y pueden darse dos situaciones. Si la generación es **menor** que el consumo, la comunidad autoconsume toda la energía solar producida (que no se factura, pues sustituye energía que habría que comprar) y adquiere de la red el déficit restante al precio de compra PVPC. Si la generación es **mayor** que el consumo, la comunidad autoconsume la parte que cubre su demanda y vierte el excedente sobrante a la red, recibiendo por él una compensación al precio mayorista.

Al final del periodo de facturación, la compensación acumulada por los excedentes vertidos se descuenta del importe de la energía comprada. Esta compensación está limitada: puede reducir la factura hasta cero, pero nunca generar un saldo a favor del consumidor. La energía entra y sale físicamente de la red con normalidad en ambas direcciones; el mecanismo de compensación es únicamente la liquidación económica de ese intercambio.

Modelo de comunidad adoptado. El caso de estudio es una **ecocomunidad rural** de quince viviendas en **parcelas colindantes de titularidad privada**, organizada como **cooperativa** que actúa como titular único del suministro eléctrico. La interconexión entre la generación distribuida de cada parcela y la batería comunitaria se realiza mediante una **red interior privada** (cableado propio bajo servidumbre de paso entre fincas colindantes), de modo que la energía fluye internamente *sin atravesar la red de*

distribución pública, y la comunidad se presenta ante el sistema eléctrico a través de un **único contador frontera**.

Bajo esta topología, el **balance horario agregado** entre el consumo y la generación totales de la comunidad es *exactamente* lo que registra el contador frontera y constituye la única factura eléctrica oficial. Esto justifica que el simulador modele la comunidad como **nodo agregado** no como una simplificación, sino como una **correspondencia físicamente exacta**: el balance agregado sobre el que decide el controlador es la factura que se optimiza. El reparto de ese coste único entre las viviendas es una operación **interna** de la cooperativa (repercusión de gasto común medido por subcontadores privados, sin reventa de energía conforme a la Ley 24/2013 del Sector Eléctrico (Jefatura del Estado, 2013)), no una facturación regulada vivienda a vivienda; el coeficiente de reparto es, por tanto, una **clave interna** que distribuye coste y ahorro entre los socios, no el coeficiente reglamentario del autoconsumo colectivo.

Por qué no el autoconsumo colectivo estándar. La alternativa reglamentaria directa, el **autoconsumo colectivo a través de red** del RD 244/2019, *no* produce un nodo agregado real: no existe conexión física entre viviendas, sino que la distribuidora reparte la generación (y la descarga de la batería) entre los distintos CUPS mediante **coeficientes fijos** ($ENG_{h,i} = \beta_{h,i} \cdot ENG_h$) y *netea cada vivienda por separado*. Esto introduce dos ineficiencias que el modelo agregado evita: (i) el excedente de un vecino se vierte a la red a precio mayorista mientras otro compra su déficit a PVPC en la misma hora, sin compensación cruzada; y (ii) la batería compartida se descargaría repartida por coeficientes *ciegos*, ajenos a quién demanda realmente la energía, desperdiciando su valor. La red interior privada de la cooperativa elimina ambas, permitiendo que el controlador asigne cada flujo a quien lo necesita.

Condiciones de aplicabilidad y encuadre regulatorio. Esta correspondencia exacta exige condiciones concretas, que se asumen explícitamente y se discuten como limitación (Sección 8.2): parcelas colindantes sin vía de dominio público interpuesta (por la que no es legal tender cableado privado), titularidad única del suministro por la cooperativa y renuncia de los vecinos al contrato individual con comercializadora. Conviene precisar que este modelo *no* es una figura regulada llave en mano: las Redes de Distribución Cerradas, cuyo procedimiento de autorización desarrolla el Real Decreto 314/2023 (Gobierno de España, 2023), están reservadas a zonas industriales, comerciales o de servicios compartidos (solo admiten consumo residencial como excepción marginal y ligada a la industria, manteniendo además cada consumidor su comercializadora), por lo que el escenario aquí adoptado se sostiene jurídicamente como *red interior de un único consumidor* (la cooperativa), no como red de distribución cerrada. Su viabilidad económica se apoya en los programas de incentivos a comunidades energéticas con almacenamiento (Programa CE IMPLEMENTA del IDAE, Orden TED/764/2024

(Ministerio para la Transición Ecológica y el Reto Demográfico, 2024)), que exigen sistema de almacenamiento de forma obligatoria.

La característica que condiciona el diseño del motor de decisión es la asimetría de precios: el precio de venta de excedentes (mayorista, indicador 1739 de ESIOS (Red Eléctrica de España, 2023)) es sistemáticamente inferior al de compra (PVPC, indicador 1001), que incluye peajes y cargos del sistema. Por ello, maximizar el autoconsumo interno es siempre más rentable que maximizar la venta de excedentes.

3.2. El Problema de la Gestión de Baterías en Comunidades Energéticas

La inclusión de un sistema de almacenamiento de energía en baterías (BESS) en una comunidad de autoconsumo introduce un problema de decisión secuencial bajo incertidumbre: en cada hora del día, el gestor debe decidir cuánta energía cargar o descargar de la batería considerando el precio actual de la energía, la generación solar disponible, el consumo esperado de las viviendas y el estado de carga actual de la batería.

Este problema tiene tres características que lo hacen especialmente adecuado para técnicas de optimización avanzada. En primer lugar, las decisiones son secuencialmente dependientes: cargar la batería ahora reduce el margen de carga disponible en las próximas horas. En segundo lugar, existe incertidumbre sobre el futuro: ni el consumo, ni la generación solar, ni siquiera el precio de la energía son perfectamente predecibles con horas de antelación. En tercer lugar, el horizonte de decisión relevante es de 24 horas, suficiente para que el precio varíe entre máximos y mínimos que crean oportunidades de arbitraje temporal. El precio, además, solo se conoce con exactitud de forma parcial: REE publica el PVPC del día siguiente a partir de las 20:30 h, de modo que dentro del horizonte de 24 horas las primeras horas son ciertas y las posteriores deben estimarse, diferencia que motiva el modelo de pronóstico en tres capas empleado en este trabajo (Sección 5.3).

La estrategia realmente óptima no es evidente a priori: depende de la interacción entre generación, consumo, precio y degradación, todos ellos sujetos a incertidumbre dentro del horizonte de 24 horas, y es precisamente lo que el motor de decisión debe aprender o calcular.

3.3. El Espacio de Acciones: Discreto frente a Continuo

La aplicación de aprendizaje por refuerzo a la gestión de sistemas de almacenamiento de energía ha experimentado un crecimiento notable en la última década, desde los trabajos fundacionales de Mnih et al. (2015) sobre DQN. Su aplicación a los sistemas energéticos y a la respuesta de la demanda está ampliamente documentada en revisiones recientes (Perera & Kamalaruban, 2021; Vázquez-Canteli & Nagy, 2019). La decisión de diseño más determinante en este dominio es la topología del espacio de acciones, que condiciona estructuralmente tanto el algoritmo aplicable como la calidad de la política aprendida.

Un **espacio discreto** representa las decisiones de la batería como un conjunto finito de acciones que combinan estrategia (cargar, descargar, no actuar) con nivel de potencia. Es la representación que emplean algoritmos basados en valor como DQN, y encaja bien con la gestión eléctrica porque la estrategia rentable suele consistir en concentrar la carga y la descarga en los picos y valles de precio, que son decisiones de naturaleza discreta. Su ventaja es la simplicidad y la estabilidad de entrenamiento. Su limitación es el error de cuantización: el conjunto finito de niveles no puede representar los ajustes de potencia intermedios que la política óptima requiere en algunas horas. En este trabajo se experimentó con DQN y también con PPO sobre el mismo espacio discreto.

Un **espacio continuo** asigna directamente la potencia neta dentro del rango físico del inversor. Elimina por construcción el error de cuantización a costa de requerir algoritmos de control continuo más sofisticados como SAC.

3.4. Estado del Arte: RL puro frente a MPC y la Arquitectura Híbrida

El aprendizaje por refuerzo aplicado a la gestión de sistemas energéticos ha pasado en la última década de propuestas aisladas a un cuerpo de literatura consolidado. Revisiones sistemáticas del área (Perera & Kamalaruban, 2021; Vázquez-Canteli & Nagy, 2019) recogen su aplicación a la respuesta de la demanda, la climatización de edificios, la carga de vehículos eléctricos y el arbitraje de almacenamiento, e identifican como factores determinantes del éxito la formulación de la función de recompensa, la eficiencia de muestreo y la capacidad de generalización entre instalaciones. La gestión de baterías es uno de los casos más estudiados, por su naturaleza de decisión secuencial bajo incertidumbre y por el atractivo de aprender políticas adaptadas a patrones de precio y consumo no estacionarios sin necesidad de un modelo explícito del sistema.

Ahora bien, el aprendizaje por refuerzo no compite en el vacío. El control predictivo basado en modelos (Rawlings et al., 2017) constituye el estado de la práctica en el despacho económico de almacenamiento: incorpora de forma explícita las restricciones físicas del sistema y, con un pronóstico razonable, alcanza soluciones próximas al óptimo. Por ello, la comparación metodológicamente exigente no enfrenta al RL contra una heurística simple, sino contra un MPC bien calibrado. La literatura sobre esta comparación no es concluyente: en dominios de gestión energética el RL puro tiende a igualar el rendimiento de un MPC bien sintonizado, pero superarlo de forma consistente resulta difícil, precisamente porque el MPC ya explota la estructura del problema que el agente debería aprender desde cero. Es esta tensión la que motiva el interés por las arquitecturas híbridas, que es el enfoque adoptado en este trabajo.

La comparativa honesta del RL con controladores MPC bien calibrados muestra un panorama matizado: la literatura encuentra que el MPC mantiene un rendimiento ligeramente superior y se transfiere con más suavidad entre escenarios (Zhan et al., 2023). En este dominio, un MPC determinista correctamente sintonizado captura ya la mayor parte del valor económico disponible mediante arbitraje diario y emparejamiento de picos de precio, y el margen restante queda acotado por el coste de la incertidumbre del pronóstico. En este trabajo ese margen se cuantifica de forma explícita para el caso de estudio (la brecha entre el MPC con previsión perfecta y con previsión realista resulta ser del 15,7%; Sección 5.3.1), y la expectativa realista para un esquema híbrido es recuperar solo una fracción de él. Este margen acotado, lejos de invalidar el enfoque, define con precisión el espacio en el que el motor de IA debe demostrar su valor.

La arquitectura híbrida MPC+RL responde a esta realidad combinando la estabilidad y las garantías del MPC con la capacidad adaptativa del RL. Johannink et al. (2019) propusieron el *Residual Reinforcement Learning* en el contexto del control robótico: el agente aprende únicamente las correcciones residuales sobre un controlador base competente, aprovechando el conocimiento encapsulado en ese controlador como punto de partida. Aplicada al presente trabajo, esta arquitectura aporta una propiedad de **seguridad por construcción**: como la corrección del agente está acotada, si el agente propone una corrección nula el sistema replica exactamente el comportamiento del MPC subyacente, eliminando el riesgo de exploración destructiva que desaconseja el uso de RL puro en infraestructuras críticas.

La selección del algoritmo de RL continuo para calcular la corrección residual se desarrolla en detalle en la Sección 5.3, donde se justifica la elección de SAC frente a las alternativas continuas (PPO, TD3, DDPG) sobre la base de su eficiencia de muestreo y su robustez ante la alta varianza de la recompensa económica.

3.5. Soluciones Actuales para la Gestión del Almacenamiento

La gestión de baterías con inteligencia artificial es ya una realidad, tanto en el ámbito comercial como en proyectos de investigación: existen sistemas EMS propietarios e incluso plataformas que abordan el almacenamiento compartido. Ahora bien, la mayoría de estas soluciones presentan tres limitaciones para el escenario de este trabajo. En primer lugar, son de carácter cerrado y propietario, lo que dificulta auditarlas y adaptarlas a contextos para los que no fueron diseñadas. En segundo lugar, están orientadas mayoritariamente al almacenamiento individual o industrial (donde la batería responde a un único punto de consumo) y no a la batería compartida de una comunidad, en la que un único activo debe operarse para el balance conjunto de todos los participantes (balance que, en el modelo de cooperativa con un único punto de suministro aquí adoptado, constituye además la factura eléctrica oficial; Sección 3.1). En tercer lugar, rara vez documentan de forma reproducible y transparente la mejora económica que su controlador aporta frente a una referencia bien calibrada, de modo que resulta difícil saber cuánto valor añade realmente la inteligencia frente a un control clásico. En comunidades de pequeña escala con recursos limitados, estas tres carencias se agravan.

La batería de una comunidad de autoconsumo colectivo plantea un problema distinto, porque un único activo debe gestionarse de forma centralizada para el balance agregado de todos los participantes bajo el marco del RD 244/2019. La energía generada se reparte entre las viviendas y solo el excedente conjunto se vierte a la red, de modo que la decisión de carga y descarga afecta a toda la comunidad y no a un consumidor aislado. El presente trabajo se centra en este escenario, aplicando aprendizaje por refuerzo a la optimización económica del almacenamiento comunitario y midiendo de forma transparente la mejora que aporta frente a un control de referencia bien calibrado.

Capítulo 4

Resumen de la Solución Propuesta y Metodología

4.1. Descripción General

La solución propuesta es la plataforma LeaLink, cuya arquitectura se organiza en ocho capas funcionales repartidas en dos bloques: seis capas de investigación y *benchmarking* (Figura 4.1) y dos capas de producción (Figura 5.5). La comunidad modelada comprende quince viviendas con perfil de consumo residencial 2.0TD, una instalación fotovoltaica compartida de 42 kWp y una batería comunitaria de tecnología LFP con capacidad de 80 kWh e inversor bidireccional de 50 kW.

En el bloque de investigación, la **capa de datos y configuración** construye y mantiene el dataset de simulación a partir de fuentes oficiales y centraliza los parámetros del sistema; la **capa de simulación físico-económica** implementa el gemelo digital de la comunidad; la **capa de entornos de aprendizaje por refuerzo** envuelve ese simulador en interfaces Gymnasium (Farama Foundation, 2023); la **capa de entrenamiento multisemilla** optimiza los agentes sobre la partición de entrenamiento; la **capa de controladores y agentes** reúne la librería común de políticas (heurístico, MPC y controladores residuales) compartida entre investigación y producción; y la **capa de evaluación comparativa** contrasta todos los controladores sobre el conjunto *held-out* con significancia estadística.

En el bloque de producción, la **capa de producción *edge*** gestiona el ciclo de vida del modelo entrenado y su exportación a formato ONNX para la inferencia ligera en hardware de borde, y la **capa SaaS** expone los resultados a los usuarios finales mediante una interfaz web diferenciada por rol, con persistencia de los perfiles e histórico de la comunidad.




Figura 4.1: Arquitectura de la plataforma, parte 1: capas de investigación y *benchmarking* (datos, simulación, entornos, entrenamiento multisemilla, controladores y evaluación comparativa). La parte de producción (*edge* y SaaS) se muestra en la Figura 5.5.

4.2. Metodología

El desarrollo sigue un ciclo iterativo de tipo Scrum con sprints semanales, adaptado a las características de un proyecto de investigación aplicada. Las iteraciones alternan entre el desarrollo de componentes software y la experimentación con el motor de decisión, con validación continua mediante la suite de tests automatizados.

Se aplica la metodología MLOps al ciclo de vida del motor de decisión: configuración externalizada en YAML (sin *magic numbers* en el código, siguiendo principios de código limpio (Martin, 2008)), semillas fijas para reproducibilidad total de experimentos, versionado de modelos entrenados y de las estadísticas de normalización (*vec_normalize.pkl*), y trazabilidad de curvas de entrenamiento mediante TensorBoard.

El proceso de selección del algoritmo final siguió un protocolo de experimentación estruc-

turado en dos fases: una fase de **exploración** (establecimiento de cotas de rendimiento mediante MPC, experimentación con candidatos (DQN, PPO) con análisis de limitaciones, y diseño del controlador final (Residual SAC) que resuelve esas limitaciones) y una fase de **validación** estadística, en la que el controlador propuesto se confirma con tres semillas de entrenamiento y contraste de significancia frente a las familias alternativas completas: DQN, PPO discreto, PPO continuo, SAC puro y las variantes residuales con TD3 y DDPG (Sección 5.3.11). Este protocolo garantiza que la selección del algoritmo está basada en evidencia experimental y no en preferencias a priori.

Capítulo 5

Marco Práctico y Herramientas Empleadas

Este capítulo constituye el núcleo técnico del trabajo. Se estructura en cinco bloques: los fundamentos teóricos y el *stack* tecnológico (Sección 5.1), la ingeniería de datos y el gemelo digital físico-económico de la comunidad (Sección 5.2), el motor de decisión energético (desde las cotas de rendimiento hasta los resultados experimentales) (Sección 5.3), la exportación del modelo a producción (Sección 5.4) y la plataforma SaaS que lo integra (Sección 5.5).

5.1. Fundamentos Teóricos y Herramientas

5.1.1. Proceso de Decisión de Markov

El problema de gestión de la batería comunitaria se formula como un Proceso de Decisión de Markov (MDP) definido por la tupla $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$ (Sutton & Barto, 2018). El espacio de estados $\mathcal{S}$ recoge las variables observables en cada paso temporal h : el estado de carga $\text{SoC}_h \in [0, 10, 0, 90]$, el precio de compra p_c^h , el precio de venta p_v^h , el excedente solar $e_h = \max(0, g_h - c_h)$ y el déficit de consumo $d_h = \max(0, c_h - g_h)$.

El espacio de acciones $\mathcal{A}$ define los flujos energéticos que el controlador puede modular en cada hora: energía solar cargada en batería c_s , energía de red cargada en batería c_m , energía descargada para consumo d_c y energía descargada vendida a red d_r . Estos cuatro flujos están acoplados por las restricciones físicas del sistema.

La función de recompensa $R(s, a)$ es el beneficio marginal respecto a la política de referencia IDLE: el escenario contrafactual con la batería desconectada (los cuatro flujos a cero), en el que la comunidad opera solo con sus paneles y la red, autoconsumiendo lo que puede, comprando el déficit y vertiendo el excedente. Su beneficio marginal es cero por definición, de modo que toda cifra en €/semana de este trabajo mide el dinero que la gestión de la batería añade sobre ese escenario sin almacenamiento:

$$r_h = E_{\text{vend},h} p_v^h - E_{\text{comp},h} p_c^h - c_{\text{deg},h} \quad (5.1)$$

El factor de descuento $\gamma = 0,99$, valor canónico en la práctica del RL profundo, establece un horizonte efectivo de $1/(1 - \gamma) = 100$ pasos, equivalente a unos cuatro días dentro de los episodios semanales de 168 horas. La elección es deliberadamente mayor que las 24 horas del MPC: garantiza que el agente pondere las consecuencias de sus decisiones sobre el estado de carga más allá del horizonte de planificación, valorando el efecto de cargar o descargar la batería sobre las jornadas siguientes (que el LP del MPC, por construcción, no ve).

5.1.2. Familias de Algoritmos Aplicables

Los algoritmos de RL aplicables a este problema se organizan en tres familias según su mecanismo de aprendizaje, no según el tipo de espacio de acción. Los métodos *value-based* (DQN y variantes) aprenden la función de valor $Q(s, a; \theta)$ y requieren necesariamente un espacio de acción discreto. Los métodos *policy gradient on-policy* (PPO (Schulman et al., 2017), A3C) aprenden directamente la política $\pi_\theta(a|s)$ actualizando con las trayectorias de la política actual; son agnósticos al tipo de espacio, pudiendo operar tanto en discreto como en continuo, y en este trabajo se entrenaron sobre el mismo espacio discreto que DQN. Los métodos *actor-critic off-policy* (SAC, TD3) combinan actor y crítico con *replay buffer*, son más eficientes en muestras y, en su formulación estándar, están diseñados para espacios de acción continuos.

5.1.3. Soft Actor-Critic

El algoritmo Soft Actor-Critic (SAC) (Haarnoja et al., 2018) incorpora un término de entropía máxima en el objetivo de aprendizaje:

$$\pi^* = \arg \max_{\pi} \sum_t \mathbb{E}_{(s_t, a_t) \sim \pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot|s_t))] \quad (5.2)$$

donde $\mathcal{H}(\pi(\cdot|s_t))$ es la entropía de la política en el estado s_t y α es el coeficiente de temperatura. Este término de entropía regula automáticamente la exploración: cuando la política es determinista (baja entropía), el agente explora más; cuando es estocástica (alta entropía), el agente explota el conocimiento actual. Esta propiedad proporciona una robustez notable a hiperparámetros, siendo SAC la elección preferida en aplicaciones de control continuo con restricciones físicas.

Además, SAC emplea en su formulación estándar dos redes crítico (*clipped double-Q*) y utiliza el mínimo de sus estimaciones para mitigar la sobrestimación del valor Q , técnica heredada de TD3 (Fujimoto et al., 2018). Se adopta esta configuración canónica ($n_{\text{critics}} = 2$), sin tratarla como un hiperparámetro a ajustar.

5.1.4. Control Predictivo Basado en Modelos (MPC)

El Control Predictivo Basado en Modelos (MPC) es un paradigma de control óptimo que resuelve en cada paso temporal un problema de optimización de horizonte finito, aplicando solo la primera acción de la secuencia óptima y repitiendo el proceso en el siguiente paso (Rawlings et al., 2017). En el contexto de la gestión energética, el MPC con horizonte de 24 horas determina el perfil óptimo de carga y descarga para las próximas 24 horas, ejecuta la decisión de la hora actual, y recalcula con la información actualizada.

La elección de 24 horas como horizonte no es arbitraria: es la escala natural del problema. Tanto el precio PVPC como la generación fotovoltaica y el consumo residencial tienen una periodicidad dominante diaria, de modo que una ventana de 24 horas contiene un ciclo completo de arbitraje (el valle y el pico de precio, y el día y la noche solares). Coincide además con la ventana de información del mercado español (REE publica el PVPC del día siguiente a las 20:30 h, y el despacho diario de OMIE opera precisamente a esa escala), por lo que es el horizonte estándar de la planificación horaria (Nivel 3) en la gestión de almacenamiento. Alargarlo aportaría poco: más allá del día siguiente no hay nueva estructura de precios que explotar y el error de pronóstico crece, mientras que el efecto de las decisiones sobre jornadas posteriores lo captura el agente a través del factor de descuento ($\gamma = 0,99$, Sección 5.1).

La principal ventaja del MPC es que puede incorporar explícitamente las restricciones físicas del sistema (límites de SoC, potencia máxima) y optimizar una función objetivo económica bien definida. Su principal limitación es que su rendimiento depende de la calidad del modelo del sistema y del pronóstico de las variables futuras.

5.1.5. Arquitectura Residual MPC+RL

La arquitectura Residual RL (Johannink et al., 2019) combina un controlador base competente con un agente de RL que aprende únicamente las correcciones residuales. La acción final es:

$$a_{\text{final}} = \text{clip}(a_{\text{base}} + \Delta a \cdot \delta_{\text{máx}}, \text{límites físicos}) \quad (5.3)$$

Con $\Delta a = \mathbf{0}$, el sistema es exactamente el controlador base. El agente SAC solo necesita aprender en el espacio residual: las correcciones sobre lo que el MPC ya hace bien. Esto resuelve la *cold-start pathology* pre-llenando el *replay buffer* con demostraciones del controlador base.

5.1.6. Herramientas y Stack Tecnológico

Cuadro 5.1: Stack tecnológico de la plataforma LeaLink.

Componente	Tecnología	Función
Lenguaje	Python	Ecosistema de aprendizaje automático
Framework RL	Stable-Baselines3	SAC, PPO, DQN auditados
Deep Learning	PyTorch	Backend de SB3
Entorno RL	Gymnasium (Farama)	Interfaz estándar de entornos
Optimización LP	SciPy / HiGHS	Solver del LP del MPC
Datos	Pandas / NumPy	Pipeline ETL y simulación
Fuente precios	ESIOS API (REE)	Indicadores 1001 y 1739
Fuente consumo	ESIOS API (REE)	Indicador 1006 (perfil 2.0TD)
Fuente generación	PVGIS API (JRC-EU)	Producción FV histórica
Runtime edge	ONNX Runtime	Inferencia sin SB3 ni Gymnasium
Base de datos	PostgreSQL	Perfiles, histórico, coeficientes
Frontend web	Flask + SQLAlchemy	Dashboards Superadmin y Usuario
Despliegue	Docker Compose	Reproducibilidad del entorno
Configuración	YAML (<code>yaml.safe_load</code>)	Hiperparámetros externalizados
Tracking ML	TensorBoard	Curvas de entrenamiento
Testing	pytest	76 tests automatizados
Control versiones	Git	Reproducibilidad de experimentos

La selección de SB3 (Raffin et al., 2021) frente a RLlib se justifica por sus implementaciones auditadas con verificación estática de tipos, soporte nativo para `VecNormalize` y acceso programático al *replay buffer*, que es lo que permite implementar el protocolo de inicialización con demostraciones del MPC (DAWN) sobre los algoritmos *off-policy*. HiGHS garantiza optimalidad global en el LP del MPC y detección explícita de infactibilidad, verificada sobre 1.000 escenarios aleatorios. La arquitectura de exportación a ONNX permite desplegar el modelo entrenado en hardware de borde sin el stack completo de entrenamiento.

5.2. Ingeniería de Datos y Entorno de Simulación

5.2.1. Fuentes de Datos Oficiales

El dataset de simulación integra cuatro ficheros procedentes de tres fuentes oficiales. El **perfil de consumo 2.0TD** (`consumo_esios_2021_2023.csv`) se obtiene del indicador 1006 de ESIOS (Red Eléctrica de España, 2023), que publica coeficientes horarios normalizados del consumo residencial elaborados a partir de medidas reales de contadores inteligentes de la red española. Se escala a $15 \times 3500 \text{ kWh/año} = 52.500 \text{ kWh/año}$.

La **generación fotovoltaica** (`solar_pvgis_2021_2023.csv`) procede de PVGIS (JRC-EU) (European Commission, Joint Research Centre, 2022), que proporciona la producción unitaria horaria para 1 kWp en las coordenadas de la comunidad. A partir de este perfil unitario, el pipeline genera quince instalaciones individuales, una por vivienda, cuya capacidad toma los valores reales de la comunidad Vilarín registrados en la plataforma SaaS (véase Anexo A), garantizando la coherencia entre los datos de entrenamiento y los atributos del gemelo digital. Las capacidades individuales suman exactamente 42 kWp. Se aplica además un rendimiento propio por vivienda y un ruido horario independiente ($\sigma = 0,03$) que representa el sombreado puntual y la variabilidad meteorológica local, de forma análoga al ruido de consumo de la ecuación (5.4). La generación comunitaria es la suma de las quince instalaciones, 42 kWp agregados.

Los **precios del mercado** se obtienen de dos indicadores de ESIOS: el indicador 1001 (PVPC en €/MWh, fichero `precios_esios_2021_2023.csv`) como precio de compra, y el indicador 1739 (compensación simplificada en €/MWh, fichero `compensacion_autoconsumo_esios_2021_2023.csv`) como precio de venta de excedentes.

5.2.2. Pipeline ETL


El módulo `experimentos/build_dataset.py` convierte los cuatro ficheros crudos de `data/raw/` en el dataset final de simulación. Primero escala el consumo: el perfil normalizado 2.0TD (ESIOS 1006) se multiplica por 3500 kWh/año y por las quince viviendas, y sobre la demanda agregada se añade un ruido AR(1) que aporta variabilidad horaria realista:

$$f_h = \text{clip}(1 + \sigma \varepsilon_h, 0,7, 1,3), \quad \varepsilon_h \sim \text{AR}(1), \quad \rho = 0,50, \quad \sigma = 0,05 \quad (5.4)$$

Los parámetros del ruido se fijan por argumentos de plausibilidad física, no por calibración contra medidas (que no existen para la comunidad modelada, al ser el dataset un agregado sintético; Sección 8.2): la magnitud $\sigma = 0,05$ refleja que la agregación

de quince viviendas suaviza la variabilidad del perfil individual pero no la elimina; la persistencia $\rho = 0,50$ evita el ruido blanco hora a hora, físicamente irreal, porque los desvíos de consumo de una comunidad (una ola de frío, una ausencia) persisten durante varias horas; y el recorte a $[0,7, 1,3]$ acota los desvíos extremos al rango verosímil de una demanda residencial agregada. Después construye la generación solar repartiendo el perfil unitario de PVGIS (1 kWp) en quince instalaciones individuales con las capacidades fijas de la comunidad Vilarín (que suman 42 kWp), rendimiento propio por vivienda y ruido propio ($\sigma = 0,03$, menor que el del consumo porque la producción FV de instalaciones colindantes está fuertemente correlacionada y sus desvíos locales, como el sombreado puntual, son de menor amplitud relativa). Por último convierte los precios de compra (PVPC, ESIOs 1001) y de venta de excedentes (ESIOs 1739) de €/MWh a €/kWh, sanea el precio de excedente imponiendo $p_{\text{exc}} = \max(0, p_{\text{exc}})$, coherente con el RD 244/2019 (que impide remuneración negativa), y alinea todas las series a la zona horaria Europe/Madrid antes de fusionarlas.

El resultado es `dataset_final.csv`, con 22.646 horas (junio 2021 – diciembre 2023) y cinco columnas: `fecha`, `consumo_total`, `generacion_total`, `precio_kwh` y `precio_excedente`. Un fichero `metadata.json` lo acompaña con el hash SHA-256 de cada fuente y del dataset, la semilla y los parámetros del ruido, garantizando la trazabilidad. La Figura 5.1 resume el recorrido completo del dato, desde las fuentes oficiales hasta la entrada normalizada de la red del agente.



Integración de fuentes oficiales (ESIOs / PVGIS), escalado de comunidad y normalización continua VecNormalize para RL

Figura 5.1: Pipeline de datos: fuentes crudas oficiales (ESIOs 1006/1001/1739 y PVGIS), proceso ETL y escalado comunitario, construcción de la observación en el entorno de simulación y normalización VecNormalize previa a la red del agente.

5.2.3. Justificación del Dimensionado de la Instalación

La instalación fotovoltaica se dimensionó en 42 kWp para equilibrar generación y consumo a nivel anual. Con un consumo medio de 3500 kWh/año por vivienda (coherente con la media eléctrica del hogar español según los estudios SPAHOUSEC del IDAE (IDAE, Instituto para la Diversificación y Ahorro de la Energía, 2011)) y quince viviendas, el consumo agregado asciende a 52.500 kWh/año. Aplicando las 1250 horas equivalentes de irradiancia anual en Galicia, la potencia necesaria es:

$$P_{\text{solar}} = \frac{52.500 \text{ kWh/año}}{1250 \text{ h/año}} = 42 \text{ kWp} \quad (5.5)$$

Este dimensionado maximiza la tasa de autoconsumo bajo el régimen de compensación simplificada del RD 244/2019: la energía generada se aprovecha internamente o se compensa en factura sin generar excedentes estructurales irrecuperables. Un dimensionado mayor produciría un superávit anual de generación que, al superar el coste de los consumos mensuales, no podría compensarse económicamente.

La batería comunitaria se dimensionó en 80 kWh nominales (64 kWh útiles con $\text{SoC} \in [10\%, 90\%]$). El déficit energético nocturno (20:00–08:00 h, ventana de doce horas con potencia media de 5,72 kW) asciende a 68,6 kWh/noche. Los 64 kWh útiles cubren el 93 % de ese déficit con una reducción de coste de capital del 20 % respecto a una unidad de 100 kWh, cuya capacidad útil (80 kWh) excedería el ciclo diario real en torno a un 14 %. Un sistema BESS comercial LFP de 80 kWh en formato armario es un producto estándar disponible en el mercado.

5.2.4. Partición Train/Evaluación por Muestreo Estratificado

El dataset cubre dos regímenes de mercado radicalmente diferentes: la crisis energética de 2022 (precios PVPC horarios de hasta 0,95 €/kWh) y el periodo post-crisis de 2023. Un split temporal convencional genera distribuciones de entrenamiento y evaluación heterogéneas (diferencia del 24 % en el rendimiento del MPC entre ambos periodos).

La solución adoptada es el muestreo aleatorio por semanas completas. Las 134 semanas de 168 horas del dataset se distribuyen aleatoriamente sin reemplazo (semilla fija 42) en 50 semanas de evaluación y 84 de entrenamiento, de modo que ambos pools quedan repartidos a lo largo de todo el rango temporal y las dos distribuciones resultan homogéneas. El test `test_split_no_solapado` verifica la ausencia de *data leakage*.

5.2.5. Simulador Físico-Económico: Gemelo Digital

La Figura 5.2 muestra la topología física que el simulador reproduce: los cuatro flujos de la batería que decide el agente (cs, cm, dc, dr) y los flujos automáticos del balance (autoconsumo directo, compra de déficit y vertido de excedente), que no pasan por la batería.




Figura 5.2: Topología física de la comunidad y de los cuatro flujos de la batería. En cada hora la batería o carga (cs, cm) o descarga (dc, dr); los flujos grises son consecuencia automática del balance horario y no pasan por la batería.

Modelo Electroquímico

El estado de carga evoluciona según:

$$E_{h+1} = E_h \cdot \alpha + P_c^h \cdot \eta_c - P_d^h / \eta_d \quad (5.6)$$

donde $\alpha = 1 - 0,004 \text{ \%}/\text{h}$ es el factor de retención por autodescarga, $\eta_c = \eta_d = 0,95$ son las eficiencias de carga y descarga (round-trip: 90,25%), y el SoC operativo se limita a [10 %, 90 %]. P_d^h denota aquí la energía útil entregada en el lado de corriente alterna (consumo de las viviendas o venta a red); dividir por η_d recupera la energía bruta que efectivamente se descuenta de la batería, de modo que la eficiencia de descarga se aplica una única vez.

Los valores de estos parámetros proceden de las hojas de características de sistemas BESS comerciales de química LFP, igual que la vida útil empleada en la calibración de la degradación (Sección 5.2.5): la eficiencia *round-trip* resultante (90,25 %, al aplicar $\eta = 0,95$ en cada sentido) se sitúa en el rango típico del 88–95 % de un sistema estacionario completo, incluyendo las pérdidas de conversión del inversor; y la autodescarga de

0,004 %/h (en torno al 3 % al mes) corresponde al orden de magnitud característico de la química LFP, de autodescarga baja frente a otras químicas de litio.

Modelo de Degradación No Lineal

El coste de degradación por paso temporal es:

$$c_{\text{deg},h} = C_{\text{base}} \cdot \underbrace{\left(1 + \left(\frac{P}{P_{\text{máx}}}\right)^2\right)}_{f_P} \cdot \underbrace{\left(1 + 15 |\text{SoC} - 0,5|^4\right)}_{f_{\text{SoC}}} \cdot E_{\text{movida},h} \quad (5.7)$$

f_P penaliza cuadráticamente los ciclos a alta corriente (efecto Joule). f_{SoC} penaliza cuárticamente la operación en los extremos del rango, reproduciendo el comportamiento real de baterías LFP donde la operación prolongada próxima al 0 % o 100 % de SoC acelera los mecanismos de degradación electroquímica (Vetter et al., 2005; Xu et al., 2018). El coeficiente $C_{\text{base}} = 0,005 \text{ €/kWh}$ no debe confundirse con el coste efectivo de degradación: una vez modulado por los factores de estrés, el coste efectivo medio resulta de unos $0,006 \text{ €/kWh}$, y es ese valor el que se calibra contra la amortización realista de la batería en la Sección 5.2.5.

Esta no linealidad es intencional y tiene una consecuencia metodológica crucial: el MPC, que linealiza la degradación como $K = 0,005 \text{ €/kWh}$ fijo, introduce un error sistemático de modelado que el Residual SAC puede aprender a corregir.

Calibración del Coste Base de Degradación

El valor $C_{\text{base}} = 0,005 \text{ €/kWh}$ de la ecuación (5.7) no es el coste de degradación directamente, sino el *coeficiente base* que, una vez modulado por los factores de estrés, reproduce el coste de amortización realista de la batería. La calibración parte del coste marginal de reposición de las *celdas* (el único componente que se desgasta con el ciclado, frente al inversor o la instalación, que son capital hundido (CAPEX)):

$$c_{\text{amort}} = \frac{c_{\text{celda}}}{2 N_{\text{ciclos}}}, \quad (5.8)$$

donde el factor 2 refleja que el coste se imputa sobre el *throughput bidireccional* (carga más descarga, E_{movida}). Con un coste neto de celdas LFP de $c_{\text{celda}} \approx 90\text{--}100 \text{ €/kWh}$ (tras la subvención al almacenamiento del Real Decreto 477/2021 (Gobierno de España, 2021) y la caída sostenida del precio de celda (BloombergNEF, 2024; Schmidt et al., 2019)) y una vida útil $N_{\text{ciclos}} \approx 8\,000$ ciclos completos hasta el 80 % de SoH, valor típico de las hojas de características de fabricantes de celdas LFP de aplicación estacionaria (batería fija de edificio o instalación, cuyo ciclado es más suave que el de un vehículo

eléctrico), la ecuación (5.8) arroja $c_{\text{amort}} \approx 0,006 \text{ €/kWh}$. La cifra es *independiente de la capacidad nominal*, lo que justifica fijarla como parámetro constante en €/kWh.

El coste imputado por la ecuación (5.7) no es plano, sino $C_{\text{base}} \cdot f_P \cdot f_{\text{SoC}}$. Sobre las trayectorias evaluadas, el multiplicador medio (ponderado por energía) de los factores de estrés resulta $\overline{f_P f_{\text{SoC}}} \approx 1,2$, de modo que el coste efectivo medio es $C_{\text{base}} \cdot 1,2 \approx 0,006 \text{ €/kWh}$, *coincidente con el coste de amortización* c_{amort} de la ecuación (5.8). En otras palabras, $C_{\text{base}} = 0,005$ se fija para que el coste *efectivo* (no el coeficiente) iguale la amortización realista de una batería LFP subvencionada. La ventaja de la formulación no lineal es que reparte ese coste medio según el estrés electroquímico real de cada operación (mayor a alta corriente, por efecto Joule, y en los extremos de SoC (Vetter et al., 2005; Xu et al., 2018)) en lugar de mediante un coste plano, que es precisamente la aproximación de primer orden del MPC.

Conviene ser explícito sobre la dependencia de los supuestos: la igualdad anterior descansa en la subvención del RD 477/2021 (aplicable a la instalación considerada) y en una vida útil de gama estacionaria; sin subvención, el coste de amortización de un *pack* no subvencionado se situaría en torno a 0,013–0,017 €/kWh, y C_{base} constituiría una cota inferior. En cualquier caso, y de forma determinante para la validez del estudio, el coste de degradación se aplica de manera *idéntica* a todos los controladores (MPC, DQN, PPO y Residual SAC) y en la métrica de evaluación. Por tanto, **el orden comparativo entre controladores y su significancia estadística son invariantes al valor absoluto de C_{base}** : solo el ahorro absoluto en €/año escala (de forma aproximadamente lineal) con dicho parámetro. La conclusión central de este trabajo (que la arquitectura residual supera al MPC realista) no depende, por tanto, de esta calibración (Sección 8.2).

Modelo Económico

El beneficio marginal respecto a IDLE en cada paso es:

$$r_h = E_{\text{vend},h} \cdot p_v^h - E_{\text{comp},h} \cdot p_c^h - c_{\text{deg},h} \quad (5.9)$$

El modelo es asimétricamente desfavorable para el arbitraje puro: dado que $p_c^h > p_v^h$ siempre, comprar de red para cargar la batería y vender después es sistemáticamente ineficiente. Esto crea el incentivo natural para maximizar el autoconsumo interno.

El entorno discreto utilizado por DQN añade además un término de *reward shaping*: un coste de oportunidad dinámico que penaliza la acción de descargar a red cuando $\text{SoC} < 0,70$, escalando hasta cuatro veces el spread de precios a medida que el SoC se acerca al mínimo operativo. Este término no forma parte del modelo económico base de la ecuación (5.9) ni se aplica en el MPC o en el Residual SAC; es específico del espacio de acciones discreto y busca frenar el vaciado prematuro de la batería que la

discretización tiende a favorecer.

Inicialización del SoC y Frontera del Episodio

El estado de carga inicial de la batería y el valor de la energía almacenada en los extremos del episodio se tratan *deliberadamente de forma distinta* en entrenamiento, evaluación y despliegue. No es una inconsistencia, sino tres decisiones coherentes con la finalidad de cada contexto.

(A) Inicialización del SoC.

- *Entrenamiento — aleatorio.* El SoC inicial se muestrea uniformemente dentro de los límites operativos. Es una forma de *domain randomization*: obliga al agente a aprender una política robusta a *cualquier* estado de partida, en lugar de especializarse en un único punto.
- *Evaluación — fijo (50 %) y con semilla.* Prima la reproducibilidad y la comparación justa: MPC, DQN, PPO y Residual SAC parten exactamente del mismo estado. Además, el SoC inicial es un transitorio que se diluye a lo largo de la semana (168 h), por lo que su valor concreto es de segundo orden sobre el beneficio semanal.
- *Despliegue — continuista.* La batería es un activo físico que arrastra su carga indefinidamente, sin episodios. Precisamente la aleatorización del SoC en entrenamiento es lo que capacita al agente para operar desde cualquier carga que se encuentre en producción.

(B) Frontera del episodio (valor terminal y coste inicial). En el entrenamiento la recompensa incorpora un **valor terminal** (que retribuye la energía que queda en la batería al final del episodio) y un **coste inicial** simétrico (que descuenta el valor de la energía con la que se arranca). Sin estos términos, un agente episódico aprendería a *vaciar la batería a la red en la última hora*, pues la energía almacenada no reportaría recompensa dentro del horizonte finito; los términos de frontera eliminan ese artefacto y hacen que el episodio aproxime la tarea continua real. La **evaluación**, en cambio, reporta el **beneficio marginal realizado** (*cashflow* puro, ecuación (5.9), sin términos de frontera): mide el dinero efectivamente ahorrado durante la semana, y al aplicarse de forma *idéntica* a todos los controladores, la comparación permanece justa. En **producción** la cuestión no se plantea: al no existir episodios, no hay frontera que corregir.

Como consecuencia directa, la recompensa observada *durante* el entrenamiento (que incorpora los términos de frontera) queda de forma sistemática algo por debajo del beneficio marginal limpio reportado en la evaluación: ambas métricas se calculan sobre las mismas 50 semanas *held-out*, pero la de entrenamiento descuenta en neto el coste inicial frente al valor terminal. Esta brecha es esperable por construcción y no refleja

un peor rendimiento real del modelo.

5.3. Motor de Decisión Energético

5.3.1. Cotas de Rendimiento: El Controlador MPC

Antes de cualquier experimento con RL se establecen dos cotas de rendimiento que contextualizan todos los resultados posteriores.

MPC con Pronóstico Oráculo (Cota Teórica Superior)

El MPC oráculo resuelve en cada paso un problema de LP de horizonte 24 horas recibiendo los datos reales futuros como pronóstico. El problema LP tiene 96 variables de decisión (4 flujos $\times$ 24 horas), las restricciones de balance energético, límites de SoC, potencia y acoplamiento físico, y la función objetivo:

$$\min \sum_{h=0}^{23} \left[(p_v^h + K)c_s^h + (p_c^h + K)c_m^h - (p_c^h \eta_d - K)d_c^h - (p_v^h \eta_d - K)d_r^h \right] \quad (5.10)$$

donde $K = 0,005 \text{ €/kWh}$ es la penalización linealizada de degradación. Ningún controlador desplegable puede superar sistemáticamente al MPC oráculo porque hacerlo requeriría predecir el futuro con exactitud.

Resultado: +51,45 €/semana (IC95 [44,07; 60,29]) bajo el protocolo unificado de evaluación (50 semanas *held-out*, SoC inicial 50 %, intervalo de confianza por *bootstrap*; Sección 5.3.10). El intervalo es ancho porque refleja la variabilidad estacional entre las semanas del año, no incertidumbre del controlador (con previsión perfecta el resultado de cada semana es determinista).

Alcance de la optimalidad. El MPC se formula como un programa lineal, lo que garantiza el *óptimo global de su función objetivo* y un tiempo de resolución de milisegundos, apto para operación en tiempo real en el nodo *edge*. Esa linealidad obliga, no obstante, a aproximar la degradación (no lineal en la realidad, ecuación (5.7)) mediante un coste marginal constante K . En consecuencia, el MPC es óptimo respecto a su *modelo lineal*, no necesariamente respecto al problema no lineal subyacente: un MPC no lineal (NLP) o un esquema de programación dinámica que incorporasen la degradación exacta podrían aproximarse mejor al óptimo verdadero, a costa de perder la convexidad, la garantía de óptimo global y la resolución en tiempo real del LP. Se adopta por ello el MPC lineal como cota de referencia, que es la práctica estándar en la gestión de almacenamiento, en el entendido de que no constituye el mejor controlador sin aprendizaje *concebible*, sino

el más fuerte y práctico; y es precisamente esta brecha de linealización la que el residual aprende a capturar con coste de inferencia despreciable (Sección 5.3.3, Argumento 1).

MPC con Pronóstico Realista (Baseline Competitivo)

Misma formulación LP, pero con la ventana de previsión perturbada para reflejar la incertidumbre real. La generación FV recibe un ruido AR(1) con σ creciente del 5 % en $h+1$ al 25 % en $h+24$ ($\rho = 0,7$); el consumo, un ruido AR(1) con $\sigma = 15$ % y $\rho = 0,3$. Los precios siguen el modelo de tres capas según la publicación del PVPC a las 20:30 h: las horas ya publicadas se conocen de forma exacta (capa 1); la ventana intradiaria posterior, de unas seis horas, correspondiente al mercado OMIE, lleva un ruido suave ($\sigma = 5$ %, $\rho = 0,5$, capa 2); y el resto del horizonte, todavía sin publicar, se estima con mayor incertidumbre ($\sigma = 15$ %, $\rho = 0,7$, capa 3). Es el mismo modelo de precios que ve el MPC interno del Residual SAC, lo que garantiza una comparación justa entre ambos.

La estructura y la magnitud de este ruido se justifican por el comportamiento característico del error de pronóstico a día siguiente: es mínimo en la primera hora y crece con el horizonte, de ahí el σ creciente del 5 al 25 % en la generación FV, cuyo error (de origen meteorológico) es además el más persistente ($\rho = 0,7$: un frente nuboso mal previsto afecta a horas consecutivas). El consumo agregado, en cambio, recibe un error de magnitud constante ($\sigma = 15$ %) y menos persistente ($\rho = 0,3$), coherente con una demanda residencial cuyos desvíos son más erráticos y de menor memoria que los meteorológicos. Los valores concretos son supuestos del escenario, no mediciones; su elección no es crítica para las conclusiones, porque la ablación F6 (Sección 5.3.12) barre el ruido de consumo entre el 5 y el 25 % y el resultado cualitativo del trabajo se mantiene en todo el rango.

Resultado: +43,39 €/semana (IC95 [41,24; 45,57], media sobre diez semillas de ruido).

El coste agregado de la incertidumbre del pronóstico es $51,45 - 43,39 = 8,06$ €/semana (15,7 %), englobando las tres fuentes de ruido (generación, consumo y precios). Este valor establece el límite teórico de mejora alcanzable mediante un pronóstico más preciso y define el margen en el que opera el Residual SAC.

5.3.2. Experimentación con Algoritmos Candidatos

El proceso de selección del algoritmo de control siguió un protocolo de experimentación estructurado en el que se entrenaron y evaluaron más de veinticinco configuraciones de agentes a lo largo de tres familias algorítmicas. Esta sección presenta los hitos representativos de cada familia (aquellos que motivaron una decisión técnica concreta), mientras que el historial completo de configuraciones se recoge en el Anexo H. Todos los agentes se evalúan con el protocolo unificado (50 semanas, semilla 42, beneficio

marginal respecto a IDLE) frente a la cota práctica del MPC realista. Conviene precisar que la exploración de candidatos (familias DQN y PPO) se realizó durante la fase de selección de algoritmo, sobre el dimensionado preliminar de 50 kWp/100 kWh, en el que el MPC realista se situaba en +48,73 €/semana; el controlador final y las cotas se reevaluaron sobre el dimensionado definitivo de 42 kWp/80 kWh (Sección 5.3.12), por lo que las cifras de DQN y PPO de esta sección corresponden a aquella fase.

Dos fases: exploración y validación. La experimentación se organiza en dos fases de propósito distinto. En la **fase de exploración**, que es la de esta sección, cada configuración se entrena con *una sola semilla* y de forma deliberadamente barata; su fin es *generar hipótesis y acotar* el espacio de arquitecturas e hiperparámetros, por lo que sus cifras son *indicativas* y no soportan por sí solas conclusiones cuantitativas. Las configuraciones que superan este cribado pasan a la **fase de validación** (Sección 5.3.11), donde se entrenan con **tres semillas** y se evalúan con **diez semillas de ruido** (intervalo de confianza al 95 % por *bootstrap* y test de Wilcoxon) sobre el dimensionado definitivo. Es esta segunda fase la que sustenta las conclusiones del trabajo; la exploración solo justifica *por qué* se valida cada candidato.

Criterio de selección de los candidatos. Los candidatos de la exploración no se eligen por preferencia, sino como representantes canónicos de las familias algorítmicas de la Sección 5.1: DQN representa a los métodos basados en valor, por ser el algoritmo de referencia del dominio desde Mnih et al. (2015) y el más citado en las revisiones de RL aplicado a sistemas energéticos (Perera & Kamalaruban, 2021; Vázquez-Canteli & Nagy, 2019); PPO representa a los *policy gradient on-policy*, por ser el estándar de facto de esa familia por su robustez de entrenamiento (Schulman et al., 2017), y se entrena sobre el mismo espacio discreto para aislar el efecto del mecanismo de aprendizaje del efecto del espacio de acciones. La tercera familia (*actor-critic off-policy* continuo, cuyo representante es SAC) no se explora como agente autónomo, sino que se reserva para la arquitectura residual, decisión que se justifica en la Sección 5.3.3; la suite de validación completa después esa familia con sus otros dos miembros estándar (TD3 y DDPG) y con el propio SAC puro como ablación (Sección 5.3.11).

Controlador Heurístico (Suelo de Rendimiento)

El controlador heurístico aplica reglas if-then deterministas sobre el SoC y el balance neto: si hay excedente solar y $\text{SoC} < \text{SoC}_{\text{máx}}$, cargar; si hay déficit y $\text{SoC} > \text{SoC}_{\text{mín}}$, descargar; nunca comprar de red para cargar la batería. Establece el suelo de rendimiento que cualquier controlador inteligente debe superar.

Familia DQN: el Problema del Crédito Temporal

DQN-A — Línea base sin propagación temporal. La primera configuración de DQN utiliza el algoritmo estándar con *n-step* returns de un solo paso ($n = 1$), espacio de observación de 101 dimensiones sin codificación temporal y espacio de acciones discreto. El resultado fue pobre: el agente no logra superar los ≈ 39 €/semana de media. El diagnóstico identificó el cuello de botella en la propagación tardía del crédito: con $n = 1$, la recompensa de descargar la batería en una hora de precio alto se propaga muy lentamente hacia las decisiones de carga que la hicieron posible varias horas antes.

DQN-B — N-step y horizonte de descuento ajustado. La segunda configuración representativa introduce *n-step* returns con $n = 8$ y reduce el espacio de acciones de 13 a 9, eliminando niveles de potencia redundantes en las estrategias de carga solar y descarga para consumo. El factor de descuento base es $\gamma = 0,995$, que con la propagación de ocho pasos resulta en un descuento efectivo $\gamma^n \approx 0,96$. Esta configuración es la mejor de toda la familia DQN, con un resultado de **+45,23 €/semana**. El análisis de la política muestra que el agente aprende a gestionar la batería con un SoC medio en torno al 39 %, repartiendo la descarga entre consumo interno (33 %) y venta a red (27 %). Sin embargo, no alcanza el nivel del MPC realista: queda 3,50 €/semana por debajo del *baseline*.

DQN-C — N-step largo: más no es mejor. Una tercera configuración exploró *n-step* returns con $n = 24$, correspondiente a un ciclo completo de carga/descarga de 24 horas, con factor de descuento efectivo $\gamma^{24} \approx 0,787$. La hipótesis era que un horizonte de propagación más largo mejoraría la captura de los ciclos diarios. El resultado fue **+41,71 €/semana** (no convergió en 3M pasos): con $n = 24$ el aprendizaje es notablemente más lento y el agente no había convergido tras tres millones de pasos de entorno, manteniéndose por debajo de la configuración con $n = 8$. La conclusión es que $n = 8$ ofrece el equilibrio adecuado entre propagación de crédito y velocidad de convergencia para este problema, frente a horizontes de propagación más largos que ralentizan el aprendizaje sin aportar mejora.

Análisis de las limitaciones de DQN. Más allá del ajuste de *n-step*, la familia DQN presenta una limitación estructural irresoluble: el **error de cuantización** del espacio de acciones discreto. La granularidad fija entre niveles de potencia impide representar los ajustes finos de pocos kilovatios que la política óptima requiere en horas de alta volatilidad de precios. Este error es sistemático y no desaparece con más entrenamiento ni con redes más grandes, lo que motivó la transición a algoritmos de acción continua.

Familia PPO: el Problema del Colapso de Política

PPO-A — Colapso por exceso de exploración. La primera configuración de PPO se motivó por el problema de crédito tardío de DQN: PPO con estimación de ventaja generalizada (GAE) utiliza el *rollout* completo para entrenar la función de valor, resolviendo el horizonte temporal de forma estructural. Sin embargo, con un coeficiente de entropía constante de 0,01, el agente alcanzó un máximo de +39,91 €/sem para luego colapsar hasta ≈ 36 €/sem. El diagnóstico identificó el coeficiente de entropía como la causa: un valor demasiado alto mantiene una exploración excesiva que destruye la política una vez que el agente ha encontrado una buena solución. Configuraciones intermedias con entropía constante más baja (0,003) retrasaron el colapso pero no lo evitaron, confirmando que el problema es estructural en PPO *on-policy*: las actualizaciones sucesivas sobre datos recientes provocan que el agente olvide la buena política previamente aprendida.

PPO-B — Decaimiento de entropía y aprendizaje. La configuración final de PPO resuelve el colapso mediante el decaimiento lineal del coeficiente de entropía (de 0,005 a 0,0005) y de la tasa de aprendizaje (de 3×10^{-4} a 3×10^{-5}), combinado con *rollouts* más largos (8192 pasos) y un espacio de observación ampliado a 108 dimensiones que incorpora codificación temporal y una señal de margen solar. La exploración alta al inicio y la explotación estable al final eliminan el colapso, con un resultado de +45,69 €/semana (mejor configuración PPO, sin colapso). PPO-B alcanza un rendimiento comparable al mejor DQN y se estabiliza sin colapsar, pero al igual que DQN no supera el *baseline* del MPC realista: queda 3,04 €/semana por debajo.

Conclusión de la Experimentación con RL Puro

Los experimentos con las familias DQN y PPO confirman empíricamente la conclusión de la literatura (Zhan et al., 2023): el aprendizaje por refuerzo puro alcanza rendimientos próximos al MPC con pronóstico realista pero no lo supera de forma consistente cuando el MPC está bien calibrado. El mejor DQN (+45,23) y el mejor PPO (+45,69) quedan ambos por debajo del MPC realista (+48,73).

Este resultado no invalida el motor de IA: motiva la transición a una arquitectura híbrida en la que el RL no compite contra el MPC, sino que aprende a corregirlo. La justificación detallada se presenta en la Sección 5.3.3.

La elección de SAC como algoritmo de esa arquitectura residual se deriva de tres requisitos que la propia corrección impone: (a) espacio de acción *continuo*, porque la razón de ser del residual son los ajustes finos de potencia que el espacio discreto no puede representar; (b) naturaleza *off-policy* con *replay buffer*, imprescindible para inyectar

las demostraciones del MPC (protocolo DAWN, Sección 5.3.7), algo estructuralmente imposible en un método *on-policy* como PPO; y (c) exploración regulada dentro de un rango acotado, que la regularización por entropía de SAC proporciona de forma automática (Haarnoja et al., 2018). De los tres *actor-critic off-policy* continuos estándar (SAC, TD3, DDPG), SAC es el único que cumple los tres requisitos por construcción; TD3 y DDPG se incluyen después en la suite de validación precisamente para confirmar esa elección por comparación directa (Sección 5.3.11).

Cabe preguntarse por qué no se exploró antes SAC como agente autónomo, sin MPC base. La razón es de asignación de esfuerzo: la evidencia acumulada en la exploración (DQN y PPO por debajo del MPC realista) y la literatura (Zhan et al., 2023) indicaban que ningún agente de RL puro superaría a un MPC bien calibrado, por lo que el esfuerzo experimental se dirigió a la arquitectura híbrida en lugar de a un tercer intento de RL puro. La hipótesis no se dio por supuesta: la suite de validación incluye SAC puro (versión F5) exactamente para cerrarla con datos, y su resultado (26,94 €/semana, el peor agente de toda la suite; Sección 5.3.12) confirma a posteriori que explorar SAC autónomo no habría cambiado la decisión.

De esta exploración nace además el registro de experimentos (`config/experimentos.yaml`) que define las versiones de la suite de validación de la Sección 5.3.11: cada familia y cada versión validada responde a una hipótesis generada en esta fase (el n -step y el γ de DQN, el decaimiento de entropía de PPO, la forma y el rango de la corrección residual), de modo que la suite no es un barrido ciego de hiperparámetros sino la confirmación estadística, sobre el dimensionado definitivo, de lo aprendido durante la exploración.

5.3.3. Justificación del Motor de IA sobre MPC Puro

La elección del Residual SAC como controlador final se sustenta en tres argumentos estructurales independientes del rendimiento numérico bruto.

Argumento 1 — Corrección de errores sistemáticos de modelado. El MPC optimiza una degradación linealizada ($K = 0,005$ €/kWh fijo) mientras el simulador aplica el modelo no lineal de la ecuación (5.7). Esta brecha crea un error sistemático y predecible que el agente SAC puede aprender a corregir: ser más agresivo en la zona central del SoC, donde el MPC sobrepenaliza la degradación, y más conservador en los extremos, donde la infrapenaliza.

Argumento 2 — Adaptabilidad al envejecimiento de la batería. Los parámetros físicos del MPC (η_c , η_d , $E_{\text{máx}}$, δ_{AD}) se degradan a lo largo de la vida útil de la batería (15 a 20 años para una LFP estacionaria, es decir, fija en la instalación). Un MPC con parámetros desactualizados toma decisiones sistemáticamente subóptimas sin mecanismo de detección. El Residual SAC puede reentrenarse periódicamente incorporando los

parámetros actualizados, mientras el MPC base garantiza el rendimiento mínimo durante la adaptación.

Argumento 3 — Garantía de suelo de rendimiento. Con $\Delta = 0$, el Residual SAC multiplicativo es matemáticamente equivalente al MPC realista, ya que $\text{flow} \times (1 + 0) = \text{flow}$: el punto de partida del aprendizaje y el modo de respaldo del sistema son exactamente el MPC. Para el agente ya entrenado la garantía es de *acotación*, no de identidad: la corrección no puede exceder $\pm\delta_{\text{máx}}$ sobre cada flujo, lo que limita estructuralmente cuánto puede alejarse del MPC (en la suite de validación, la peor configuración residual observada queda 1,07 €/semana por debajo del MPC, un 2,5 %, frente a los 4–16 €/semana que pierden los agentes de RL puro). Ningún algoritmo de RL puro ofrece ninguna de las dos propiedades.

Cuadro 5.2: Comparativa estructural de los controladores evaluados.

Controlador	Esp. usado	Off- policy	Demo MPC	Robustez	Decisión
DQN	Discreto	Sí	Parcial	Media	Descartado*
PPO	Discreto	No	No	Alta	Descartado*
SAC puro	Continuo	Sí	Sí	Alta	Candidato
Residual SAC	Continuo	Sí	Sí	Alta	Seleccionado

*Descartados como controlador final tras la fase de exploración; se reentrenan no obstante en la suite de validación (Sección 5.3.11) como familias comparativas, para confirmar con estadística las limitaciones aquí diagnosticadas.

La Figura 5.3 sitúa a todos los controladores del ecosistema bajo una misma interfaz raíz (**BaseController**), organizados en tres familias: clásicos y *baselines*, RL puro y control híbrido residual.




Figura 5.3: Taxonomía de los controladores implementados. Todas las familias comparten el contrato `solve(state, forecast)`, lo que permite evaluarlas bajo el mismo protocolo; el MPC suministra la política base `u_mpc(t)` a la familia residual.

5.3.4. Diseño del Residual SAC: de Aditiva a Multiplicativa

El controlador final es un agente SAC que aprende correcciones residuales sobre el MPC realista. El diseño atravesó tres iteraciones principales, cada una resolviendo una limitación de la anterior.

Nota de nomenclatura: las cifras de esta subsección corresponden a la *fase de diseño* (dimensionado preliminar de 50 kWp/100 kWh, una semilla) y son indicativas; las iteraciones se citan como v2–v5 siguiendo el Anexo H. En la *suite de validación* (Sección 5.3.11), los identificadores SAC-A, SAC-B y SAC-C designan los reentrenamientos confirmatorios de estas tres arquitecturas (aditiva, multiplicativa amplia y multiplicativa fina) sobre el dimensionado definitivo de 42 kWp/80 kWh, cuyos resultados con tres semillas y diez semillas de ruido se reportan en la Sección 5.3.12.

Iteración 1 (v2/v3): residual aditivo. La primera arquitectura aplica una corrección aditiva absoluta sobre cada flujo del MPC: $\text{flow} + \Delta \cdot \delta_{\text{máx}} \cdot P_{\text{máx}}$. Con $\delta_{\text{máx}} = 0,10$ (correcciones de hasta ± 5 kW), el agente alcanzó +48,80 €/semana, pero con un problema metodológico: el entorno de esta versión permitía carga y descarga simultáneas (físicamente imposible), lo que inflaba artificialmente el resultado. Una versión corregida con neteo y $\delta_{\text{máx}} = 0,05$ produjo correcciones insignificantes y se estancó en ≈ 41 €/semana. El problema de fondo de la arquitectura aditiva es que aplica la misma corrección absoluta independientemente de la magnitud del flujo del MPC: una corrección de ± 5 kW es enorme cuando el MPC propone 2 kW y despreciable cuando propone 40 kW.

Iteración 2 (v4): residual multiplicativo amplio. La segunda arquitectura introduce la corrección multiplicativa: $\text{flow} \times (1 + \Delta \cdot \delta_{\text{máx}})$. Esta formulación escala

proporcionalmente: si el MPC propone un flujo nulo, la corrección es nula (el agente no puede activar lo que el MPC descartó); si el MPC propone un flujo elevado, la corrección es proporcionalmente mayor. Con $\delta_{\text{máx}} = 0,30$ ($\pm 30\%$ sobre cada flujo del MPC), el agente arrancó mejor que las versiones aditivas pero se estancó en torno a $+43,3 \text{ €/semana}$ desde los 80.000 pasos. El diagnóstico identificó que un rango de corrección demasiado amplio ($\pm 30\%$) permite al agente desviarse en exceso del MPC, perdiendo la ventaja de partir de una política ya optimizada.

Iteración 3 (v5): residual multiplicativo fino (arquitectura final). La configuración final reduce el rango de corrección a $\delta_{\text{máx}} = 0,15$ ($\pm 15\%$ sobre cada flujo del MPC) y aumenta el coeficiente de entropía a 0,01, obligando a correcciones finas sobre un MPC ya optimizado mientras mantiene suficiente exploración dentro del rango reducido. Esta es la arquitectura que se consolida como controlador propuesto: su reentrenamiento confirmatorio sobre el dimensionado definitivo (versión SAC-C de la suite de validación) alcanza $+44,05 \text{ €/semana}$ frente a los $+43,39$ del MPC realista, una mejora de $+0,66 \text{ €/semana}$ estadísticamente significativa (Sección 5.3.12).

5.3.5. Formulación Final del Residual SAC

La acción final del controlador es:

$$a_{\text{final},i} = a_{\text{MPC},i} \times (1 + \Delta_i \cdot \delta_{\text{máx}}), \quad \delta_{\text{máx}} = 0,15 \quad (5.11)$$

para cada uno de los cuatro flujos $i \in \{c_s, c_m, d_c, d_r\}$, donde $\Delta_i \in [-1, 1]$ es la salida del actor SAC. Con $\Delta = \mathbf{0}$, $a_{\text{final}} = a_{\text{MPC}}$, replicando exactamente el MPC realista.

La Figura 5.4 ilustra el ciclo de inferencia paso a paso entre el motor de decisión y el entorno simulado: en cada hora, el entorno entrega la observación, el MPC resuelve su LP y propone la acción base, el actor SAC calcula la corrección residual Δ , ambas se combinan según la ecuación (5.11) y la acción resultante se aplica al simulador, que avanza al siguiente estado.




Figura 5.4: Diagrama de secuencia de la inferencia del Residual SAC sobre el entorno simulado: el MPC resuelve su LP y propone la acción base, el actor calcula la corrección Δ (determinista, con normalización congelada) y la fusión multiplicativa se aplica al simulador físico-económico.

5.3.6. Espacio de Observación (112 dimensiones)

Cuadro 5.3: Composición del vector de observación del Residual SAC.

Grupo	Variables	Dims
Estado actual	SoC, p_c , p_v , excedente, déficit	5
Pronóstico 24 h	Consumo, gen., p_c , p_v para $h+1 \dots h+24$	96
Codif. temporal	sin / cos hora, día sem., mes, margen solar	7
Intención MPC	$(c_s^{\text{MPC}}, c_m^{\text{MPC}}, d_c^{\text{MPC}}, d_r^{\text{MPC}})$	4
Total		112

Los 108 valores de base (5 actuales + 96 pronóstico + 7 temporales) se amplían con los 4 flujos normalizados de la intención del MPC, permitiendo al agente conocer la acción base sobre la que propone su corrección; es una extensión natural del esquema residual de Johannink et al. (2019), en la que el condicionamiento a la acción base se hace explícito en la observación.

5.3.7. Protocolo de Inicialización DAWN

Antes del entrenamiento se pre-llena el *replay buffer* con 100.000 transiciones generadas por el MPC puro ($\Delta = \mathbf{0}$), procedimiento denominado *DAWN warmup*. Esto ancla el crítico al nivel de rendimiento del MPC desde la primera actualización y calibra las estadísticas de normalización (**VecNormalize**) con experiencia representativa, evitando la patología de arranque en frío.

5.3.8. Modelo de Ruido de Precios en Tres Capas

El entorno de la configuración final incorpora un modelo de ruido de precios estructurado en tres capas que refleja la disponibilidad real de información en el mercado eléctrico español. La primera capa corresponde a los precios PVPC publicados por REE (exactos, sin ruido). La segunda capa modela las horas inmediatamente posteriores, correspondientes al mercado intradiario de OMIE, con ruido bajo ($\sigma = 5\%$, $\rho = 0,5$). La tercera capa modela el horizonte restante, todavía sin publicar, con ruido mayor ($\sigma = 15\%$, $\rho = 0,7$). Este modelo hace el entorno de entrenamiento más realista que el ruido AR(1) uniforme empleado en las versiones anteriores, y es el mismo modelo de precios que ve el MPC interno del Residual SAC, lo que garantiza una comparación justa.

5.3.9. Hiperparámetros Finales

Cuadro 5.4: Hiperparámetros del Residual SAC (configuración final SAC-C).

Parámetro	Valor	Justificación
Arquitectura residual	multiplicativa	Escala con la magnitud del flujo MPC
delta_max	0,15	$\pm 15\%$; meseta 0,05–0,20, degradación en 0,30 (barrido F2)
ent_coef	0,01	Exploración dentro del rango reducido
learning_rate	10^{-4}	Convergencia estable en espacio 4D
buffer_size	100 000	Cubre la diversidad de episodios
batch_size	256	Estándar SAC en problemas continuos
gamma	0,99	Horizonte efectivo ≈ 100 pasos
tau	0,005	Actualización suave del crítico objetivo
net_arch	[256, 256]	Capacidad para 112 dimensiones
DAWN warmup	100 000	Pre-llenado del buffer con MPC puro
Pasos totales	1.000.000	Convergencia completa

5.3.10. Criterio de Selección del Modelo y Protocolo de Evaluación

Cada algoritmo se entrena con **tres semillas** y la evaluación distingue dos preguntas distintas; este trabajo reporta y despliega el modelo que responde a la primera.

(1) ¿Qué modelo se despliega? De las tres semillas se selecciona el **mejor modelo**, no el de rendimiento medio. El objetivo no es caracterizar el rendimiento típico del algoritmo, sino obtener el *mejor controlador desplegable*: una vez fijados sus pesos, ese modelo rinde a su nivel con independencia de la varianza del proceso de entrenamiento (desplegar un sistema es desplegar un modelo concreto, no un promedio). Su rendimiento se reporta de forma robusta como la **media sobre diez semillas de ruido de evaluación** (distintas realizaciones del ruido AR(1) sobre las 50 semanas *held-out*), de modo que la cifra no depende de una realización de ruido afortunada.

(2) ¿Qué algoritmo es mejor en promedio? Es una pregunta diferente (la robustez *inter-entrenamiento*) que requeriría la distribución sobre las semillas de entrenamiento (media $\pm$ desviación). Resulta relevante en un escenario de *reentrenamiento* (p. ej. un ajuste fino por comunidad), donde la fiabilidad importa más que el pico afortunado; ahí la garantía de suelo del Residual SAC asegura una varianza inter-semilla mínima (sus tres semillas rinden casi idéntico), frente a la mayor dispersión esperable en DQN y PPO.

Sobre el conjunto de evaluación. Las 50 semanas de evaluación son *held-out*: ningún modelo se entrena sobre ellas, por lo que las cifras reportadas no incurrir en fuga de datos (*leakage*). Además, la selección del mejor de las tres semillas se realiza con la métrica interna de entrenamiento (SoC inicial aleatorio y valor terminal), distinta de la que se publica en la evaluación unificada (SoC fijo y beneficio marginal puro), de modo que el modelo no se selecciona sobre la misma medida que se reporta. El optimismo de selección residual es, por tanto, despreciable (y nulo en la práctica para el Residual SAC, cuyas tres semillas rinden casi idéntico por la garantía de suelo: métrica interna de 41,08, 41,14 y 41,11 €/semana para las semillas 42, 1337 y 2024).

5.3.11. Diseño de la Suite de Validación

La exploración fija qué hipótesis merece la pena confirmar con rigor; de ella se deriva la *suite de validación*: las familias y versiones que se entrenan con tres semillas y se evalúan con diez semillas de ruido bajo el protocolo de la Sección 5.3.10. Cada familia no es una prueba ciega, sino que responde a una hipótesis concreta, encadenadas en el mismo razonamiento que llevó al controlador final:

- **DQN** (DQN-1... 6): comprueba si un método *basado en valor* puro supera al

MPC y delimita el efecto del horizonte de propagación de crédito (barrido de n -step 1/4/8/24, descuento y tasa de aprendizaje). Hipótesis: no lo supera y el error de cuantización del espacio discreto es estructural.

- **PPO discreto** (PPO-D1... 5): confirma que el *on-policy* con entropía constante colapsa y que el decaimiento conjunto de entropía y tasa de aprendizaje lo evita.
- **PPO continuo** (PPO-C1... 3): aísla la pregunta «¿basta con pasar a acción continua?». Al ser *on-policy* no puede aprovechar las demostraciones del MPC (DAWN), de modo que separa el mérito del espacio continuo del de la arquitectura residual.
- **Residual SAC** (SAC-A/B/C más ablaciones): es el controlador propuesto. SAC-A/B/C contrastan la forma del residual (aditivo frente a multiplicativo), el rango de corrección δ y el coeficiente de entropía; las ablaciones aíslan cada componente: **F2** barre δ (0,05–0,30), **F4** elimina el *warmup* DAWN, y **F6** estresa la robustez variando el ruido de consumo ($\sigma = 5\%$ y 25%).
- **TD3 y DDPG residuales**: misma arquitectura residual con otros algoritmos *off-policy*; justifican *por comparación y descarte* la elección de SAC (regularización por entropía y doble crítico).
- **SAC puro** (F5): SAC continuo directo, sin MPC base ni DAWN; aísla el mérito de la *arquitectura residual* frente al del algoritmo en sí.

Cada candidato existe, por tanto, para confirmar o descartar una hipótesis derivada de la exploración. La suite se ha completado en su totalidad: 31 versiones entrenadas y evaluadas bajo el protocolo unificado (tres semillas de entrenamiento, diez semillas de ruido de evaluación, 50 semanas *held-out*, intervalos de confianza al 95 % por *bootstrap* y test de Wilcoxon pareado por semana y semilla de ruido frente al MPC realista). Los resultados agregados se presentan en la Sección 5.3.12; el detalle completo de cada versión (media, IC95, p e hiperparámetros) se recoge en el Anexo F, y los entornos de entrenamiento y las condiciones de reproducibilidad en el Anexo G.

5.3.12. Resultados Experimentales

El entrenamiento converge con rapidez según los registros de evaluación periódica (`evaluations.npz` de cada ejecución): la meseta se alcanza en torno a los 100.000 pasos y se mantiene estable hasta completar el millón, comportamiento coherente con el espacio de corrección acotado a $\pm 15\%$, porque desde el primer punto de control el agente rinde ya cerca de su nivel final (la corrección acotada no puede alejarse del suelo del MPC). El mejor *checkpoint* de la semilla desplegada (1337) se selecciona en el paso 280.000. No se reproduce aquí la curva de entrenamiento: en el protocolo de este

trabajo el objeto evaluado es el modelo final bajo la evaluación unificada, y la dinámica del entrenamiento (idéntica entre semillas por la garantía de suelo, Cuadro 5.6) no aporta información adicional sobre el rendimiento desplegado. El Cuadro 5.5 recoge los resultados finales de los *baselines* y de la mejor versión de cada familia bajo el protocolo de evaluación unificado; el detalle de las 31 versiones se encuentra en el Anexo F.

Cuadro 5.5: Resultados de la suite de validación: *baselines* y mejor versión de cada familia (€/semana, beneficio marginal frente a IDLE; 50 semanas *held-out* $\times$ 10 semillas de ruido; IC95 por *bootstrap*; p del test de Wilcoxon pareado por semana y semilla de ruido frente al MPC realista).

Controlador	€/sem	Δ MPC	IC95	p
MPC oráculo (cota superior)	51,45	+8,06	[44,07; 60,29]	n/a
TD3 residual (TD3-4)	44,17	+0,79	[42,02; 46,37]	$1,5 \cdot 10^{-37}$
Residual SAC (SAC-C)	44,05	+0,66	[41,90; 46,25]	$1,5 \cdot 10^{-23}$
DDPG residual (mejor: DDPG-1)	43,44	+0,05	[41,32; 45,60]	0,95
MPC realista (referencia)	43,39	—	[41,24; 45,57]	—
DQN (mejor: DQN-1, $n=1$)	39,36	−4,02	[37,21; 41,62]	$5,0 \cdot 10^{-67}$
PPO discreto (mejor: PPO-D4)	39,35	−4,04	[37,09; 41,70]	$2,4 \cdot 10^{-60}$
PPO continuo (mejor: PPO-C3)	38,31	−5,07	[36,08; 40,66]	$6,5 \cdot 10^{-45}$
Heurístico	30,49	−12,90	[28,14; 32,91]	$4,6 \cdot 10^{-75}$
SAC puro (F5)	26,94	−16,44	[25,53; 28,40]	$1,3 \cdot 10^{-83}$
IDLE (sin batería)	0,00	−43,39	—	—

Dimensionado definitivo 42 kWp / 80 kWh en todas las filas. Cada agente se entrena con tres semillas y se despliega la mejor (Sección 5.3.10); las ablaciones F2/F4/F6 del Anexo F usan una semilla.

Resultado central

El resultado central del trabajo es que el **Residual SAC (SAC-C, +44,05 €/semana)** supera al **MPC realista (+43,39 €/semana)** en +0,66 €/semana (+1,5 %), con IC95 [41,90; 46,25] y significancia estadística muy alta en el contraste pareado por semana y semilla de ruido (Wilcoxon, $p = 1,45 \cdot 10^{-23}$): la mejora es pequeña en magnitud pero extraordinariamente consistente, porque se repite semana a semana en las 500 evaluaciones realizadas (50 semanas $\times$ 10 semillas de ruido). Conviene leer el margen con honestidad: el MPC realista es un controlador muy fuerte, y el techo alcanzable es la brecha de pronóstico de 8,06 €/semana, de la que el residual recupera en torno al 8 %. El valor de la arquitectura no reside solo en esa mejora media, sino en su combinación con la garantía de suelo (Sección 5.3.3) y con una aportación creciente cuando el pronóstico se degrada (ablación F6, más abajo). Ningún controlador de RL puro (DQN, PPO en sus dos variantes, SAC directo) consigue siquiera igualar al MPC.

Consistencia entre semillas de entrenamiento

Cuadro 5.6: Consistencia inter-entrenamiento del Residual SAC (SAC-C): métrica interna de entrenamiento por semilla (€/semana).

Semilla de entrenamiento	Métrica interna
42	41,08
1337 (desplegada)	41,14
2024	41,11
Rango	0,06

Las tres semillas de entrenamiento difieren entre sí en solo 0,06 €/semana (un 0,15 %), evidencia empírica de que la garantía de suelo elimina en la práctica la varianza inter-semilla característica del RL profundo: partir del MPC y corregirlo de forma acotada deja poco espacio para que la aleatoriedad del entrenamiento produzca modelos dispares. Se despliega la semilla 1337 (mejor métrica interna) y su rendimiento publicado (+44,05) es la media agregada sobre las diez semillas de ruido de evaluación; la significancia del resultado queda establecida por el contraste pareado sobre los 500 pares semana-ruido (Wilcoxon, $p < 0,001$).

Estudios del ganador

Forma del residual (SAC-A/B/C). Los reentrenamientos confirmatorios de las tres arquitecturas de la fase de diseño reproducen su ordenación sobre el dimensionado definitivo: la aditiva SAC-A queda en 42,47 €/semana ($-0,91$ frente al MPC, $p = 1,8 \cdot 10^{-28}$), la multiplicativa amplia SAC-B en 42,31 ($-1,07$) y solo la multiplicativa fina SAC-C supera al MPC ($+0,66$). El dato confirma el diagnóstico de la fase de diseño: la forma multiplicativa con rango fino no es una opción entre varias equivalentes, sino la única de las tres que aporta valor positivo; las otras dos son significativamente peores que el propio MPC que corrigen.

Barrido del rango de corrección (ablación F2). El Cuadro 5.7 muestra el efecto de $\delta_{\text{máx}}$ manteniendo el resto de la configuración de SAC-C.

Cuadro 5.7: Barrido del rango de corrección $\delta_{\text{máx}}$ (ablación F2).

$\delta_{\text{máx}}$	0,05	0,10	0,15 (SAC-C)	0,20	0,30
€/semana	43,79	44,01	44,05	43,78	42,43
Δ vs. MPC	+0,41	+0,63	+0,66	+0,40	−0,95

F2-d05/d10/d20/d30: una semilla de entrenamiento; SAC-C: tres semillas.

La ventaja sobre el MPC forma una meseta robusta en $\delta_{\text{máx}} \in [0,05; 0,20]$ (todas las versiones lo superan) y se degrada con claridad en 0,30, donde el agente puede desviarse demasiado de la política base. El resultado del trabajo no depende, por tanto, de un ajuste fino afortunado del rango de corrección.

Arranque guiado DAWN (ablación F4). La ablación F4 elimina el *warmup* DAWN manteniendo el resto de la configuración de SAC-C: el resultado final es +44,04 €/semana (+0,65 sobre el MPC), estadísticamente indistinguible del +44,05 de SAC-C. El dato obliga a matizar la tesis inicial: **DAWN no mejora el rendimiento final** del residual multiplicativo, porque la propia arquitectura (corrección acotada sobre una política ya optimizada) evita por sí sola la patología de arranque en frío: los registros de evaluación periódica del entrenamiento (`evaluations.npz` de cada ejecución) muestran que, incluso sin *warmup*, el agente rinde desde el primer punto de control (paso 20.000) cerca de su nivel final (39,1 frente a 39,9 con DAWN, sobre una meseta final de ≈ 41 en la métrica interna). El valor de DAWN queda así acotado a lo operativo: arrancar con el *replay buffer* poblado por la política del MPC y las estadísticas de normalización calibradas, algo relevante en un escenario de reentrenamiento en producción, donde el sistema debe seguir operando mientras aprende, pero no en la cifra final de laboratorio.

Sensibilidad al error de pronóstico (ablación F6). La ablación F6 reentrena y evalúa la configuración de SAC-C bajo dos niveles alternativos de ruido de consumo; cada fila del Cuadro 5.8 compara al agente con el MPC realista *que ve el mismo nivel de ruido*, de modo que la comparación es justa en los tres escenarios.

Cuadro 5.8: Sensibilidad al error de pronóstico de consumo (ablación F6). La fila central corresponde a la configuración estándar (F6-s15 es exactamente SAC-C).

σ_{consumo}	MPC realista	Residual SAC	Δ	p
5 %	48,27	47,48	−0,79	$1,9 \cdot 10^{-68}$
15 %	43,39	44,05	+0,66	$1,5 \cdot 10^{-23}$
25 %	38,59	40,02	+1,42	$8,6 \cdot 10^{-61}$

La aportación del residual crece de forma monótona con el error de pronóstico ($-0,79 \rightarrow +0,66 \rightarrow +1,42$). Con un pronóstico casi perfecto el MPC es ya casi óptimo y el residual no encuentra error sistemático que corregir (de hecho, estorba); cuanto peor es el pronóstico, mayor es el margen sistemático aprendible. Este resultado confirma el mecanismo del Argumento 1 de la Sección 5.3.3 y delimita el dominio de utilidad del sistema: comunidades con pronósticos imperfectos, que es precisamente el caso realista.

Familias comparativas

DQN (DQN-1... 6). La mejor versión validada es DQN-1 (n -step = 1) con 39,36 €/semana ($-4,02$ frente al MPC, $p = 5,0 \cdot 10^{-67}$), seguida de cerca por DQN-6 ($n=4$, 39,27). Estas versiones son reentrenamientos del registro de experimentos sobre el dimensionado definitivo, no las versiones DQN-A/B/C de la fase de exploración. La validación obliga a matizar una hipótesis de aquella fase: el n -step ≈ 8 que allí pareció óptimo no se reproduce (con $n=8$ se obtienen 37,24 y 38,34), y el horizonte largo $n=24$ es claramente el peor (31,65). La conclusión robusta no es el valor concreto de n -step, que resulta sensible al resto de la configuración, sino la estructural: toda la familia queda entre 4 y 12 €/semana por debajo del MPC, con el error de cuantización del espacio de acciones discreto como causa de fondo.

PPO discreto (PPO-D1... 5). La validación confirma la hipótesis de la exploración sobre el colapso de entropía: las dos versiones con decaimiento conjunto de entropía y tasa de aprendizaje son las mejores de la familia (PPO-D4, 39,35 €/semana, y PPO-D3, 38,91), mientras que las tres de entropía constante quedan por detrás (37,14 a 37,96), con la de mayor entropía fija (PPO-D5, ent 0,01) como la peor. Aun así, la mejor versión queda 4,04 €/semana por debajo del MPC ($p = 2,4 \cdot 10^{-60}$), prácticamente empatada con el mejor DQN (39,36): las dos familias discretas topan en el mismo techo, coherente con un error de cuantización estructural que ningún ajuste de hiperparámetros elimina.

PPO continuo (PPO-C1... 3). Las tres versiones quedan en 38,14, 33,66 y 38,31 €/semana: pasar a acción continua elimina el error de cuantización pero no basta para alcanzar al MPC (unos 5 €/semana por debajo). Al ser *on-policy*, PPO no puede aprovechar demostraciones del MPC, lo que aísla la conclusión: el mérito del controlador final no está en el espacio de acción continuo, sino en la arquitectura residual.

SAC puro (F5). El mismo algoritmo del controlador ganador, entrenado directamente sobre el entorno continuo sin MPC base ni DAWN, obtiene 26,94 €/semana ($-16,44$, $p = 1,3 \cdot 10^{-83}$), el peor agente de toda la suite e inferior incluso al heurístico. Es la

evidencia más nítida de que el mérito del resultado central corresponde a la *arquitectura residual* y no al algoritmo SAC en sí.

TD3 residual (TD3-1...4). La familia TD3 confirma que la arquitectura residual funciona con otros algoritmos *off-policy*: TD3-1/2/3 ($\delta_{\text{máx}} = 0,15$) resultan estadísticamente indistinguibles del MPC realista ($p = 0,81, 0,12$ y $0,07$), y TD3-4 ($\delta_{\text{máx}} = 0,10$) alcanza $+44,17$ €/semana ($+0,79, p = 1,5 \cdot 10^{-37}$), la mejor media puntual de toda la suite, por encima incluso de SAC-C ($+44,05$). Se mantiene no obstante SAC-C como controlador desplegado, por tres razones: (a) la diferencia entre ambos no es estadísticamente significativa (IC95 $[42,02; 46,37]$ frente a $[41,90; 46,25]$, ampliamente solapados); (b) la familia SAC es más robusta al hiperparámetro, con cinco de sus diez versiones superando al MPC con significancia frente a una de cuatro en TD3, cuyo resultado depende críticamente del valor de $\delta_{\text{máx}}$; y (c) es la familia caracterizada en profundidad (todas las ablaciones F2–F6) y la ya integrada en la plataforma (exportación ONNX, Sección 5.4). TD3-4 queda documentado como alternativa de despliegue equivalente.

DDPG residual (DDPG-1/2). Las dos versiones quedan estadísticamente empatadas con el MPC realista: DDPG-1 (sin ruido de exploración explícito) obtiene $43,44$ €/semana ($+0,05, p = 0,95$) y DDPG-2 (ruido Ornstein-Uhlenbeck) $43,36$ ($-0,03, p = 0,20$). Sin doble crítico ni regularización por entropía, DDPG no extrae valor positivo del margen de corrección, pero tampoco cae por debajo del MPC: la garantía de suelo de la arquitectura residual sostiene incluso al algoritmo más frágil de los tres *off-policy* probados. El patrón agregado de la comparativa es nítido: la arquitectura residual mantiene a todos los algoritmos en el nivel del MPC o por encima, y solo los mejor regularizados (SAC, y TD3 con el rango adecuado) convierten ese suelo en mejora significativa.

Síntesis: hipótesis confirmadas y matizadas

La suite confirma las hipótesis centrales del trabajo: (i) ningún agente de RL puro (valor, *policy-gradient* discreto o continuo, SAC directo) iguala al MPC bien calibrado; (ii) el residual multiplicativo fino lo supera con significancia estadística; (iii) el mérito es de la arquitectura residual y no del algoritmo (F5); y (iv) el resultado es robusto al rango de corrección (meseta de F2). Dos hipótesis intermedias quedan en cambio matizadas por los datos, y se reportan como tales: el n -step óptimo de DQN no es estable entre configuraciones, y DAWN no mejora el rendimiento final (su valor es operativo, no de resultado). Por último, la ablación F6 delimita el dominio de utilidad: la ventaja del residual existe cuando el pronóstico es imperfecto y crece con su error, el escenario realista de una comunidad energética rural.

5.4. Despliegue en Producción: Exportación a ONNX

Una vez diseñado y validado el motor de decisión, esta sección documenta cómo se lleva a producción: la exportación del modelo entrenado a un formato de inferencia ligero que pueda ejecutarse en hardware de borde, paso previo a su integración en la plataforma SaaS (Sección 5.5).

El modelo Residual SAC se entrena con Stable-Baselines3 y PyTorch, un stack pesado e inadecuado para su ejecución en hardware de borde. Para el despliegue en producción, la red del actor se exporta al formato Open Neural Network Exchange (ONNX), un estándar abierto de representación de modelos que permite la inferencia sin las dependencias de entrenamiento. El actor SAC se convierte mediante `torch.onnx.export` al fichero `residual_sac_actor.onnx`, que contiene únicamente la red de política necesaria para inferir la corrección residual; por separado, los parámetros de normalización de observaciones (`VecNormalize`) se exportan a un fichero `.npz` acompañante (`vec_normalize_*.npz`), ya que la red espera observaciones normalizadas con las mismas estadísticas vistas durante el entrenamiento.

En producción, el runtime `onnxruntime` carga el modelo y ejecuta la inferencia con una latencia del orden de milisegundos por paso (despreciable frente al paso de control horario), sin necesidad de PyTorch ni Gymnasium; la equivalencia numérica entre el actor PyTorch y el exportado a ONNX se verifica con los tests `test_onnx_equivalence`. La acción final se reconstruye aplicando la corrección residual multiplicativa sobre la decisión del MPC:

$$\text{flow}_{\text{final}} = \text{máx}(0, \text{flow}_{\text{MPC}} \times (1 + \delta \cdot 0,15)) \quad (5.12)$$

donde δ es la salida del actor ONNX. Esta arquitectura permite desplegar el controlador en un dispositivo de bajo coste (por ejemplo, una Raspberry Pi) que ejecuta el MPC y aplica la corrección del modelo en tiempo real. La Figura 5.5 completa la vista arquitectónica de la Figura 4.1 con las dos capas de producción: el despliegue *edge* y la plataforma SaaS que consume sus decisiones.




Figura 5.5: Arquitectura de la plataforma, parte 2: producción *edge* (exportación ONNX, inferencia ligera y bucle horario) y capa SaaS (recepción de decisiones, histórico y cierres mensuales).

5.5. Plataforma SaaS

La plataforma web LeaLink expone la gestión de la comunidad energética a sus usuarios finales. Está construida sobre Flask con SQLAlchemy como ORM y PostgreSQL como base de datos, desplegada mediante Docker Compose para garantizar la reproducibilidad del entorno. El acceso se organiza en dos roles globales (Superadmin y Usuario), cuyas funciones concretas se detallan al describir el modelo de datos.

5.5.1. Arquitectura

La aplicación se organiza en *blueprints* de Flask, uno por dominio funcional. Los módulos principales gestionan las comunidades, las viviendas, los cierres mensuales, las baterías, las notificaciones, las incidencias y los accesos por rol. La persistencia recae en PostgreSQL, y el despliegue completo (aplicación web, base de datos y proceso de inicialización de datos) se orquesta con `docker-compose.yml`, un `Dockerfile` y un script `entrypoint.sh`. Un endpoint `/health` permite a Docker Compose verificar la disponibilidad del servicio mediante `depends_on: service_healthy`.

Modelo de datos. El núcleo del esquema se compone de siete entidades de dominio (ocho clases, al modelarse `AccesoVivienda` como entidad asociativa), recogidas en la Figura 5.6; a ellas se suma `OperacionHoraria`, el registro horario de las decisiones del controlador *edge* (Sección 5.5.2), con lo que el modelo completo consta de nueve clases. `Comunidad` agrupa sus `Viviendas` (1:N) y a lo sumo una `Bateria` (1:0..1); la relación entre `Usuario` y `Vivienda` es N:M y se materializa en `AccesoVivienda`, que almacena además el rol del usuario dentro de la vivienda (titular, convivente o solo lectura). Cada `Vivienda` acumula su histórico de `CierreMensual`, mientras que `Incidencia` y `Notificacion` vinculan a los usuarios con sus comunidades y viviendas. El acceso se diferencia en dos roles globales: **Superadmin**, que administra el conjunto de entidades,

y **Usuario**, con acceso restringido a sus propias viviendas y cierres.




Figura 5.6: Modelo de datos de la plataforma SaaS: siete entidades con **AccesoVivienda** como relación asociativa N:M entre **Usuario** y **Vivienda**.

5.5.2. Integración con el Motor de Decisión: la API Edge

El nexco entre el modelo ONNX desplegado en el borde y la plataforma SaaS es la API edge. El dispositivo de borde, tras ejecutar el controlador, comunica sus decisiones y resultados a la plataforma a través de dos endpoints: `/api/edge/decision`, que registra la decisión de carga/descarga de cada hora, y `/api/edge/generar-cierre`, que dispara el cálculo del cierre mensual. Ambos se autentican mediante un *token* Bearer y están exentos de la protección CSRF que aplica al resto de la aplicación, al ser consumidos por un cliente automático y no por un navegador.

Conviene explicitar el alcance del prototipo en este punto: el dispositivo de borde no está conectado a APIs de datos en tiempo real, sino que se emula con un proceso que recorre el dataset histórico (los mismos ficheros de ESIOs y PVGIS con los que se entrenó y evaluó el controlador) y alimenta la plataforma a través de exactamente los mismos endpoints que usaría el hardware real. Los conectores a las fuentes en vivo están diseñados con la misma interfaz que el dataset histórico, pero su activación (que requiere únicamente configurar los tokens de acceso) queda como trabajo futuro (Capítulo 9).

5.5.3. Cálculo de Cierres y Reparto por Vivienda

El modelo de decisión opera sobre el agregado comunitario: el MPC y el Residual SAC toman decisiones sobre la batería mirando el balance total de la comunidad (consumo

y generación totales), porque bajo el modelo de cooperativa con un único punto de suministro (autoconsumo individual, Capítulo 3) el balance agregado es la **única factura eléctrica oficial**. Por ello, el dato primario del sistema es el agregado, y el desglose por vivienda no es una facturación regulada, sino la **cuota interna** de reparto del gasto común que la cooperativa asigna a cada socio. En la implementación actual este reparto se efectúa de forma multiplicativa sobre el total horario mediante dos coeficientes energéticos: el **coeficiente de reparto interno** pondera el consumo imputado a cada vivienda, y su **potencia fotovoltaica instalada** pondera la generación, de modo que la suma de las cuotas reproduce exactamente el total de la factura común. La evolución prevista de la plataforma sustituye este reparto energético por **coeficientes de reducción de gasto**: la energía de toda la comunidad se netea horariamente como un único balance (coherente con el neteo del CUPS único sobre el que decide el controlador) y lo que se reparte entre los vecinos no es energía sino el *ahorro económico* resultante, ponderado por el número de paneles solares aportado por cada vivienda. Esta separación entre agregado (que ve el modelo) y desglose (que ve el usuario) garantiza, en ambos esquemas, que la capa de presentación nunca altera los datos sobre los que se entrenó y evaluó el controlador.

Esta elección de operar sobre el agregado no es solo una conveniencia de modelado, sino una consecuencia de la observabilidad real del sistema. El controlador, situado en el punto de generación y almacenamiento, solo mide en tiempo real la generación fotovoltaica, el estado de carga de la batería y el intercambio neto con la red en ese punto; el consumo de la comunidad no se mide directamente en tiempo real (cada vivienda dispone, a lo sumo, de su propio subcontador interno), sino que se estima mediante previsión (perfil histórico agregado y pronóstico meteorológico), que es precisamente la información que el motor recibe en su ventana de pronóstico de 24 horas (Sección 5.3). El motor decide la acción de cada hora a partir de ese pronóstico (la hora en curso es el primer paso de previsión, con la menor incertidumbre), no del valor realizado, que solo interviene en la liquidación física; de este modo se evita cualquier anticipación de información (*lookahead*) y tanto el MPC como el agente reciben exactamente las mismas entradas, lo que garantiza una comparación justa. El desglose individualizado por vivienda solo se determina a posteriori, en el reparto interno del gasto común entre los socios. Por ello, la política de la batería se optimiza necesariamente sobre el balance agregado previsto, y el reparto por participante es competencia de la liquidación interna posterior y no del control.

El **escenario de referencia** para medir el ahorro corresponde al coste que tendría cada vivienda con sus propios paneles fotovoltaicos pero sin batería comunitaria ni

reparto colectivo. Para cada hora h :

$$\text{compra_base}_h = \text{máx}(0, c_h - g_h) \cdot p_c^h \quad (5.13)$$

$$\text{comp_base}_h = \text{máx}(0, g_h - c_h) \cdot p_v^h \quad (5.14)$$

donde c_h y g_h son el consumo y la generación individuales de la vivienda. La factura de referencia mensual es $\text{factura_base} = \text{máx}(0, \sum_h \text{compra_base}_h - \sum_h \text{comp_base}_h)$, y el ahorro mide el valor añadido de la comunidad (batería más reparto colectivo) sobre el autoconsumo individual con paneles propios: $\text{ahorro} = \text{máx}(0, \text{factura_base} - \text{factura_real})$. Comparar contra el escenario *con paneles propios* (y no contra el escenario sin ningún sistema solar) aísla el valor que aporta específicamente la batería comunitaria y el reparto, evitando atribuirle el ahorro que ya proporcionarían los paneles individuales por sí solos.

5.5.4. Naturaleza de los Valores del Panel de Control

La Figura 5.7 muestra el panel de control de la plataforma en funcionamiento para una vivienda concreta: los indicadores de cabecera (ahorro acumulado, media mensual, porcentaje de ahorro sobre la factura y cierres registrados), la evolución mensual del ahorro frente a los dos escenarios de referencia (sin paneles y sin comunidad), la comparativa de gasto entre los tres escenarios, el origen de la energía consumida en el último mes (autoconsumo directo, batería comunitaria y red) y la posición de la vivienda en el ahorro medio mensual de la comunidad.




Figura 5.7: Captura de pantalla del panel de control de la plataforma SaaS (LeaLink) para una vivienda: indicadores de ahorro, comparativa de gasto entre escenarios (sin paneles, sin comunidad y con comunidad), origen de la energía consumida y comparación con el resto de viviendas de la comunidad.

Los valores económicos mostrados en el panel de control de la plataforma (ahorro mensual y acumulado por vivienda) provienen de una simulación de operación continua sobre datos históricos consecutivos, cuyo propósito es demostrar la integración completa del sistema de extremo a extremo. **No constituyen una evaluación del modelo**, que se realiza exclusivamente sobre el conjunto de evaluación *held-out* de 50 semanas según se detalla en la Sección 5.3.12. Esta distinción es importante: el panel ilustra el funcionamiento del sistema desplegado, mientras que la validación científica del controlador reside en el protocolo de evaluación reproducible.

Capítulo 6

Planificación y Seguimiento

6.1. Fases del Proyecto

Cuadro 6.1: Fases del proyecto y distribución temporal.

#	Fase	Inicio	Fin
0	Concepción y viabilidad	Sep 2025	Oct 2025
1	Setup, arquitectura, YAML	Oct 2025	Nov 2025
2	Ingeniería de datos (ETL)	Nov 2025	Dic 2025
3	Simulador físico-económico	Dic 2025	Ene 2026
4	Controlador MPC	Ene 2026	Feb 2026
5	Experimentación DQN y PPO	Feb 2026	Mar 2026
6	Residual SAC y tuning	Mar 2026	May 2026
7	Evaluación unificada y API	May 2026	Jun 2026
8	Documentación y defensa	Jun 2026	Jul 2026




Figura 6.1: Diagrama de Gantt del proyecto, con resolución quincenal: para cada fase, la barra superior (gris) es la planificación inicial y la inferior (azul) la ejecución real. Las mayores desviaciones se concentran en las fases 5 y 6 (en torno a un mes entre ambas, por las causas de la Sección 6.2) y se absorben comprimiendo las fases 7 y 8, manteniendo la entrega en julio de 2026.

6.2. Desviaciones Técnicas

Las fases 5 y 6 acumularon la mayor desviación. La Fase 5 se alargó porque los experimentos con DQN y PPO requirieron análisis sistemático adicional para entender las causas del bajo rendimiento antes del descarte documentado. La Fase 6 se alargó por tres causas: (1) la *cold-start pathology*, identificada y resuelta mediante el protocolo de pre-llenado; (2) el diseño iterativo del espacio de observación de 112 dimensiones; y (3) el tuning de $\delta_{\text{máx}}$ y `ent_coef` mediante exploración sistemática con TensorBoard.

Capítulo 7

Principales Aportaciones

Aportación 1 — Proceso documentado de selección del algoritmo de RL (OG-1, OG-3). A diferencia de trabajos que implementan directamente el algoritmo de moda, este trabajo documenta la experimentación con DQN y PPO, el análisis de sus limitaciones estructurales y el diseño del Residual SAC que las resuelve. La comparativa con un MPC realista bien calibrado como *baseline* (en lugar de una heurística simple) sitúa los resultados en el contexto del estado del arte.

Aportación 2 — Gemelo digital calibrado con datos reales (OG-2). Un simulador físico-económico con modelo de degradación no lineal LFP, modelo económico asimétrico coherente con el RD 244/2019 y dataset de 22.646 horas construido a partir de fuentes oficiales. La brecha intencional entre la degradación linealizada del MPC y el modelo no lineal del simulador es la base del margen de mejora que el Residual SAC explota.

Aportación 3 — Instanciación de la arquitectura Residual RL en el almacenamiento comunitario, con garantía de suelo exacta y verificada (OG-3). El paradigma del aprendizaje residual sobre un controlador base no es original de este trabajo: lo propusieron Johannink et al. (2019) en el contexto del control robótico. La aportación concreta es su adaptación al dominio de la batería comunitaria: un agente SAC que corrige a un MPC realista mediante una formulación residual **multiplicativa**, $\text{flow} \times (1 + \Delta \cdot \delta_{\text{máx}})$ con $\delta_{\text{máx}} = 0,15$, a la que se llegó tras descartar empíricamente la variante aditiva del trabajo original (Sección 5.3.4). Frente a la formulación aditiva, esta escala la corrección con la magnitud del flujo del MPC y, sobre todo, hace que la propiedad de suelo sea **exacta**: con $\Delta = 0$, $\text{flow} \times (1 + 0) = \text{flow}$, de modo que el peor caso del motor es exactamente el MPC realista. Esta propiedad se verifica empíricamente con el test `test_delta_zero_matches_mpc` (módulo `test_residual_env.py`) y no la ofrece ningún algoritmo de RL puro.

Aportación 4 — Plataforma abierta para comunidades rurales (OG-4). Una plataforma software basada íntegramente en herramientas y fuentes de datos públicas (ESIOS, PVGIS), con dashboards diferenciados por rol que democratizan el acceso a la gestión energética inteligente para comunidades de pequeña escala sin conocimientos técnicos.

Capítulo 8

Conclusiones

8.1. Conclusiones Técnicas

El trabajo demuestra empíricamente que RL puro no supera al MPC realista de forma consistente en el dominio de la gestión de baterías comunitarias, resultado coherente con la literatura reciente (Zhan et al., 2023). La suite de validación lo confirma para las cuatro variantes puras: DQN sufre un error de cuantización estructural irresoluble con el espacio discreto de 9 acciones; PPO, discreto o continuo, no puede aprovechar el protocolo de inicialización con demostraciones por su naturaleza *on-policy*; y el SAC directo sin MPC base es el peor agente de toda la suite (+26,94 €/semana).

La arquitectura Residual SAC resuelve ambas limitaciones: opera en espacio continuo y corrige de forma acotada una política base ya optimizada. La propiedad de garantía de suelo es la contribución técnica más valiosa de la arquitectura, y conviene enunciarla con precisión: la identidad $\delta = 0 \Rightarrow$ MPC es exacta y está verificada por test; para el agente entrenado, la corrección acotada limita la desviación posible respecto al MPC. La suite lo respalda empíricamente en sus dos vertientes: las tres semillas de entrenamiento de SAC-C difieren entre sí en solo 0,06 €/semana, y de las 16 configuraciones residuales evaluadas (SAC, TD3 y DDPG), las bien configuradas igualan o superan al MPC y la peor (SAC-B, con el rango de corrección deliberadamente amplio del barrido) queda solo 1,07 €/semana por debajo (2,5 %), frente a los 4 a 16 €/semana que pierden los agentes de RL puro.

El MPC realista alcanza +43,39 €/semana respecto a IDLE, con un margen teórico de mejora de 8,06 €/semana (15,7 %) hasta el MPC oráculo. El Residual SAC recupera +0,66 €/semana de ese margen, en torno al 8 %, una mejora modesta en magnitud pero estadísticamente robusta ($p < 0,001$ en contraste pareado sobre 500 pares semana-ruido) y creciente cuando el pronóstico se degrada (ablación F6). La cuantificación explícita del margen, y de qué fracción es capturable, permite contextualizar los resultados sin sobreestimar el potencial del RL en este dominio.

La suite deja además dos lecciones de honestidad experimental que este trabajo reporta como tales: el *warmup* DAWN no mejora el rendimiento final del residual (su valor es operativo, no de resultado), y el horizonte n -step que la exploración señaló como óptimo

para DQN no se reproduce en la validación (Sección 5.3.12). Ambas correcciones ilustran el valor del esquema exploración-validación adoptado: las hipótesis de la fase barata se confirman o se corrigen con estadística antes de incorporarse a las conclusiones.

8.2. Limitaciones y Decisiones de Diseño

El alcance de este trabajo conlleva simplificaciones que conviene explicitar, distinguiendo las decisiones de diseño deliberadas de las limitaciones impuestas por los datos disponibles.

Optimización sobre el balance agregado y modelo de comunidad. El controlador optimiza el beneficio económico sobre el **balance agregado** de la comunidad. Bajo el modelo adoptado (cooperativa con un único punto de suministro, en la modalidad de autoconsumo individual (Capítulo 3)) ese balance agregado *es* la única factura eléctrica oficial, por lo que la optimización del agregado se corresponde **exactamente** con el coste real, sin desfase entre el objetivo del control y la liquidación. La decisión es además coherente con la observabilidad del sistema: la batería es un único activo físico compartido cuya política de carga y descarga depende solo del balance neto comunitario, y el controlador local únicamente observa magnitudes agregadas previstas (Sección 5.5.3), pues el consumo individualizado solo está disponible a posteriori.

La **condición de aplicabilidad** de este modelo es disponer de un único punto de suministro (contador frontera) sobre una **red interior privada**. Esto es realista en la ecocomunidad rural adoptada (parcelas colindantes de titularidad privada, sin vía de dominio público interpuesta, con la cooperativa como titular único del suministro y subcontadores internos para el reparto del gasto común (Sección 3.1)), pero no en un conjunto de viviendas independientes con CUPS propios y separadas por viario público, donde no es legal tender cableado privado y cada vecino conserva su comercializadora. Conviene además ser explícito en que esta configuración *no* es una figura regulada estándar (las Redes de Distribución Cerradas del RD 314/2023 se reservan a entornos industriales): se sostiene como red interior de un único consumidor, lo que exige la renuncia de los vecinos al contrato individual. En el escenario alternativo (viviendas independientes) la comunidad operaría en **autoconsumo colectivo**, con factura individual por coeficientes; entonces el balance agregado deja de ser la factura y queda como capa de control, y la suma de las facturas individuales podría diferir del óptimo agregado al no existir compensación cruzada entre vecinos en la misma hora. Reconciliar ambas capas con una recompensa formulada vivienda a vivienda afinaría el momento de descarga según el encaje horario de cada perfil, pero exigiría datos de consumo individualizados en tiempo real de los que ni el prototipo ni un despliegue estándar disponen, por lo que entrenarla sobre los perfiles sintéticos actuales conduciría

a sobreajuste.

Naturaleza sintética de los datos. El dataset es un agregado representativo construido a partir del perfil normalizado 2.0TD de ESIOS escalado al consumo medio del hogar español, no un registro de quince viviendas reales; el desglose por vivienda de la capa de facturación es, en consecuencia, una proyección sintética. Los resultados son válidos bajo las hipótesis del modelo y no constituyen mediciones de una instalación física.

Especialización a la comunidad de estudio. El controlador residual aprende sobre el perfil concreto de la comunidad modelada (quince viviendas, 42 kWp, batería de 80 kWh); trasladarlo a otra comunidad de distinto tamaño, generación o consumo exige regenerar el dataset y reentrenar, pues la política se ajusta a esa distribución de carga y generación. No obstante, el **MPC base opera sin reentrenamiento** sobre cualquier comunidad, pues resuelve su LP con los datos que reciba, de modo que el sistema **degrada de forma controlada**: ante una comunidad no vista, el peor caso es operar con el MPC realista mientras se reentrena el residual. Un ajuste fino por comunidad (*transfer learning*) queda como línea de trabajo futuro (Capítulo 9).

Alcance experimental y coste de cómputo. El barrido de configuraciones y semillas no se amplió más allá de la suite presentada, por su coste computacional. El conjunto de entrenamientos y evaluaciones realizado equivale a unas 500 horas de cómputo en un ordenador de gama media (Anexo G), ya que las familias residuales resuelven un problema de programación lineal en cada paso de simulación. Ampliar la rejilla (más versiones, más semillas o ablaciones de componentes internos del algoritmo, como el número de redes crítico) habría multiplicado ese coste sin aportar información proporcional a la pregunta de investigación, centrada en el mérito de la corrección residual sobre el MPC. Por ello el diseño experimental se dirigió a las hipótesis relevantes (modo y magnitud de la corrección, coeficiente de exploración y arranque guiado *DAWN*) en lugar de a una exploración exhaustiva.

Heterogeneidad de los entornos de entrenamiento. Los 31 modelos de la suite se entrenaron en cuatro entornos de software distintos (combinaciones de sistema operativo, versión de Python y *build* de PyTorch; Anexo G). La evaluación es determinista e idéntica para todos ellos (los *baselines* reproducen exactamente los mismos valores en todas las máquinas), por lo que las cifras publicadas son directamente comparables; el entrenamiento de RL profundo es, sin embargo, sensible a la semilla y al entorno de ejecución (Henderson et al., 2018), y esa varianza se gestiona estadísticamente (tres semillas, IC95 por *bootstrap* y test de Wilcoxon) en lugar de homogeneizando el hardware. Las comparaciones internas de la familia residual (barrido δ , ablaciones *DAWN* y F6, formas aditiva y multiplicativa) comparten un mismo entorno de entrenamiento y no se ven afectadas por esta limitación.

Modelo de degradación. La degradación se modela como un coste en la función de recompensa que induce un uso conservador del almacenamiento, pero no reduce la capacidad útil a lo largo del episodio; el efecto del envejecimiento sobre la vida útil se traslada al análisis de viabilidad económica mediante el coste de capital amortizado (Anexo E). Asimismo, solo se contabiliza el envejecimiento por *ciclado* (proporcional a la energía movida, dominante en una batería de uso diario); el envejecimiento de *calendario* (degradación por tiempo y temperatura, independiente del uso) queda fuera del alcance del modelo. Además, el coste de degradación efectivo ($\approx 0,006$ €/kWh, Sección 5.2.5) se calibra a la amortización de una batería LFP *subvencionada*; bajo un coste no subvencionado el ahorro absoluto reportado sería algo menor. En todo caso, al aplicarse de forma idéntica a todos los controladores, la comparación entre ellos (objeto del estudio) es invariante a su valor.

Marco regulatorio en evolución. El tratamiento normativo del almacenamiento compartido se encuentra en evolución: junto al Real Decreto-ley 7/2025, en 2025 se ha sometido a consulta pública un proyecto de real decreto específico sobre el almacenamiento en autoconsumo colectivo. Por su carácter de norma en tramitación, no se asume aquí como marco vigente; su eventual aprobación podría refinar el tratamiento del reparto de la energía almacenada.

8.3. Conclusiones Personales

La principal lección del trabajo es que el rigor en la construcción del entorno de simulación es tan importante como la sofisticación del algoritmo de RL. Un simulador con invariantes violados (simultaneidad de carga y descarga, data leakage en el split, SoC fuera de rango) invalida cualquier resultado independientemente de la complejidad del agente. La suite de 76 tests automatizados no es documentación, es parte del resultado.

La segunda lección es el valor de documentar los experimentos fallidos. El análisis de por qué DQN y PPO no funcionan en este dominio (identificando el error de cuantización y la incompatibilidad *on-policy*) tiene mayor valor académico que simplemente presentar el resultado del algoritmo ganador. Un experimento con resultado negativo bien analizado justifica las decisiones de diseño del algoritmo final.

Capítulo 9

Líneas de Trabajo Futuro

El **aumento del número de semillas de entrenamiento** (de tres a diez o más) reforzaría la caracterización de la robustez inter-entrenamiento, complementando las diez semillas de ruido de evaluación y el contraste de Wilcoxon pareado que la suite de validación ya incorpora. Dada la mínima varianza observada entre las tres semillas de SAC-C (rango de 0,06 €/semana), el beneficio esperado es de confirmación más que de descubrimiento.

La **activación de APIs en tiempo real** es la extensión natural: los conectores ESIOS, Open-Meteo y datadis se diseñan con la misma interfaz que el dataset histórico; activarlos requiere configurar los tokens de acceso.

El **despliegue en hardware de borde** (Raspberry Pi con interfaz Modbus al inversor) es el paso hacia la operación real de los Niveles 1 y 2 del control jerárquico. La arquitectura MPC+Residual SAC tiene una ventaja clave: el MPC base opera desde el primer día sin reentrenamiento.

La **participación en mercados intradiarios de OMIE** y servicios de balance de REE ampliaría la plataforma hacia una arquitectura de gestión energética multi-capas, cubriendo los horizontes sub-horarios de 15 minutos a 2 horas.

La **evolución del módulo de reparto** de la plataforma es la extensión de mayor impacto para el usuario final: el primer paso previsto es sustituir los coeficientes energéticos actuales por coeficientes de *reducción de gasto* (reparto del ahorro económico según el número de paneles aportado, con neteo horario del conjunto de la comunidad, Sección 5.5.4); a más largo plazo, unos **coeficientes dinámicos** ($\beta_{i,h}$ variables hora a hora) requerirían modelado individual por vivienda y un módulo de liquidación más complejo.

La **previsión con modelos LSTM** para irradiancia y consumo podría reducir el coste del ruido de pronóstico (8,06 €/semana) y elevar el rendimiento absoluto del sistema. Conviene señalar el matiz que aporta la ablación F6: un pronóstico mejor beneficia sobre todo al MPC base y reduce la aportación relativa del residual, de modo que esta línea desplaza valor desde el componente aprendido hacia el componente de optimización clásica sin restar rendimiento al conjunto.

Bibliografía

- BloombergNEF. (2024). *Lithium-Ion Battery Pack Prices Survey* (inf. téc.) (Encuesta anual de precios, diciembre de 2024). Bloomberg New Energy Finance. <https://about.bnef.com/insights/commodities/lithium-ion-battery-pack-prices-see-largest-drop-since-2017-falling-to-115-per-kilowatt-hour-bloombergnef/>
- European Commission, Joint Research Centre. (2022). PVGIS: Photovoltaic Geographical Information System. https://re.jrc.ec.europa.eu/pvg_tools/
- Farama Foundation. (2023). Gymnasium: A Standard API for Reinforcement Learning Environments. <https://gymnasium.farama.org>
- Fujimoto, S., van Hoof, H., & Meger, D. (2018). Addressing Function Approximation Error in Actor-Critic Methods. *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 1587-1596. <https://proceedings.mlr.press/v80/fujimoto18a.html>
- Gobierno de España. (2019). Real Decreto 244/2019, de 5 de abril, por el que se regulan las condiciones administrativas, técnicas y económicas del autoconsumo de energía eléctrica [Boletín Oficial del Estado, núm. 83, de 6 de abril de 2019 (BOE-A-2019-5089)]. https://www.boe.es/diario_boe/txt.php?id=BOE-A-2019-5089
- Gobierno de España. (2021). Real Decreto 477/2021, de 29 de junio, por el que se aprueba la concesión directa a las comunidades autónomas y a las ciudades de Ceuta y Melilla de ayudas para la ejecución de diversos programas de incentivos ligados al autoconsumo y al almacenamiento, con fuentes de energía renovable, así como a la implantación de sistemas térmicos renovables en el sector residencial, en el marco del Plan de Recuperación, Transformación y Resiliencia [Boletín Oficial del Estado, núm. 155, de 30 de junio de 2021 (BOE-A-2021-10824)]. https://www.boe.es/diario_boe/txt.php?id=BOE-A-2021-10824
- Gobierno de España. (2023). Real Decreto 314/2023, de 25 de abril, por el que se desarrolla el procedimiento y los requisitos para el otorgamiento de la autorización administrativa de las redes de distribución de energía eléctrica cerradas [Boletín Oficial del Estado (BOE-A-2023-10054)]. https://www.boe.es/diario_boe/txt.php?id=BOE-A-2023-10054
- Gobierno de España. (2025). Real Decreto-ley 7/2025, de 24 de junio, por el que se aprueban medidas urgentes para el refuerzo del sistema eléctrico [Boletín Oficial del Estado, núm. 152, de 25 de junio de 2025 (BOE-A-2025-12857)]. https://www.boe.es/diario_boe/txt.php?id=BOE-A-2025-12857

- Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018). Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 1861-1870. <https://proceedings.mlr.press/v80/haarnoja18b.html>
- Henderson, P., Islam, R., Bachman, P., Pineau, J., Precup, D., & Meger, D. (2018). Deep Reinforcement Learning that Matters. *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence*, 3207-3214. <https://doi.org/10.1609/aaai.v32i1.11694>
- IDAE, Instituto para la Diversificación y Ahorro de la Energía. (2011). Proyecto SECH-SPAHOUSEC: análisis del consumo energético del sector residencial en España (serie SPAHOUSEC). https://www.idae.es/uploads/documentos/documentos_Informe_SPAHOUSEC_ACC_f68291a3.pdf
- Jefatura del Estado. (2013). Ley 24/2013, de 26 de diciembre, del Sector Eléctrico [Boletín Oficial del Estado, núm. 310, de 27 de diciembre de 2013 (BOE-A-2013-13645)]. https://www.boe.es/diario_boe/txt.php?id=BOE-A-2013-13645
- Jefatura del Estado. (2021). Real Decreto-ley 19/2021, de 5 de octubre, de medidas urgentes para impulsar la actividad de rehabilitación edificatoria en el contexto del Plan de Recuperación, Transformación y Resiliencia [Boletín Oficial del Estado, de 6 de octubre de 2021 (BOE-A-2021-16230)]. https://www.boe.es/diario_boe/txt.php?id=BOE-A-2021-16230
- Johannink, T., Bahl, S., Nair, A., Luo, J., Kumar, A., Loskyll, M., Ojea, J. A., Solowjow, E., & Levine, S. (2019). Residual Reinforcement Learning for Robot Control. *2019 International Conference on Robotics and Automation (ICRA)*, 6023-6029. <https://doi.org/10.1109/ICRA.2019.8794127>
- Martin, R. C. (2008). *Clean Code: A Handbook of Agile Software Craftsmanship*. Prentice Hall.
- Ministerio para la Transición Ecológica y el Reto Demográfico. (2024). Orden TED/764/2024, de 22 de julio, por la que se aprueban las bases reguladoras para la concesión de ayudas del nuevo programa de incentivos a proyectos piloto singulares de comunidades energéticas (Programa CE Implementa) [Boletín Oficial del Estado (BOE-A-2024-15412)]. https://www.boe.es/diario_boe/txt.php?id=BOE-A-2024-15412
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529-533. <https://doi.org/10.1038/nature14236>
- Parlamento Europeo y Consejo de la Unión Europea. (2018). Directiva (UE) 2018/2001, de 11 de diciembre de 2018, relativa al fomento del uso de energía procedente de

- fuentes renovables [Diario Oficial de la Unión Europea, L 328, de 21 de diciembre de 2018]. <https://eur-lex.europa.eu/eli/dir/2018/2001/oj>
- Parlamento Europeo y Consejo de la Unión Europea. (2019). Directiva (UE) 2019/944, de 5 de junio de 2019, sobre normas comunes para el mercado interior de la electricidad y por la que se modifica la Directiva 2012/27/UE [Diario Oficial de la Unión Europea, L 158, de 14 de junio de 2019]. <https://eur-lex.europa.eu/eli/dir/2019/944/oj>
- Perera, A. T. D., & Kamalaruban, P. (2021). Applications of reinforcement learning in energy systems. *Renewable and Sustainable Energy Reviews*, 137, 110618. <https://doi.org/10.1016/j.rser.2020.110618>
- Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., & Dormann, N. (2021). Stable-Baselines3: Reliable Reinforcement Learning Implementations. *Journal of Machine Learning Research*, 22(268), 1-8. <http://jmlr.org/papers/v22/20-1364.html>
- Rawlings, J. B., Mayne, D. Q., & Diehl, M. M. (2017). *Model Predictive Control: Theory, Computation, and Design* (2.^a ed.). Nob Hill Publishing.
- Red Eléctrica de España. (2023). ESIOS: Sistema de Información del Operador del Sistema [Indicadores 1001 (PVPC 2.0TD), 1006 (perfiles de consumo) y 1739 (compensación simplificada de excedentes)]. <https://www.esios.ree.es>
- Schmidt, O., Melchior, S., Hawkes, A., & Staffell, I. (2019). Projecting the Future Levelized Cost of Electricity Storage Technologies. *Joule*, 3(1), 81-100. <https://doi.org/10.1016/j.joule.2018.12.008>
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal Policy Optimization Algorithms. *arXiv preprint arXiv:1707.06347*. <https://arxiv.org/abs/1707.06347>
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2.^a ed.). MIT Press.
- Vázquez-Canteli, J. R., & Nagy, Z. (2019). Reinforcement learning for demand response: A review of algorithms and modeling techniques. *Applied Energy*, 235, 1072-1089. <https://doi.org/10.1016/j.apenergy.2018.11.002>
- Vetter, J., Novák, P., Wagner, M. R., Veit, C., Möller, K.-C., Besenhard, J. O., Winter, M., Wohlfahrt-Mehrens, M., Vogler, C., & Hammouche, A. (2005). Ageing mechanisms in lithium-ion batteries. *Journal of Power Sources*, 147(1-2), 269-281. <https://doi.org/10.1016/j.jpowsour.2005.01.006>
- Xu, B., Oudalov, A., Ulbig, A., Andersson, G., & Kirschen, D. S. (2018). Modeling of Lithium-Ion Battery Degradation for Cell Life Assessment. *IEEE Transactions on Smart Grid*, 9(2), 1131-1140. <https://doi.org/10.1109/TSG.2016.2578950>

- Zhan, S., Lei, Y., & Chong, A. (2023). Comparing model predictive control and reinforcement learning for the optimal operation of building-PV-battery systems. *E3S Web of Conferences*, 396, 04018. <https://doi.org/10.1051/e3sconf/202339604018>

Apéndice A

Capacidad Fotovoltaica por Vivienda

El Cuadro A.1 recoge la capacidad fotovoltaica instalada en cada una de las quince viviendas de la comunidad Vilarín, registrada en la plataforma SaaS y utilizada como base para el reparto de la generación. Cada panel tiene una potencia de 400 Wp (silicio monocristalino, orientación sur, inclinación óptima). Las capacidades individuales suman exactamente 42 kWp.

Cuadro A.1: Capacidad fotovoltaica y número de paneles por vivienda.

Código	Dirección	kWp	Paneles
I001	Rúa da Igrexa 1	2,4	6
I002	Rúa da Igrexa 3	2,4	6
I003	Rúa da Igrexa 5	2,0	5
I004	Rúa da Igrexa 7	2,0	5
I005	Rúa da Igrexa 9	3,2	8
I006	Rúa da Igrexa 11	2,0	5
R001	Camiño do Río 2	4,4	11
R002	Camiño do Río 4	2,8	7
R003	Camiño do Río 6	2,0	5
R004	Camiño do Río 8	2,4	6
R005	Camiño do Río 10	5,2	13
R006	Camiño do Río 12	2,8	7
O001	Lugar de Outeiro 1	2,4	6
O002	Lugar de Outeiro 3	2,4	6
O003	Lugar de Outeiro 5	3,6	9
Total		42,0	105

Apéndice B

Configuración Completa: system.yaml

Se reproduce a continuación el fichero `config/system.yaml`, fuente única de configuración del sistema: parámetros físicos de la batería y de la comunidad, rutas de datos, split de semanas, ruido de ETL y de pronóstico, MPC, hiperparámetros del Residual SAC y runtime de producción. Se omiten los comentarios del fichero original; la justificación de cada valor se encuentra en los capítulos correspondientes de esta memoria.

```
1  bateria:
2    capacidad_kwh: 80.0
3    potencia_inversor_kw: 50.0
4    eficiencia_carga: 0.95
5    eficiencia_descarga: 0.95
6    autodescarga_por_hora: 0.00004
7    soc_min: 0.10
8    soc_max: 0.90
9    soc_inicial: 0.50
10   degradacion_base: 0.005
11
12  comunidad:
13    num_viviendas: 15
14    potencia_solar_total_kwp: 42.0
15    consumo_anual_vivienda_kwh: 3500.0
16
17  rutas:
18    consumo_raw: data/raw/consumo_esios_2021_2023.csv
19    precios_raw: data/raw/precios_esios_2021_2023.csv
20    compensacion_raw: data/raw/
21      compensacion_autoconsumo_esios_2021_2023.csv
22    solar_raw: data/raw/solar_pvgis_2021_2023.csv
23    dataset_final: data/processed/dataset_final.csv
24    metadata: data/processed/metadata.json
25
26  split:
27    semilla_split: 42
28    n_semanas_eval: 50
29    horas_por_semana: 168
30
31  etl:
32    semilla: 42
```

```
32   ruido_demanda:
33     rho: 0.50
34     sigma: 0.05
35     clip_min: 0.70
36     clip_max: 1.30
37   precio_excedente_min: 0.0
38
39 pronostico:
40   rho_solar: 0.7
41   rho_consumo: 0.3
42   sigma_solar_h1: 0.05
43   sigma_solar_h24: 0.25
44   sigma_consumo: 0.15
45   precio:
46     hora_publicacion: 20.5
47     sigma_intradiario: 0.05
48     sigma_estadistico: 0.15
49     rho_intradiario: 0.5
50     rho_estadistico: 0.7
51     margen_intradiario_h: 6
52
53 mpc:
54   horizonte: 24
55   duracion_episodio: 168
56   n_episodios: 500
57   valor_terminal:
58     activado: true
59     lambda: 0.0
60     modo_precio: "ultimo"
61   k_deg_lin: 0.005
62   modo_pronostico: "realista"
63
64 residual_sac:
65   total_timesteps: 1_000_000
66   delta_max: 0.15
67   dawn_warmup_steps: 100_000
68   learning_rate: 1.0e-4
69   buffer_size: 100_000
70   batch_size: 256
71   gamma: 0.99
72   tau: 0.005
73   ent_coef: 0.01
74   target_entropy: "auto"
75   net_arch: [256, 256]
76   eval_freq: 20_000
77   eval_episodes: 50
78   seeds: [42, 1337, 2024]
```

```
79     norm_obs: true
80     norm_reward: false
81     clip_obs: 10.0
82
83     produccion:
84         onnx_path: models/residual_sac_actor.onnx
85         npz_path:  models/vec_normalize_v5_1M.npz
86         delta_max: 0.15
87
88     api:
89         feed_mode: historico
```

Apéndice C

Árbol de Directorios del Repositorio

El repositorio se organiza en nueve directorios de primer nivel. El código fuente vive bajo `src/`, separado en paquetes por responsabilidad (núcleo de simulación, entornos, controladores, entrenamiento, evaluación, producción y plataforma SaaS); la configuración, los datos, los artefactos de modelo y los resultados experimentales tienen directorios propios, de modo que el código nunca contiene valores del sistema ni rutas cableadas.

```
TFG/
+-- config/                Configuración declarativa (única fuente)
|   +-- system.yaml        física, ETL, MPC y SAC (Apendice B)
|   +-- experimentos.yaml  registry de experimentos y versiones
+-- data/
|   +-- raw/               4 CSV oficiales crudos (ESI0S y PVGIS)
|   +-- processed/         dataset_final.csv + metadata.json (hashes)
+-- doc/
|   +-- diagramas/         fuentes drawio/PlantUML de las figuras
|   +-- memoria_latex/     esta memoria
+-- docker/                Imagen edge ARM64 (Dockerfile.edge)
+-- experimentos/          Puntos de entrada: build_dataset.py,
|                           entrenar.sh y eval_rapida.py
+-- models/               Artefactos de entreno (.zip, .pkl, .onnx, .npz)
|   +-- best/              campeones por familia de algoritmo
+-- resultados/            resultados.csv canónico + un JSON por versión
+-- src/
|   +-- core/              config, simulator, forecast, observation
|   +-- envs/              entornos Gymnasium: base, discreto,
|                           continuo y residual
|   +-- controllers/       heurístico, MPC, base continua/discreta
|                           y controlador Residual SAC
|   +-- buffers/           replay buffer n-step
|   +-- training/          mains por algoritmo, scaffold común,
|                           multiseed, registry y callbacks
|   +-- evaluation/        suite, evaluación unificada, escenarios
|                           y estadística (IC95, Wilcoxon)
|   +-- production/        export ONNX, inferencia edge, data feed
|                           y bucle horario
|   +-- saas/              plataforma Flask LeaLink (app, módulos,
|                           modelos, templates y tests propios)
+-- tests/                Suite pytest transversal (Apendice D)
```

Esta separación es la que recorre, fase a fase, el diagrama de dependencias de la Figura C.1.

La Figura C.1 complementa el árbol de directorios con el mapa completo de componentes y dependencias del pipeline del Residual SAC, en seis fases: datos/ETL, entrenamiento,

evaluación, exportación ONNX, producción *edge* y SaaS. Cada caja es un módulo real del repositorio y las flechas distinguen el flujo de la acción, las dependencias de código y los artefactos que pasan de una fase a la siguiente.




Figura C.1: Componentes y dependencias del pipeline completo del Residual SAC (seis fases, de los datos crudos al SaaS). Los artefactos que cruzan fases (`dataset_final.csv`, `best_model.zip`, `residual_sac_actor.onnx`) aparecen resaltados.

Apéndice D

Suite de Tests Automatizados

Los 76 tests automatizados ejecutables con `pytest` se distribuyen en once módulos: `test_dataset.py` (12 tests del pipeline ETL), `test_energy_env_continuo.py` (16 tests del entorno y el simulador), `test_mpc.py` (7 tests del controlador MPC, incluida la factibilidad del LP sobre 1.000 escenarios aleatorios), `test_heuristic.py` (8 tests de los invariantes del *baseline* heurístico: respeto de los límites de SoC y las eficiencias, y ausencia de arbitraje con la red), `test_residual_env.py` (10 tests de la arquitectura residual), `test_delta_zero.py` (2 tests de la propiedad de suelo), `regresion/test_golden.py` (14 tests de regresión *golden master* que fijan el comportamiento del simulador y los entornos frente a refactorizaciones), `test_fisica_4flujos.py` y `test_decode_equivalencia.py` (equivalencia de la física de 4 flujos y del decodificador discreto como fuente única), `test_onnx_equivalence.py` (2 tests de equivalencia numérica entre el actor PyTorch y el exportado a ONNX) y `test_edge_loop_saas.py` (3 tests de integración del bucle *edge* con la API del SaaS). El Cuadro D.1 recoge una selección de los invariantes críticos verificados:

Cuadro D.1: Tests críticos del sistema.

Test	Propósito	Módulo
<code>test_split_no_solapado</code>	Pools train/eval completamente disjuntos	ETL
<code>test_delta_zero_matches_mpc</code>	$\Delta = \mathbf{0} \Rightarrow$ replica al MPC	Residual
<code>test_residual_delta_zero</code>	Salida nula del actor preserve la acción MPC	Residual
<code>test_soc_always_in_bounds</code>	SoC $\in [10\%, 90\%]$ en todo momento	Simulador
<code>test_soc_max_no_carga</code>	No carga por encima del SoC máximo	Simulador
<code>test_soc_min_no_descarga</code>	No descarga por debajo del SoC mínimo	Simulador
<code>test_precios_excedente_no_negativos</code>	$p_{\text{exc}} \geq 0$ en todo el dataset	ETL

Apéndice E

Análisis de Viabilidad Económica

E.1. Coste de la Inversión

El coste de un sistema de almacenamiento BESS comercial LFP de 80 kWh en formato armario se sitúa, según las referencias de mercado de 2026, en un rango de 180 a 300 €/kWh para sistemas instalados de esta escala. Tomando un valor de referencia de 250 €/kWh para una instalación de pequeña escala (más cara por kWh que los grandes proyectos de red), la inversión asciende a aproximadamente 20.000 €.

E.2. Beneficio del Controlador y Periodo de Retorno

El beneficio económico que sustenta este análisis es el beneficio marginal validado del controlador frente al escenario sin batería (IDLE): +44,05 €/semana sobre el conjunto de evaluación (IC95 [41,90; 46,25], suite de validación, Sección 5.3.12), equivalente a unos 2.300 €/año para el conjunto de la comunidad (horquilla del IC95: 2.185 a 2.412 €/año). Representa el valor marginal real de la batería (el desplazamiento temporal de energía que el controlador optimiza), independiente del autoconsumo solar directo, que es atribuible a los paneles y no al almacenamiento. Conviene matizar que esta cifra refleja el régimen de precios del periodo 2021–2023, que incluye la crisis energética de 2022; en un escenario de precios más moderados el beneficio anual sería menor.

Conviene subrayar esta distinción, recurrente en el análisis del sistema: el grueso del ahorro de una instalación de autoconsumo procede de consumir la energía solar en el momento de generarla, lo que ocurre con o sin batería. La batería únicamente añade el desplazamiento temporal de los excedentes, y es ese desplazamiento lo que el controlador optimiza y la simulación cuantifica.

Nota. Este análisis parte del beneficio marginal validado del controlador (+44,05 €/semana, Sección 5.3.12) y constituye una estimación de orden de magnitud. No debe confundirse con los valores por vivienda en €/año que ilustra el panel de la plataforma (Sección 5.5.4), procedentes de una simulación de facturación de extremo a extremo con un propósito distinto.

Con una inversión de referencia de 20.000 € ($250 \text{ €/kWh} \times 80 \text{ kWh}$) y un beneficio anual

del orden de 2.300 €, el periodo de retorno simple sin ayudas se sitúa en torno a los nueve años (8,3 a 9,2 años según la horquilla del IC95), frente a una vida útil de la batería LFP de 15 a 20 años. Es, por tanto, una inversión de retorno positivo aunque ajustado en ausencia de ayudas públicas.

E.3. El Papel de las Subvenciones

El marco de ayudas vigente en España modifica sustancialmente esta conclusión. Los programas de incentivos a comunidades energéticas del IDAE (Programa CE IMPLEMENTA, Orden TED/764/2024 (Ministerio para la Transición Ecológica y el Reto Demográfico, 2024)) contemplan proyectos de autoconsumo colectivo con almacenamiento, en los que las comunidades de propietarios son elegibles, con intensidades de ayuda a fondo perdido de hasta el 60 % para la generación renovable y el 30 % para el almacenamiento, lo que en un proyecto mixto de autoconsumo con batería supone en torno al 40 % de la inversión total. A esto se suma la deducción en el IRPF por obras de mejora de la eficiencia energética (RD-ley 19/2021 (Jefatura del Estado, 2021), prorrogado) y bonificaciones municipales en el IBI.

Aplicando una subvención del 40 %, la inversión neta desciende a unos 12.000 €, lo que reduce el periodo de retorno a algo más de cinco años, holgadamente dentro de la vida útil del sistema.

E.4. Conclusión

El análisis arroja una conclusión honesta y matizada: el beneficio del almacenamiento gestionado hace de la batería una inversión de retorno positivo aunque ajustado sin ayudas públicas (en torno a nueve años), que el marco de subvención actualmente vigente y dotado convierte en claramente rentable. Esta dependencia de las ayudas no es una particularidad del proyecto, sino la realidad de prácticamente todas las comunidades energéticas en España. En este contexto, el valor del controlador inteligente es precisamente maximizar el retorno disponible sea cual sea el escenario de ayudas, extrayendo el mayor beneficio posible de la batería instalada. El dimensionamiento óptimo conjunto de generación y almacenamiento, así como una política generalizable a distintas capacidades, constituyen líneas de trabajo futuro.

Apéndice F

Resultados Completos de la Suite de Validación

Este anexo recoge las 31 versiones de la suite de validación y los cuatro *baselines*, evaluados bajo el protocolo unificado (50 semanas *held-out* $\times$ 10 semillas de ruido; IC95 por *bootstrap*; p del test de Wilcoxon pareado por semana y semilla de ruido frente al MPC realista; dimensionado 42 kWp / 80 kWh). Fuente: `resultados/resultados.csv`, generado por `src/evaluation/suite.py` a partir del registro `config/experimentos.yaml`. Las versiones con una sola semilla de entrenamiento son confirmaciones puntuales de ablación; el resto usa tres semillas y despliega la mejor (Sección 5.3.10).

F.1. Baselines (sin aprendizaje)

Controlador	€/sem	IC95	p
G1 MPC oráculo	51,45	[44,07; 60,29]	n/a
G2 MPC realista (referencia)	43,39	[41,24; 45,57]	—
G3 Heurístico	30,49	[28,14; 32,91]	$4,6 \cdot 10^{-75}$
G4 IDLE (sin batería)	0,00	—	n/a

F.2. Familia DQN (valor, discreta; 3 semillas)

Versión	Config. clave	€/sem	IC95	Δ	p
DQN-1	$n=1, \gamma=0,995$	39,36	[37,21; 41,62]	−4,02	$5,0 \cdot 10^{-67}$
DQN-2	$n=8, \gamma=0,995$	37,24	[35,02; 39,57]	−6,15	$5,0 \cdot 10^{-72}$
DQN-3	$n=8, \gamma=0,99$	38,34	[36,17; 40,62]	−5,05	$1,0 \cdot 10^{-71}$
DQN-4	$n=24$	31,65	[29,98; 33,38]	−11,74	$1,3 \cdot 10^{-83}$
DQN-5	$n=8, \text{lr } 5 \cdot 10^{-4}$	37,16	[35,06; 39,33]	−6,23	$5,5 \cdot 10^{-78}$
DQN-6	$n=4$	39,27	[36,99; 41,64]	−4,11	$2,4 \cdot 10^{-66}$

F.3. Familia PPO discreto (on-policy, discreta; 3 semillas)

Versión	Config. clave	€/sem	IC95	Δ	p
PPO-D1	rollout 2048, ent 0,01 const.	37,49	[35,30; 39,78]	−5,89	$5,5 \cdot 10^{-73}$
PPO-D2	rollout 4096, ent 0,003 const.	37,96	[35,72; 40,29]	−5,43	$3,9 \cdot 10^{-69}$
PPO-D3	rollout 8192, ent con decaimiento	38,91	[36,66; 41,22]	−4,47	$4,2 \cdot 10^{-67}$
PPO-D4	rollout 8192, ent y lr con decaimiento	39,35	[37,09; 41,70]	−4,04	$2,4 \cdot 10^{-60}$
PPO-D5	rollout 8192, ent 0,01 const.	37,14	[34,96; 39,40]	−6,24	$5,2 \cdot 10^{-75}$

F.4. Familia PPO continuo (on-policy, continua; 3 semillas)

Versión	Config. clave	€/sem	IC95	Δ	p
PPO-C1	std ₀ 0,5; ent y lr con decaimiento	38,14	[35,84; 40,56]	−5,24	$4,2 \cdot 10^{-41}$
PPO-C2	std ₀ 0,3; ent y lr con decaimiento	33,66	[31,53; 35,88]	−9,73	$1,5 \cdot 10^{-80}$
PPO-C3	rollout 4096; ent y lr constantes	38,31	[36,08; 40,66]	−5,07	$6,5 \cdot 10^{-45}$

F.5. SAC puro (continua, sin MPC; 3 semillas)

Versión	Config. clave	€/sem	IC95	Δ	p
F5	SAC directo, sin MPC ni DAWN	26,94	[25,53; 28,40]	−16,44	$1,3 \cdot 10^{-83}$

F.6. Familia Residual SAC (controlador propuesto)

Versión	Config. clave	Sem.	€/sem	IC95	Δ	p
SAC-A	aditiva, $\delta=0,05$, ent 0,005	3	42,47	[40,28; 44,73]	-0,91	$1,8 \cdot 10^{-28}$
SAC-B	mult., $\delta=0,30$, ent 0,002	3	42,31	[40,20; 44,48]	-1,07	$7,4 \cdot 10^{-40}$
SAC-C	mult., $\delta=0,15$, ent 0,01	3	44,05	[41,90; 46,25]	+0,66	$1,5 \cdot 10^{-23}$
F2-d05	$\delta=0,05$	1	43,79	[41,64; 45,99]	+0,41	$6,6 \cdot 10^{-55}$
F2-d10	$\delta=0,10$	1	44,01	[41,86; 46,22]	+0,63	$2,8 \cdot 10^{-37}$
F2-d20	$\delta=0,20$	1	43,78	[41,65; 45,97]	+0,40	$5,9 \cdot 10^{-9}$
F2-d30	$\delta=0,30$	1	42,43	[40,35; 44,57]	-0,95	$1,7 \cdot 10^{-27}$
F4-nodawn	sin <i>warmup</i> DAWN	1	44,04	[41,90; 46,23]	+0,65	$3,1 \cdot 10^{-24}$
F6-s05	$\sigma_{\text{cons}}=5\%$	1	47,48	[45,11; 49,92]	-0,79*	$1,9 \cdot 10^{-68}$
F6-s25	$\sigma_{\text{cons}}=25\%$	1	40,02	[38,11; 41,99]	+1,42*	$8,6 \cdot 10^{-61}$

Las versiones F2/F4/F6 parten de la configuración de SAC-C y modifican solo el parámetro indicado. No existe fila F6-s15: es exactamente SAC-C ($\sigma_{\text{cons}}=15\%$ es el valor estándar).

*En F6 la Δ se calcula frente al MPC realista evaluado con el mismo nivel de ruido que el agente.

F.7. Familia TD3 residual (3 semillas)

Versión	Config. clave	€/sem	IC95	Δ	p
TD3-1	$\delta=0,15$, delay 2, ruido 0,2	43,44	[41,33; 45,60]	+0,06	0,81
TD3-2	$\delta=0,15$, ruido 0,1	43,34	[41,24; 45,50]	-0,04	0,12
TD3-3	$\delta=0,15$, delay 3, lr $3 \cdot 10^{-4}$	43,57	[41,45; 45,72]	+0,19	0,07
TD3-4	$\delta=0,10$, delay 2, ruido 0,2	44,17	[42,02; 46,37]	+0,79	$1,5 \cdot 10^{-37}$

F.8. Familia DDPG residual (3 semillas)

Versión	Config. clave	€/sem	IC95	Δ	p
DDPG-1	$\delta=0,15$, sin ruido de exploración	43,44	[41,32; 45,60]	+0,05	0,95
DDPG-2	$\delta=0,15$, ruido OU $\sigma=0,15$	43,36	[41,24; 45,52]	-0,03	0,20

Apéndice G

Reproducibilidad y Entornos de Entrenamiento

Los 31 modelos de la suite se entrenaron distribuyendo las familias entre cuatro máquinas, con entornos de software distintos. Este anexo documenta esos entornos (extraídos del `system_info.txt` que Stable-Baselines3 almacena dentro de cada artefacto `.zip`) y las condiciones bajo las que los resultados son comparables.

Cuadro G.1: Entornos de entrenamiento por familia.

Familias	SO	Python	PyTorch
residual_sac (10), sac_puro, ppo_continuo (3)	Windows 10	3.14.6	2.12.1+cpu
ppo discreto (5), ddpq_residual (2)	Windows 10	3.12.7	2.12.1+cpu
dqn (6)	Linux (WSL2)	3.14.4	2.12.1+cu130
td3_residual (4)	Linux (WSL2)	3.12.3	2.12.1+cpu

Coste de cómputo. El entrenamiento completo de todos los modelos de la suite consume aproximadamente 500 horas de cómputo en un ordenador de gama media (CPU de escritorio, sin aceleración por GPU relevante para estos tamaños de red). El grueso del coste corresponde a las familias residuales, que resuelven un problema de programación lineal (el MPC base) en cada paso de simulación; la distribución entre cuatro máquinas (Cuadro G.1) respondió precisamente a la necesidad de paralelizar ese coste.

Evaluación determinista y comparabilidad. El protocolo de evaluación es determinista: dado un modelo y una semilla de ruido, produce siempre el mismo resultado, y los *baselines* sin aprendizaje (MPC, heurístico, IDLE) reproducen exactamente los mismos valores en todas las máquinas. Todas las cifras publicadas se obtuvieron con el mismo protocolo y son, por tanto, directamente comparables con independencia de dónde se entrenó cada modelo.

Gestión de la varianza de entrenamiento. El entrenamiento de RL profundo no es reproducible bit a bit entre entornos distintos: el *build* de PyTorch, la versión de las librerías de álgebra y el número de hilos alteran el orden de las operaciones en

coma flotante, y el bucle de aprendizaje amplifica esas diferencias microscópicas hasta producir modelos distintos, un fenómeno documentado en la literatura (Henderson et al., 2018). En la práctica el entorno actúa como una semilla adicional: introduce varianza, no sesgo (ningún entorno favorece sistemáticamente a un algoritmo). Esa varianza se gestiona en este trabajo igual que la de la semilla: tres semillas de entrenamiento por versión, intervalos de confianza al 95 % por *bootstrap* y contraste de Wilcoxon pareado, de modo que ninguna conclusión se apoya en una ejecución individual.

Comparabilidad interna de la familia residual. Todas las comparaciones internas del controlador propuesto (formas aditiva y multiplicativa, barrido δ de F2, ablación DAWN de F4 y sensibilidad al pronóstico de F6) se entrenaron en un mismo entorno, por lo que no se ven afectadas por esta heterogeneidad. La única comparación ajustada entre entornos distintos es SAC-C frente a TD3-4, y se trata como tal en la Sección 5.3.12: la diferencia entre ambos no es estadísticamente significativa y la elección del controlador desplegado se justifica por robustez y profundidad de caracterización, no por la media puntual.

Apéndice H

Historial Completo de Experimentos

Este anexo recoge el historial completo de configuraciones de agentes entrenadas durante el desarrollo del motor de decisión. El cuerpo de la memoria (Sección 5.3) presenta únicamente los hitos representativos que motivaron decisiones de diseño; este anexo documenta el volumen real de experimentación, incluyendo configuraciones intermedias y fallidas, como evidencia del proceso iterativo de tuning y justificación de las desviaciones de planificación recogidas en el Capítulo 6.

H.1. Familia DQN

Cuadro H.1: Historial de configuraciones DQN.

Ver.	Obs.	Acc.	n-step	Buffer	Pasos	Resultado / Nota
DQN_10	101	13	1	100k	1M	Base, sin n-step ni AR(1)
DQN_11	101	13	1	100k	2M	$\approx 39,38$; AR(1) añadido
DQN_12	101	13 $\rightarrow$ 9	8	200k	2M	Interrumpido; reduce acciones
DQN_13	101	9	8	200k	1,88M	+45,23 (mejor); $\gamma=0,995$
DQN_14	101	9	24	400k	3M	+41,71; no convergió
DQN_15	107	9	8	400k	3M	Máx +51,83; buffer erróneo
DQN_16	107	9	24	200k	5M	Crash a 4M; datos perdidos
DQN_17	101	9	24	200k	5M	Run corto, abortado
DQN_18	101	9	24	200k	5M	30–35; no converge
DQN_19	107	9	8	200k	3M	30–35; no converge
DQN_20	101	9	8	200k	3M	+45,07 ; $\gamma=0,99$

La conclusión de la familia DQN es que las configuraciones con $n = 8$ (DQN_13 y DQN_20) son las que mejor rinden, alcanzando ambas en torno a +45 €/semana pese a usar factores de descuento distintos ($\gamma = 0,995$ y $\gamma = 0,99$ respectivamente). Las configuraciones DQN_18 y DQN_19 no replicaron este rendimiento y se estancaron en torno a 30–35 €/semana, lo que sugiere que la convergencia depende de la interacción entre el factor de descuento, el número de pasos de propagación *n-step* y la duración

del entrenamiento, y no de un único hiperparámetro de forma aislada. El conjunto de experimentos confirma que la combinación $n = 8$ con entrenamiento suficiente es la vía más fiable hacia el mejor rendimiento de la familia.

H.2. Familia PPO

Cuadro H.2: Historial de configuraciones PPO.

Ver.	Obs.	Rollout	ent_coef	Pasos	Resultado / Nota
PPO_1	101	2048	0,01 const.	3M	Máx +39,91; colapso a 36
PPO_2	101	4096	0,003 const.	3M	Máx +41,82; colapso a 37
PPO_3	108	8192	decay 0,005→0,0005	3M	+44,72; sin colapso
PPO_4	108	8192	decay + LR decay	4M	+45,69 ; convergió

El decaimiento del coeficiente de entropía (PPO_3, PPO_4) resuelve el colapso de política observado en las configuraciones con entropía constante (PPO_1, PPO_2). PPO_4 añade además decaimiento de la tasa de aprendizaje, logrando la mejor configuración de la familia.

H.3. Familia Residual SAC

Cuadro H.3: Historial de configuraciones Residual SAC.

Ver.	Arquit.	$\delta_{\text{máx}}$	ent	Warmup	Resultado / Nota
v2	aditiva	0,10	0,01	50k	+48,80; sin neteo, OOM
v3	aditiva	0,05	0,005	50k	≈ 41 ; correcciones mínimas
v4	multiplic.	0,30	0,002	100k	$\approx 43,3$; se estanca
v5	multiplic.	0,15	0,01	100k	+49,23; supera MPC
v5b	multiplic.	0,20	0,01	100k	+49,06; rango amplio peor
v5c	multiplic.	0,15	0,01	200k	Warmup doble; en curso

La progresión de la familia Residual SAC ilustra el proceso de refinamiento de la arquitectura: la transición de aditiva (v2, v3) a multiplicativa (v4–v5c) resuelve el problema de la corrección de magnitud fija, y el ajuste del rango de corrección de $\delta_{\text{máx}} = 0,30$ (v4) a 0,15 (v5) consigue el equilibrio entre capacidad de corrección y

respeto a la política base del MPC. La configuración v5 es la seleccionada y, una vez fijado el dimensionado definitivo, su arquitectura se reentrenó y validó sobre 42 kWp/80 kWh dentro de la suite de validación bajo el identificador SAC-C, cuyos resultados se reportan en la Sección 5.3.12 y en el Anexo F.